INSTITUTO UNIVERSITÁRIO DE LISBOA

Introdução à Ciência de Dados

Aula 01

Ana Rita Peixoto

Martim Santos

Miguel Teodoro

2025/2026

Introdução à UC

- Equipa Docente e de Monitores
- Logística
- Objetivos da UC
- Processo Pedagógico
- Avaliação
- Planeamento

Equipa Docente

Ana Rita Peixoto (coordenadora)
rita_peixoto@iscte-iul.pt

Miguel Teodoro
miguel_teodoro@iscte-iul.pt

Martim Hernandez dos Santos
martim_hernandez@iscte-iul.pt

Equipa Monitores

João Botas
joao_botas@iscte-iul.pt

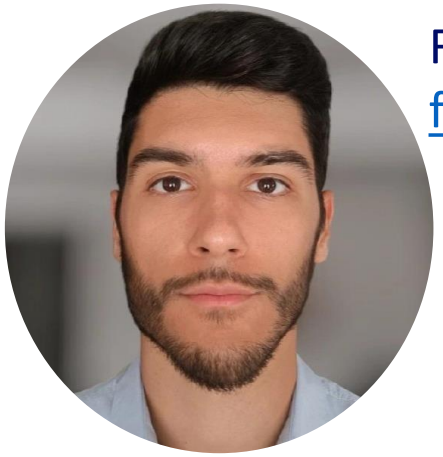

Francisco Pereira
francisco_miguel_bandeira@iscte-iul.pt

Filipa Martins
manuela_martins@iscte-iul.pt

Logística

- Conteúdos e informações nas plataformas eletrónicas
  - Fénix+ (fenix-mais.iscte-iul.pt) e Moodle (moodle.iscte-iul.pt)
- Avisos, mails e notas urgentes são enviados através das plataformas
  - Pode ser necessário fazer reencaminhamento automático (forward) das mensagens que chegam ao e-mail institucional (x@iscte-iul.pt) para o endereço que mais usam
- Dúvidas relativas aos conteúdos de matéria, exercícios ou trabalhos podem ser esclarecidas nos horários de dúvidas

Objetivos da UC

Esta unidade curricular visa um primeiro contacto com a Ciência de Dados

- Proporcionar uma visão geral dos conceitos fundamentais
- Familiarização com a Ciência de Dados
  - Entender o seu enquadramento no meio científico, na gestão e na sociedade;
  - Compreender a génese da Ciência de Dados e os fatores que levaram ao seu aparecimento
- Conhecer os tipos de dados tratados em Ciência de Dados, os seus atributos e implicações éticas de uso e ciclo de vida.
- Desenvolver o conhecimento do aluno sobre os tipos de projetos de Ciência de Dados e quais as linguagens de programação, algoritmos, bases de dados e ferramentas mais utilizadas.
- Contribuir para o desenvolvimento e acuidade do pensamento crítico do aluno no "Pensar com/os dados".

Processo pedagógico

Teoria com aplicação prática guiada e estudo com pesquisa autónoma

- Conteúdos de "visão global".
- Ilustração com casos e aspetos práticos
  - Exemplos de casos práticos da indústria
  - Tratamento exploratório de dados
- Temas apresentados e discutidos em sala MAS necessária pesquisa e reflexão autónoma
  - **Tempo de trabalho autónomo ≈ 2,5 x tempo letivo**

Ao concluir com sucesso a UC será capaz de

- Defender a necessidade da existência de uma prática científica, empresarial e societal de Ciência de Dados, elencando os benefícios da sua adopção.
- Defender a necessidade de um enquadramento ético nos e com os dados.
- Distinguir a Ciência de Dados de disciplinas afins, identificando semelhanças e diferenças.
- Entender conceitos elementares em análise de dados (data analytics) e o papel dos respetivos contextos nos dados e modelos de dados.

Avaliação

- Esta UC é feita apenas por avaliação periódica, não contemplando a modalidade de avaliação por exame!
- Componentes de avaliação:
  - Projeto (80%): projeto de grupo (4 elementos)
    - Entrega: **14/12/2025** às 23h59 no moodle
    - Apresentação: **18/12/2025** presencialmente
  - Atividades de avaliação (20%)
    - 4 minitestes no moodle, contam os 3 melhores, para cada miniteste possuem 2 tentativas e conta a última
    - 3 exercícios em aula, submetidos no moodle no período da aula, e avaliados da seguinte forma: A(20), B(16), C(12), D(8) ou E(0)
- **A nota final do projeto dependerá do projeto *orange*, do relatório e do desempenho dos estudantes na apresentação do trabalho realizado**
- A assiduidade não é contabilizada

Planeamento

Data	Conteúdo	Exercício	Miniteste
25/09	Introdução à UC; O que é a Ciência de Dados.		
02/10	Questões éticas e impacto; Ciclo de Dados.		
09/10	Tipos de problemas e de soluções; CRISP-DM.		X
16/10	Visualização de dados.	X	
23/10	Familiarização com a ferramenta *Orange*; Apresentação temas projeto.		
30/10	Preparação de dados.		X
06/11	Técnicas de modelação.	X	
13/11	Técnicas de modelação (continuação).		X
20/11	Casos práticos com dados não estruturados (Texto e Imagem).	X	
27/11	Apoio ao projeto: análise exploratória de dados e escolha de variáveis.		X
04/12	Apoio ao projeto: modelação e interpretação de resultados.		
11/12	Apoio ao projeto: melhoramentos e visualização de resultados.		

O que é a Ciência de Dados?

- Definição de Ciência de Dados
- Porquê agora?
- Dados, dados e mais dados

Ciência de Dados: o que é?

- Existem visões algo distintas na academia e na indústria, um sem número de jargões (termos técnicos) complicam e tornam confusa uma definição única.
  - Tal como Computer Science, Data Science é multi-disciplinar e aplicada
  - Hoje em dia, concorda-se que possui características de disciplina académica
  - Começam a existir Mestrados e Pós-graduações no mundo inteiro (em especial, nos EUA)
  - Mais recentemente, nascem as primeiras Licenciaturas
  - Em 2019, surge a primeira Licenciatura em Portugal: a do Iscte!

Ciência de Dados: o que é?

Data science is an interdisciplinary academic field that uses statistics, scientific computing, scientific methods, processes, algorithms and systems to extract or extrapolate knowledge and insights from noisy, structured, and unstructured data.

Wikipedia, 2023

A ciência do planeamento, aquisição, análise e inferência a partir de dados.

Definição da NSF (National Science Foundation, USA)

Ciência de Dados: o que é?

- Em ambiente empresarial, Data Science é, atualmente, uma "moda"
- Mas a extração de perspetivas e conhecimento a partir (e por causa) de dados é importante e provavelmente irá continuar a crescer em importância:
- Tal como Computer Science, Data Science é multi-disciplinar e aplicada
- As técnicas para tratar Big data estão a mudar o modo como se trabalha nos mais variados domínios: Educação, Saúde, Mercados de retalho (alimentar, ...), Finanças, etc.
- Diferentes termos são muitas vezes usados como sinónimos: data analytics, data mining, business analytics, business intelligence
  - Em geral, referem-se a um processo onde conhecimento (factos) interessante é inferido a partir dos dados disponíveis

Ciência de Dados: o que é?

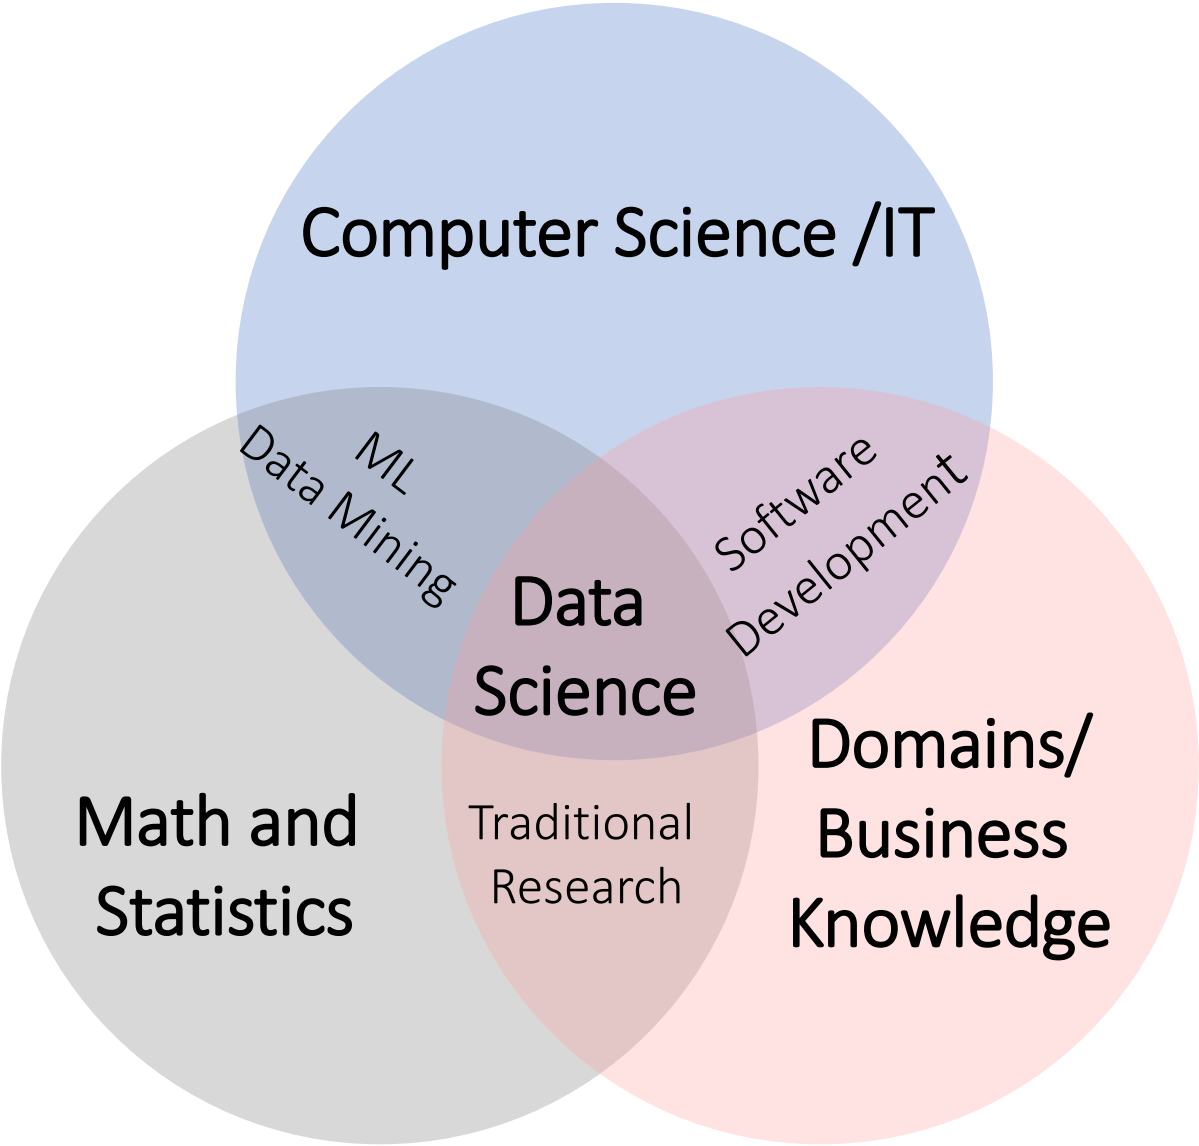

Domínios onde a Ciência de Dados estar a ter impacto

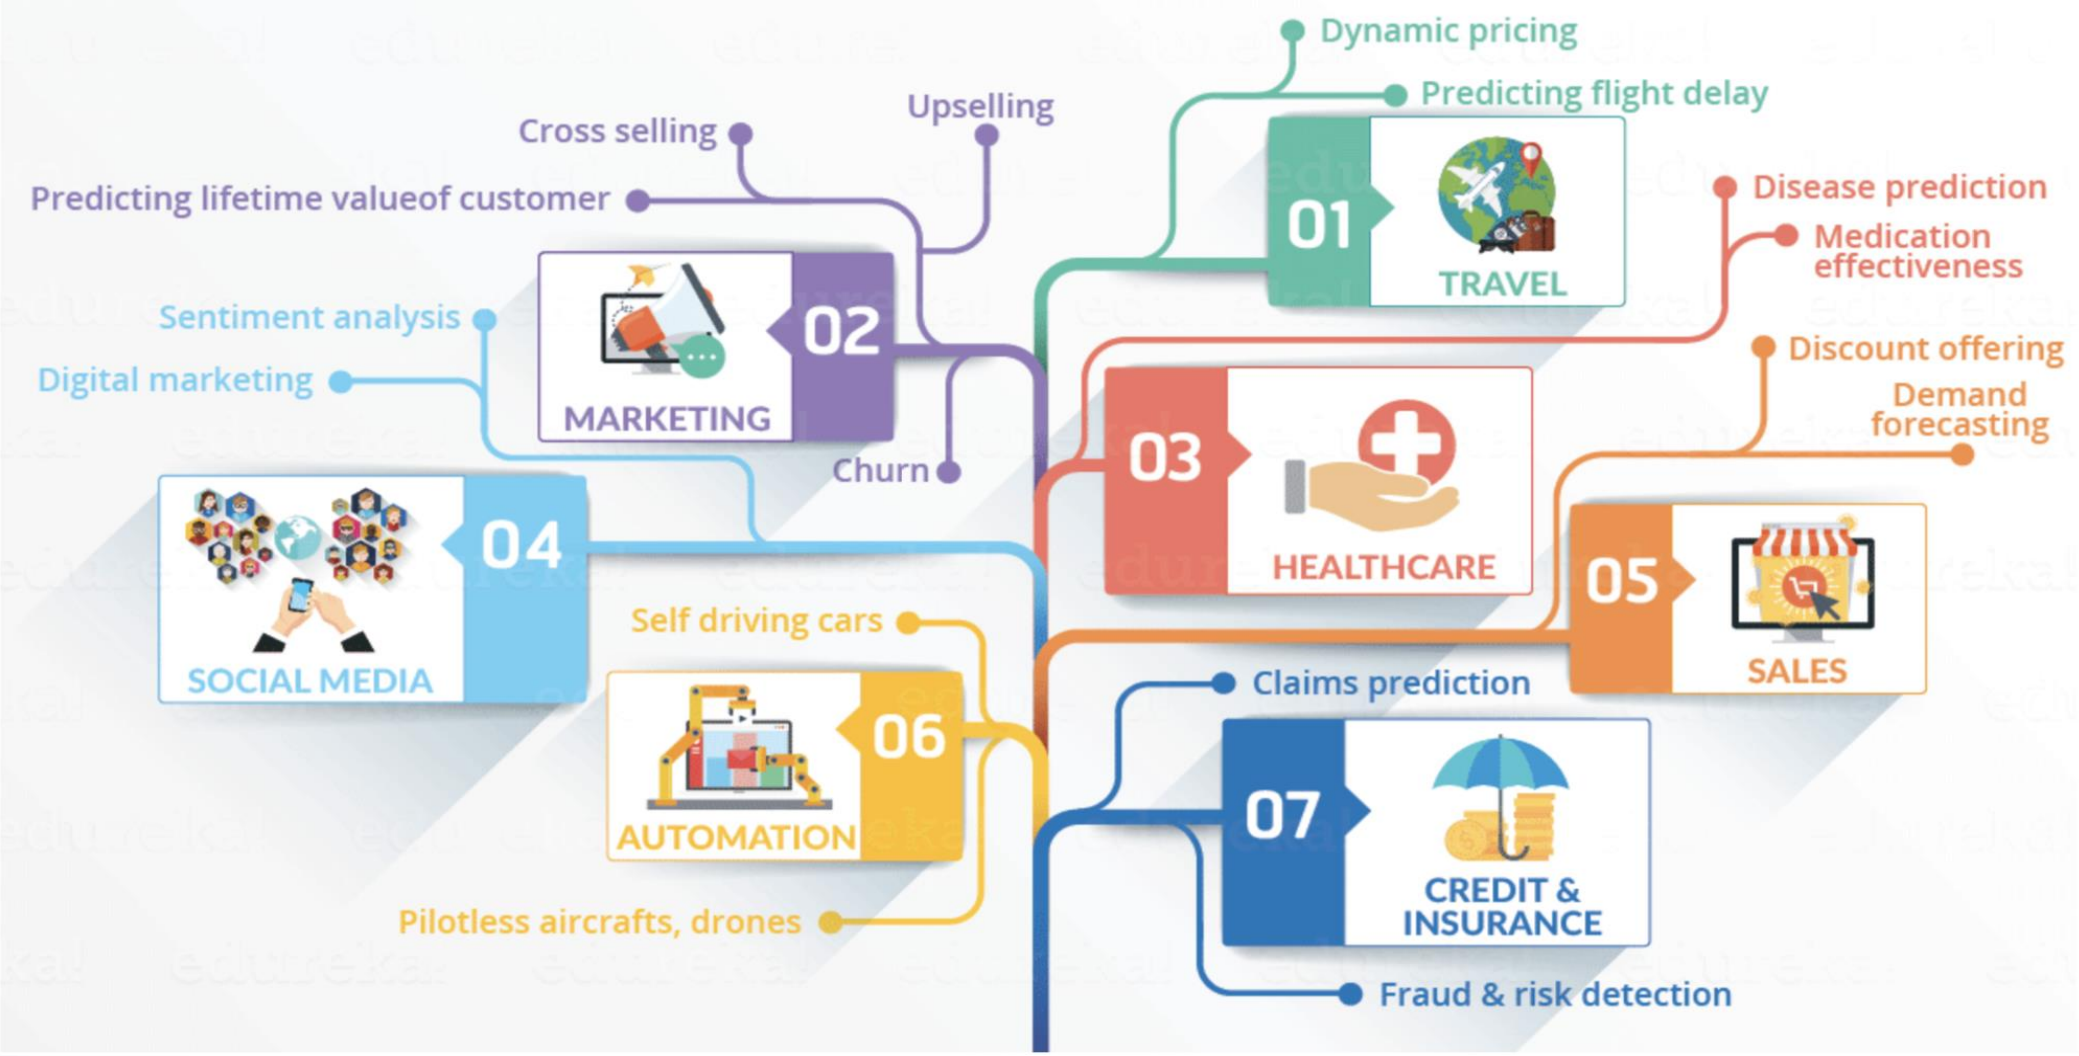

https://medium.com/edureka/what-is-data-science-a-beginners-guide-to-data-science-e684c2d6752d

Porquê agora?
Mudança de Paradigma

- Antes: Conjuntos de dados relativamente limitados, bem organizados, limpos
- Agora: Conjuntos de dados enormes, sem uma hieraquização/organização linear, com ruído
  - deixamos de usar amostras bem estudadas e cuidadosamente obtidas o que torna dificil fazer uma análise fina
  - grandes volumes de dados são recolhidos para alimentar os algoritmos (a quantidade é (pode ser) grande o suficiente para "abafar" o ruído…)
- Causalidade é substituída por Correlação
  - descobrir a causa dos dados que existem é, em geral, difícil de perceber
  - descobrir se dois factos estão correlacionados pode ser suficiente
- *Datificação:* processo de converter algo abstrato em dados (digitais) concretos

Mudança de Paradigma

Google trends (04/02/2024)

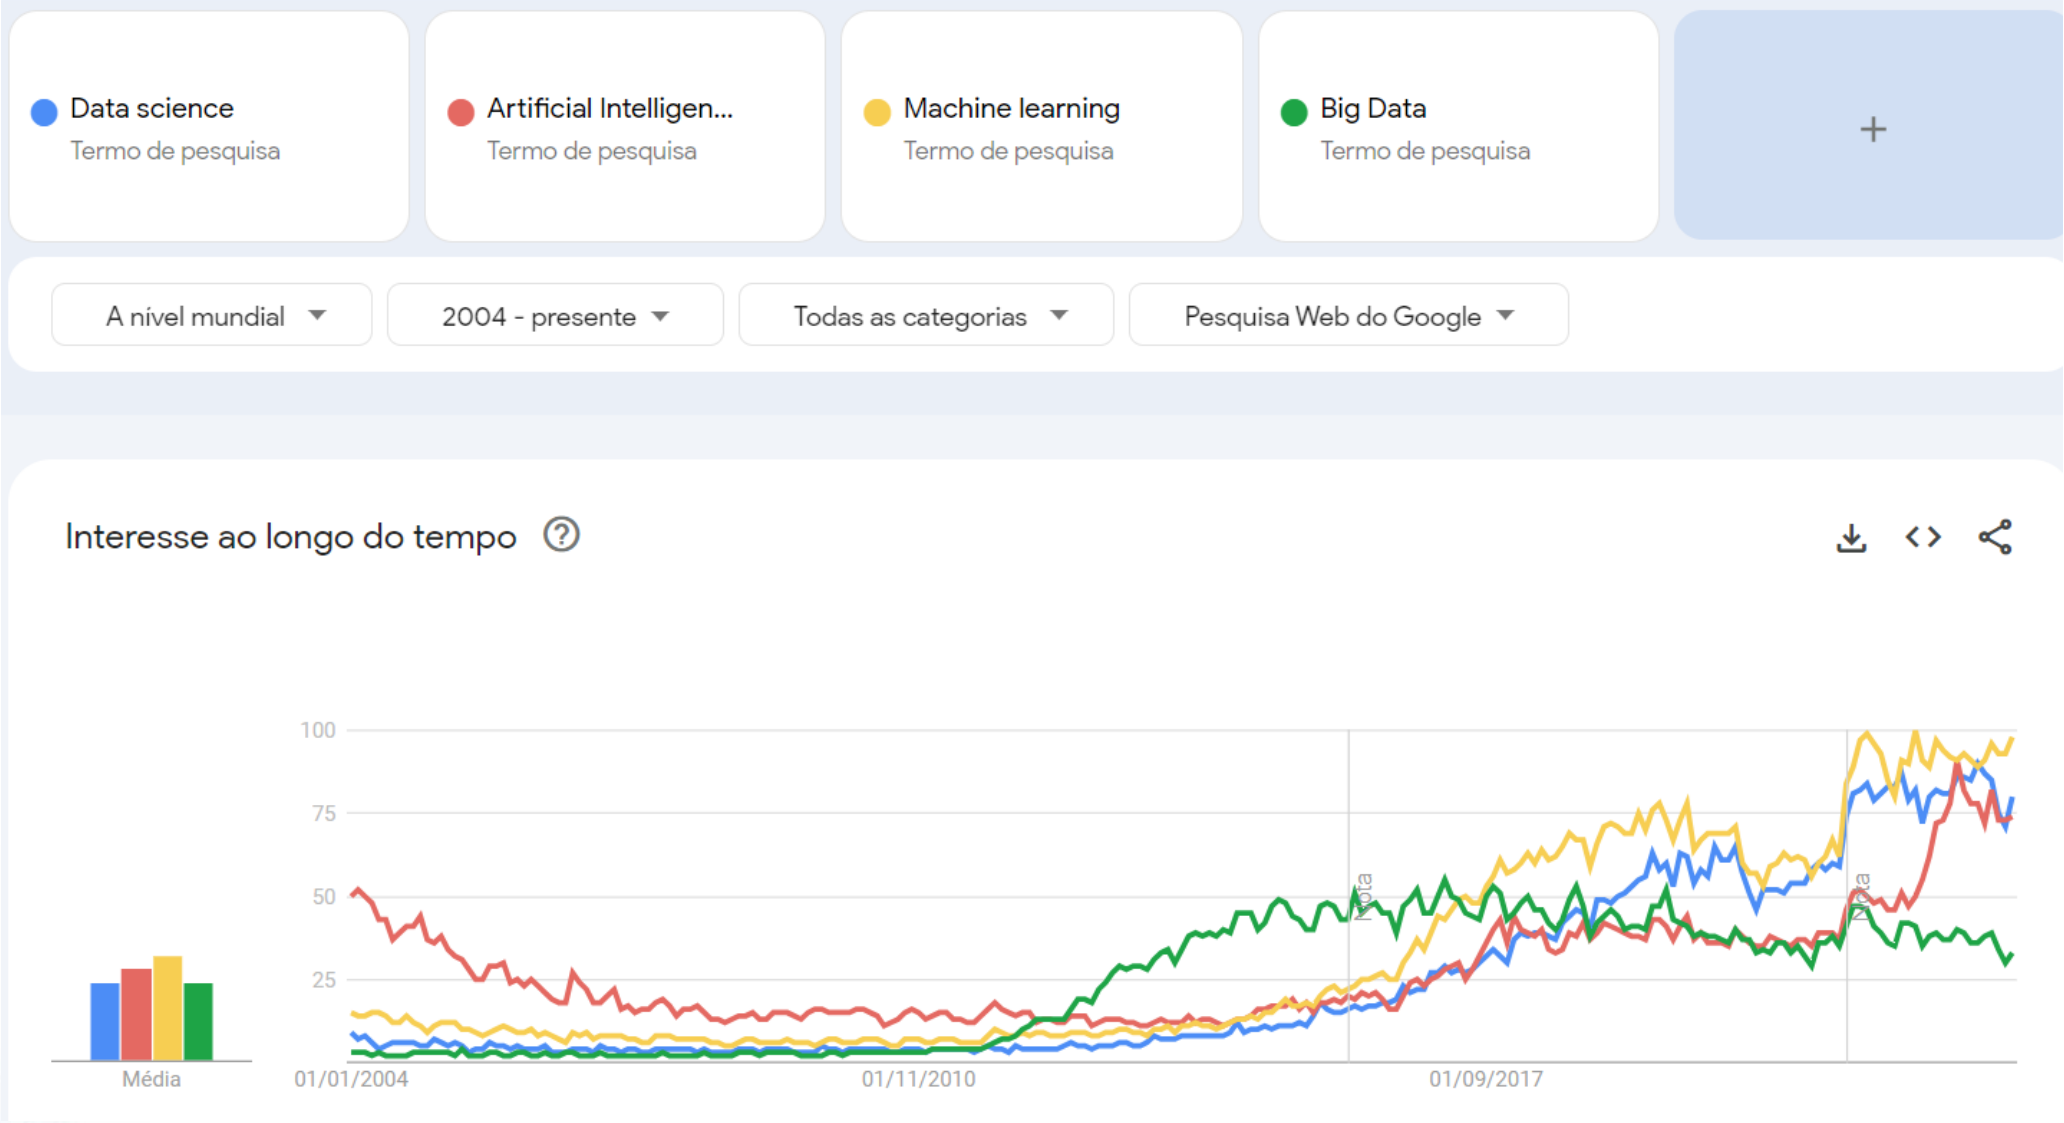

Mudança de Paradigma

Harvard Business Review

Data | Data Scientist: The Sexiest Job of the 21st Century

Subscribe

ARTWORK: TAMAR COHEN, ANDREW J BUBOLTZ, 2011, SILK
PAGE FROM A HIGH SCHOOL YEARBOOK, 8.5" X 12"

DATA

Data Scientist: The Sexiest Job of the 21st Century

by Thomas H. Davenport and D.J. Patil

FROM THE OCTOBER 2012 ISSUE

Summary Save Share 16 Comment Text Size Print $8.95 Buy Copies

When Jonathan Goldman arrived for work in June 2006 at LinkedIn, the business networking site, the place still felt like a start-up. The company had just under 8 million accounts, and the number was growing quickly as existing members invited their friends and colleagues to join. But users weren't seeking out connections with the people who were already on the site at the rate executives had expected. Something was apparently missing in the social experience. As one LinkedIn manager put it, "It was like arriving at a conference reception and realizing you don't know anyone. So you just stand in the corner sipping your drink—and you probably leave early."

Goldman, a PhD in physics from Stanford, was intrigued by the linking he did see going on and by the richness of the user profiles. It all made for messy data and unwieldy analysis, but as he began exploring people's connections, he started to see possibilities. He began forming theories, testing hunches, and

WHAT TO READ NEXT

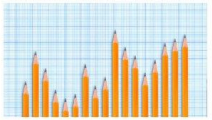

What Data Scientists Really Do, According to 35 Data Scientists

VIEW MORE FROM THE

October 2012 Issue

2/3 FREE ARTICLES LEFT > REGISTER FOR MORE

It’s a world of data

“This year’s findings reflect the ever-changing and fast-paced digital landscape, which has only been heightened by the rapid popularity of AI models such as ChatGPT,” said Josh James, founder and CEO, Domo. “Data drives everything we do, from a quick search online or sending an email, to checking the latest headlines on our way to work. Data Never Sleeps, now in its eleventh year, depicts just how much we rely on data and its impact on our daily lives in one of the 525,600 minutes in a year.”

https://www.domo.com/learn/infographic/data-never-sleeps-11

It's a world of data

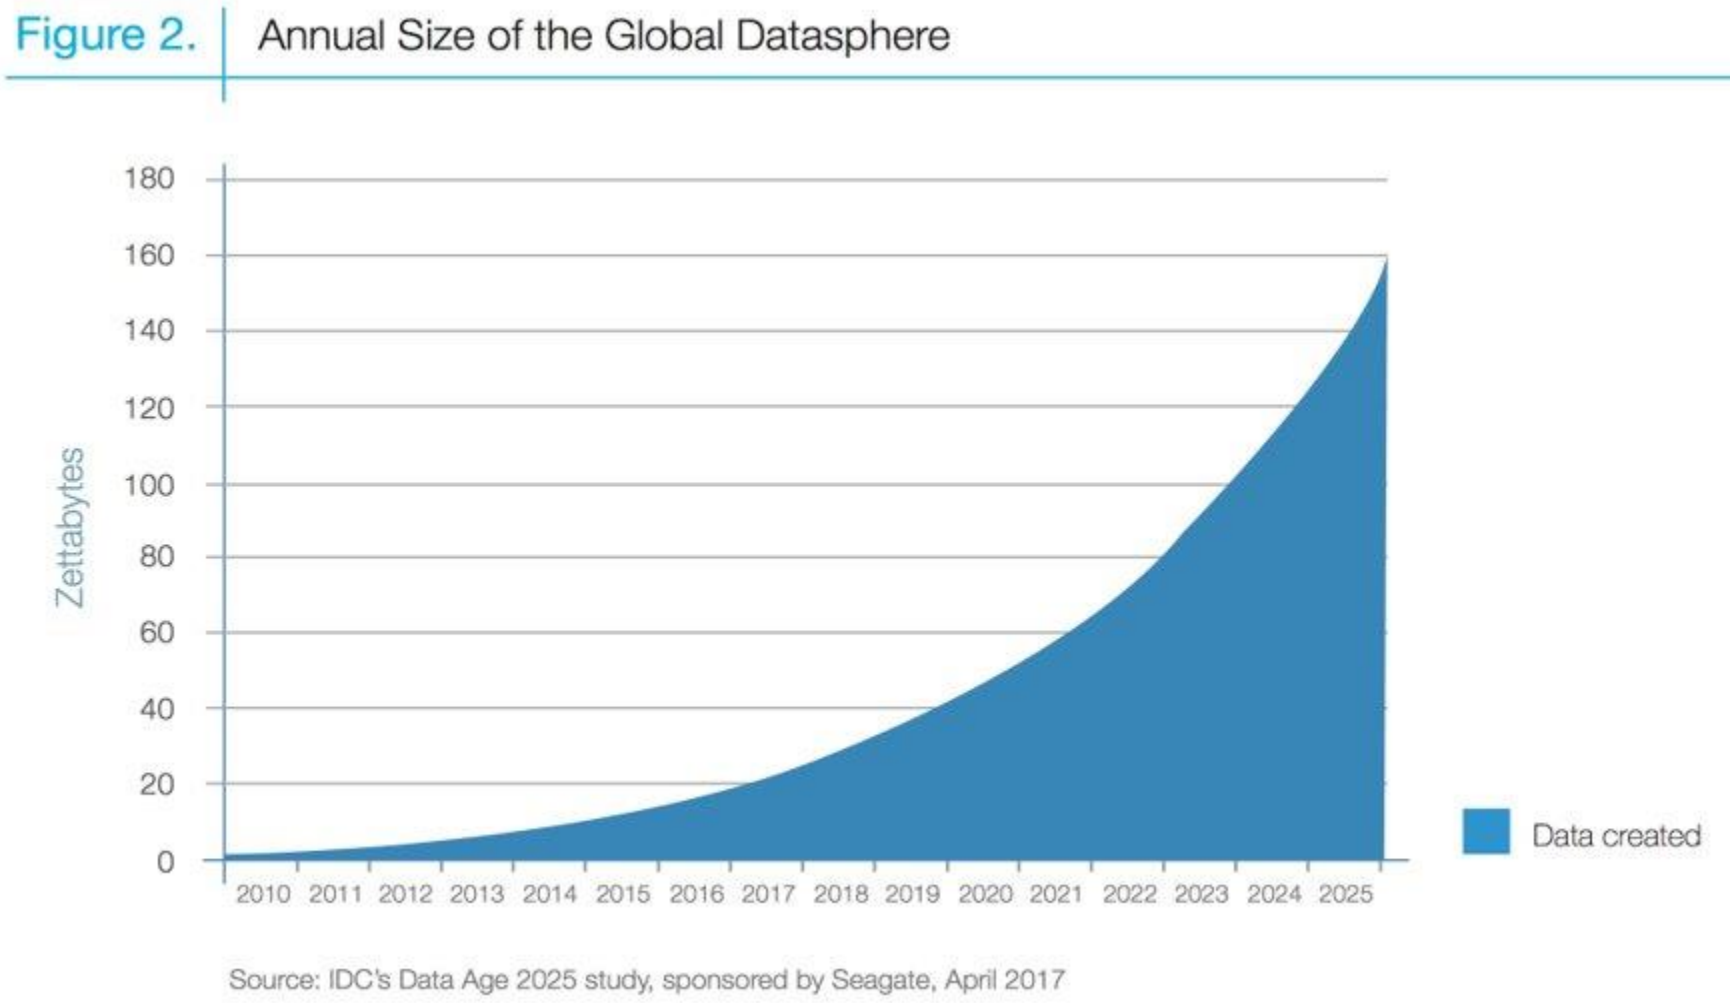

Algoritmos mais eficientes

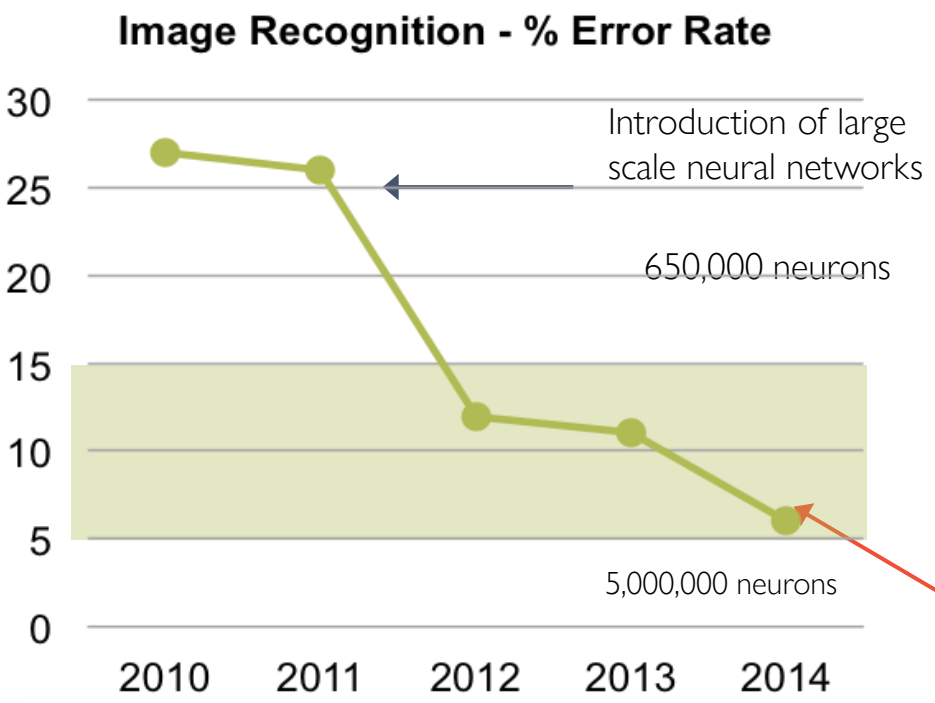

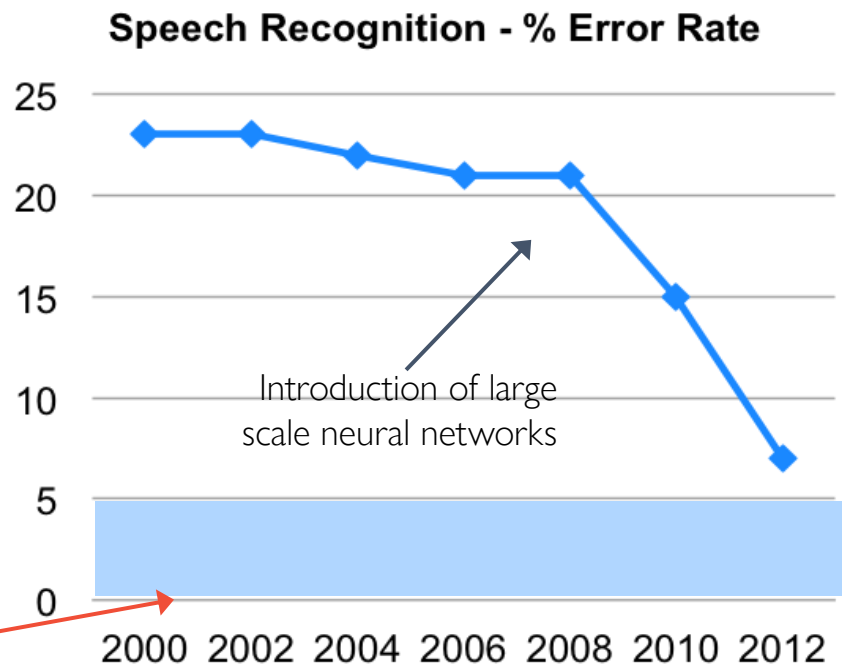

Human Error

Ref: O. Russakovsky et al., arXiv:1409.0575v1 [cs.CV], 1 Sep 2014

Custo de Processamento

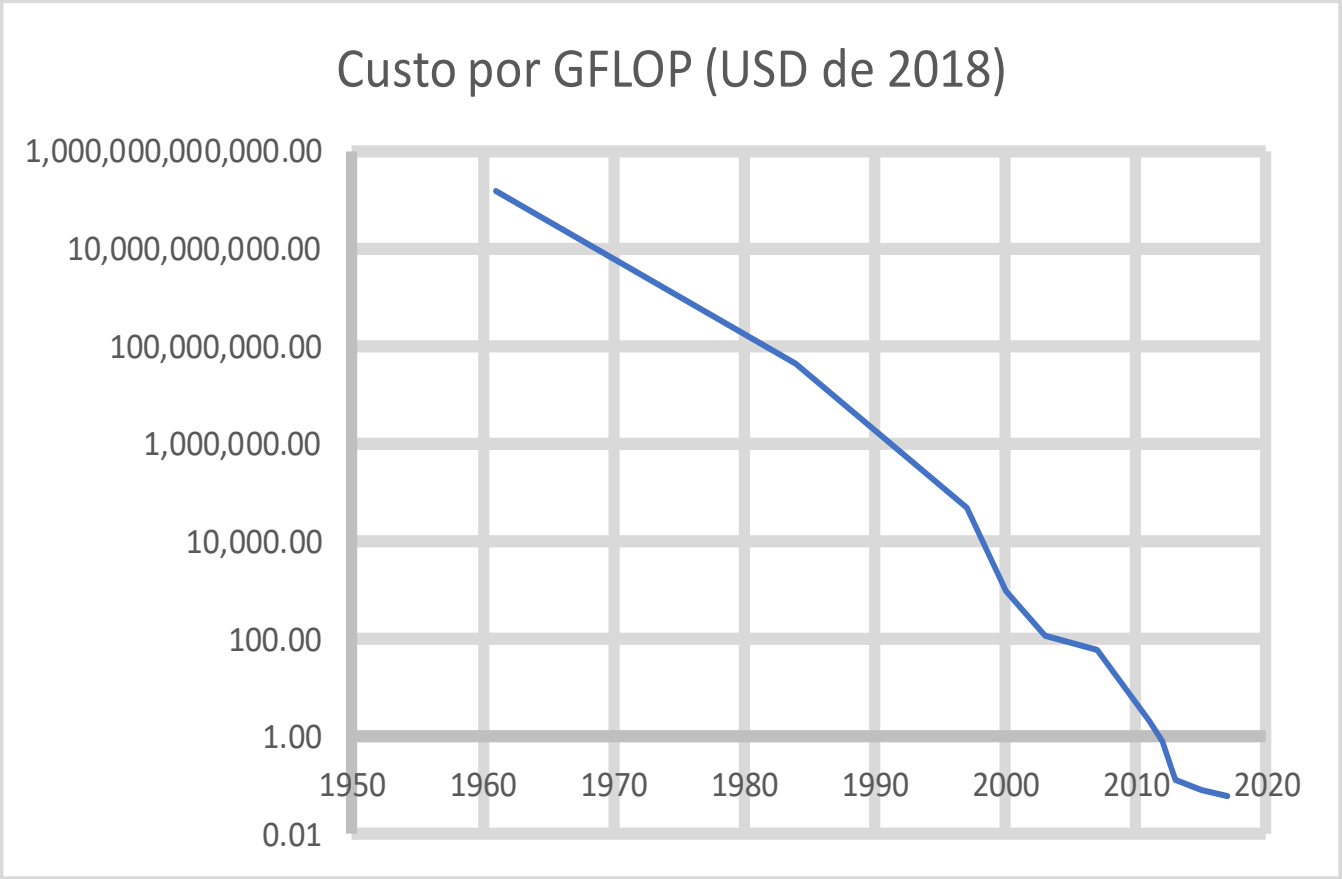

Fonte: https://en.wikipedia.org/wiki/FLOPS

Custo unitário decrescente de capacidade de computação

Nota:
GFLOP: 1 000 000 000 (109) operações em vírgula flutuante por segundo.

Um processador de última geração de computadores tipo "*desktop*" chega a atingir 300Gflops.

Mas o que são dados?

Uma fotografia de férias tirada com o telemóvel é um dado?

O saldo da conta bancária é um dado?

A chapa de matrícula de um automóvel é um dado?

O número de contribuinte fiscal é um dado?

Uma sequência “0000, 0001, 0001, 0010, 0011, 0101, 1000, 1101…” é um dado?

Dados - Definição

data

noun plural but singular or plural in construction, often attributive | da·ta | \ˈdā-tə, ˈda- *also* ˈdä-\

Simple Definition of DATA

Popularity: Top 1% of lookups

: facts or information used usually to calculate, analyze, or plan something

: information that is produced or stored by a computer

Source: Merriam-Webster's Learner's Dictionary

Informação factual (tal como medidas ou estatísticas) usadas como base de raciocínio, discussão ou cálculo.

Dados - Definição

Modelo **OAIS** – Open Archive Information System:
Dados são uma representação, re-interpretável, de informação, formalizada para comunicação, interpretação ou processamento.

O modelo OAIS faz ainda uma distinção interessante entre dados, informação, e conhecimento:

- "Informação é qualquer tipo de conhecimento que se pode partilhar. Na partilha, a informação é representada por dados. Por exemplo, uma sequência de bits acompanhada por uma descrição de como interpretar essa sequência como números que representam observações térmicas medidas em graus Celsius."

Dados vs Informação vs Conhecimento

Obtém-se aplicando a experiência humana na análise de **informação**

Exemplo:

Dados: 16B 10C 8D 14B 9D 19A 13C 17A

Informação: Dados com contexto

Número Aluno	Nota Numérica	Nota Nominal
65231	16	B
87523	10	C
77654	8	D
87642	14	B
67452	9	D
69138	19	A
96789	13	C
98723	17	A

Qual o conhecimento que se retira?

Notas numéricas < 10 -> D

Notas numéricas >= 10 e <14 -> C

Notas numéricas >= 14 e < 17-> B

Notas numéricas >= 17 -> A

Contexto e metadados

O contexto pode ser (parcialmente) expresso por **dados acerca de dados.**

A riqueza dos metadados influencia a possibilidade de transferência de informação.

Metadados podem ser interligados, criando grafos de conhecimento que constituem ontologias de informação.

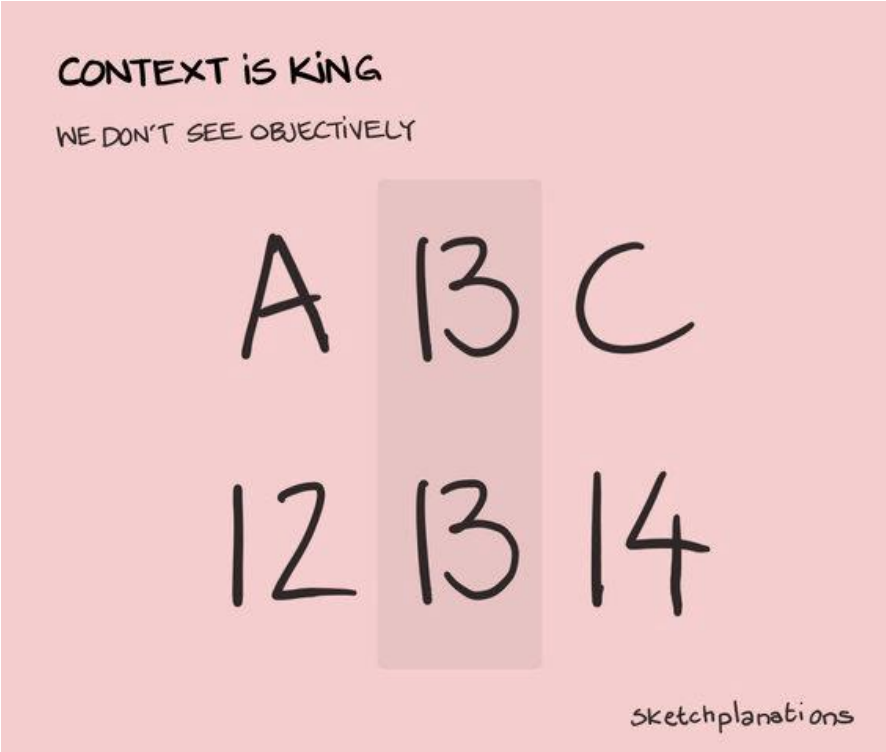

https://sketchplanations.com/context-is-king

O que significam estas riscas?

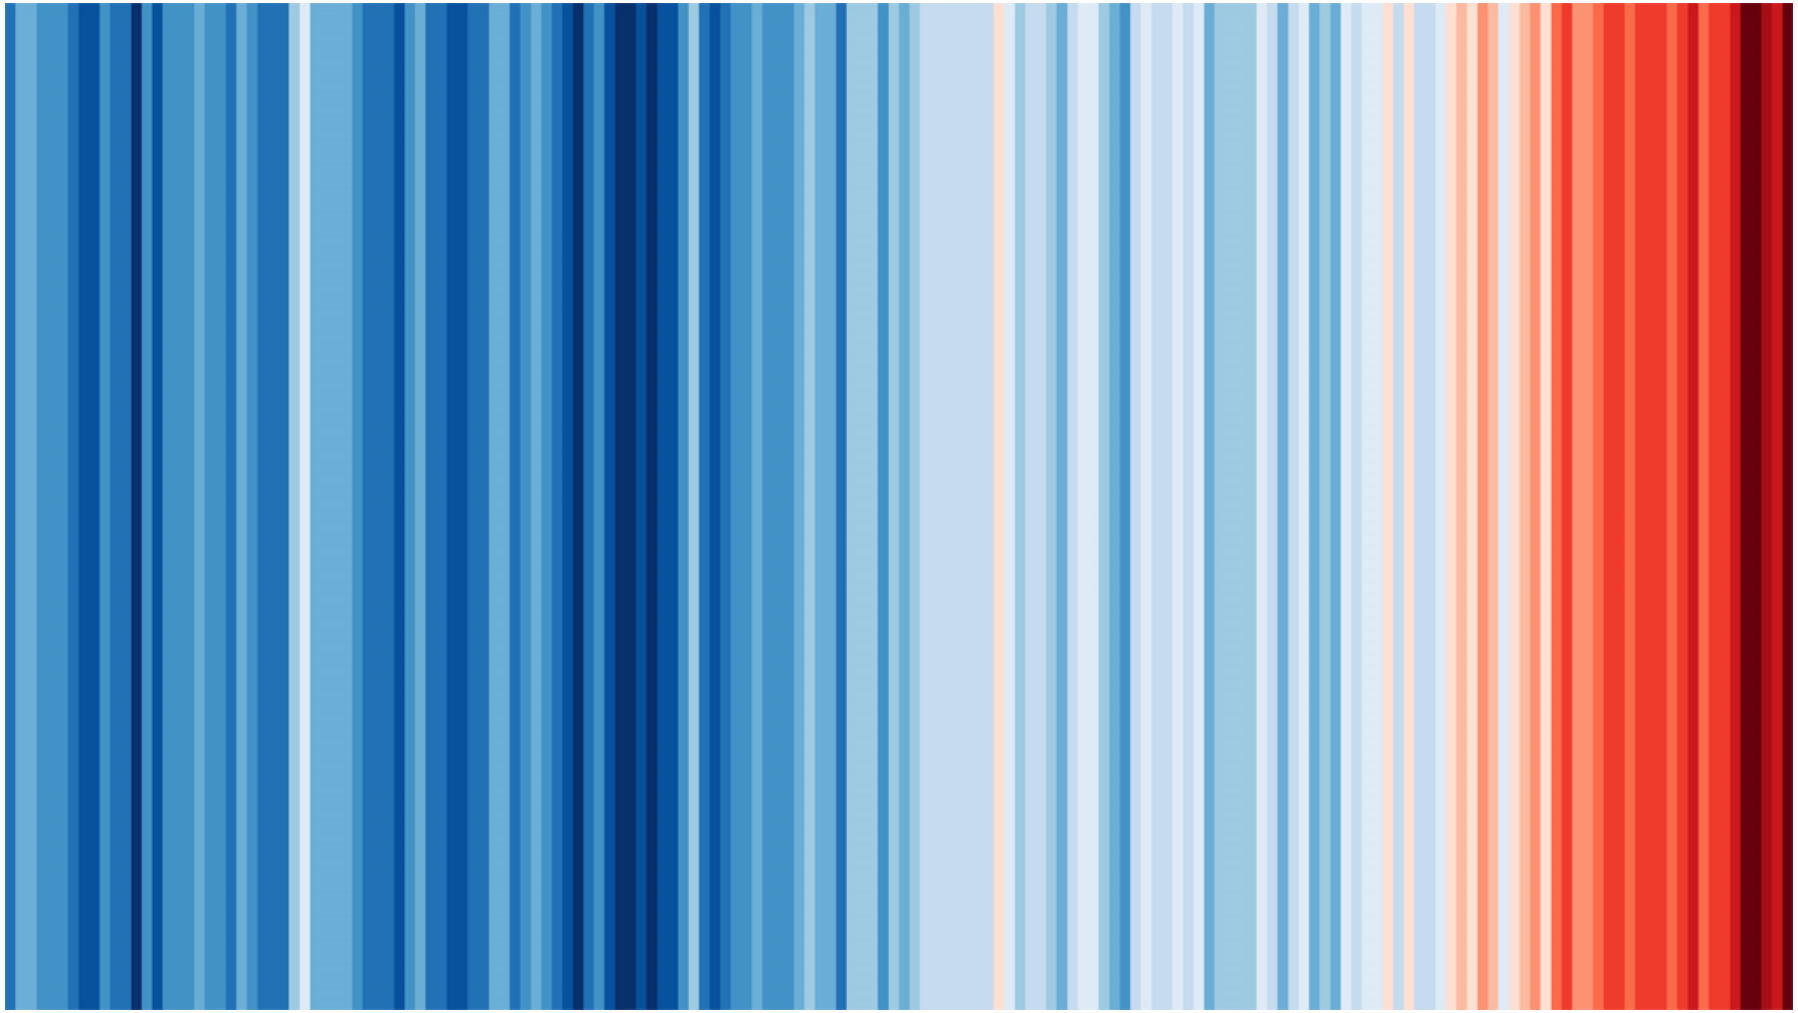

O que significam estas riscas?

https://showyourstripes.info/s

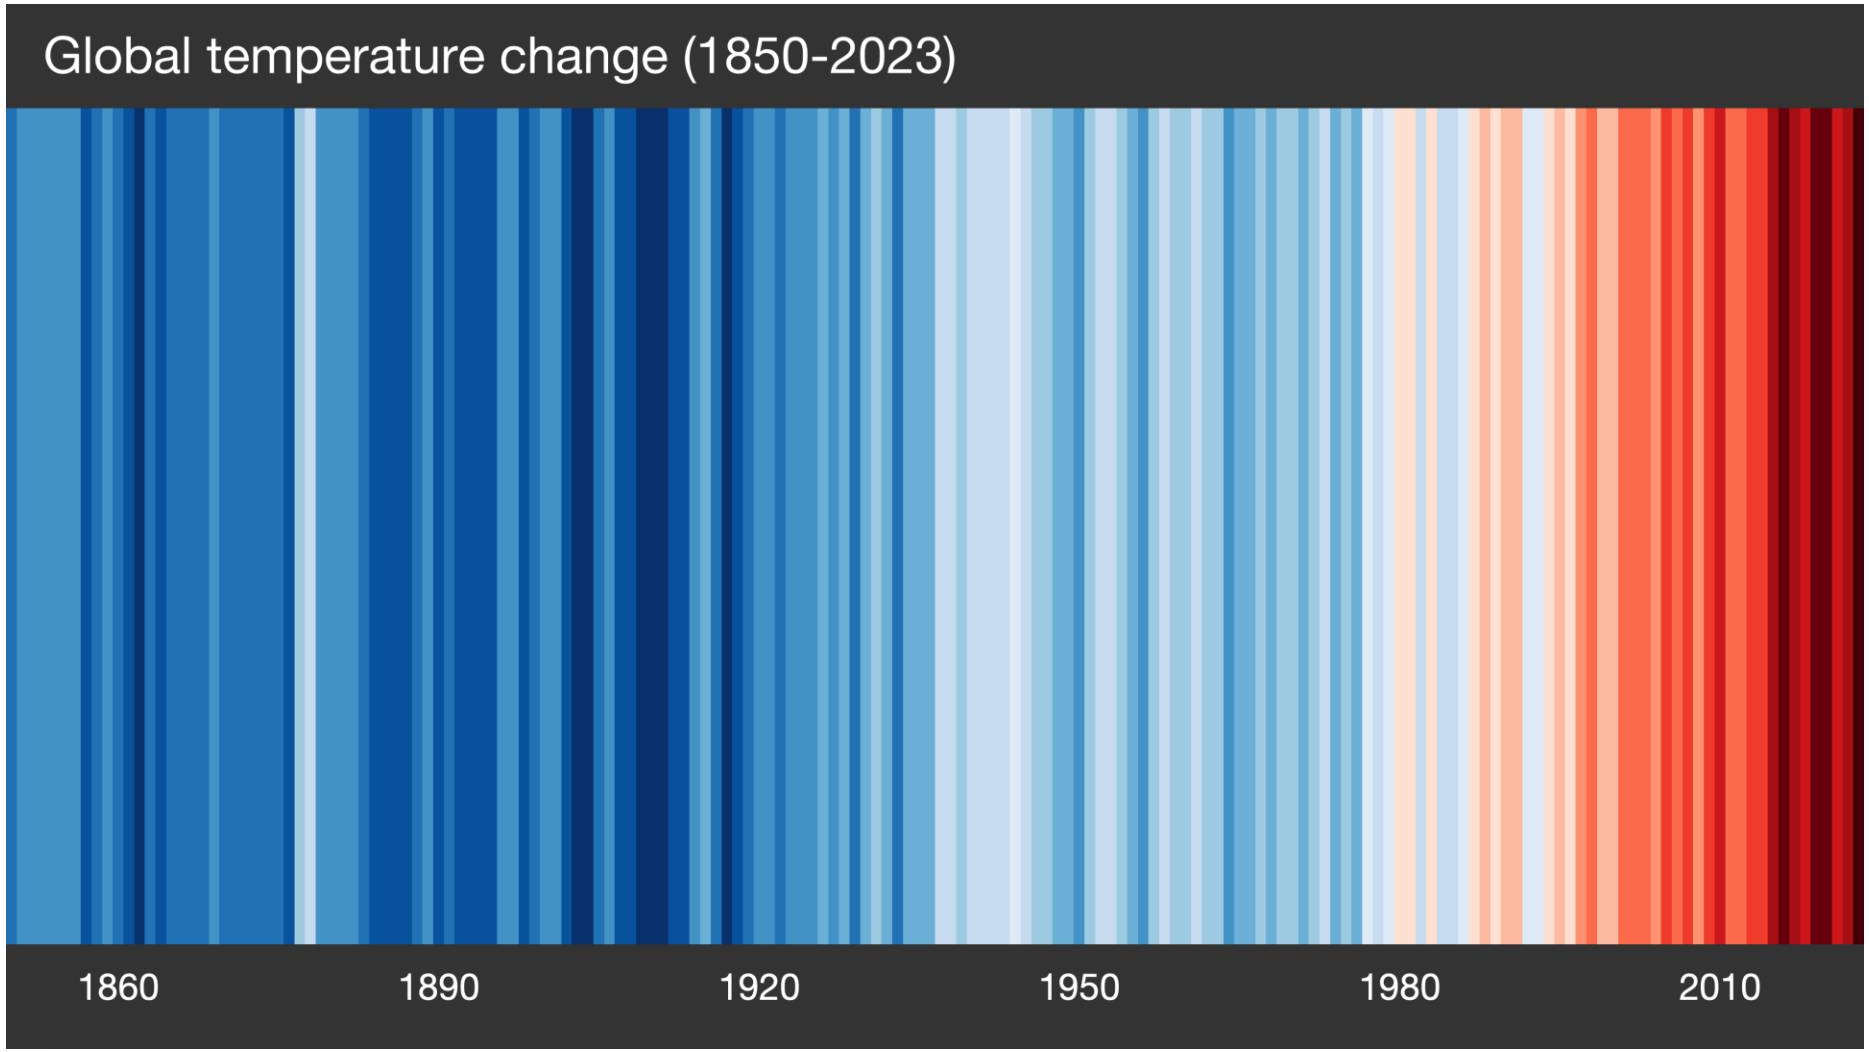

Dados não estruturados

Imagens:

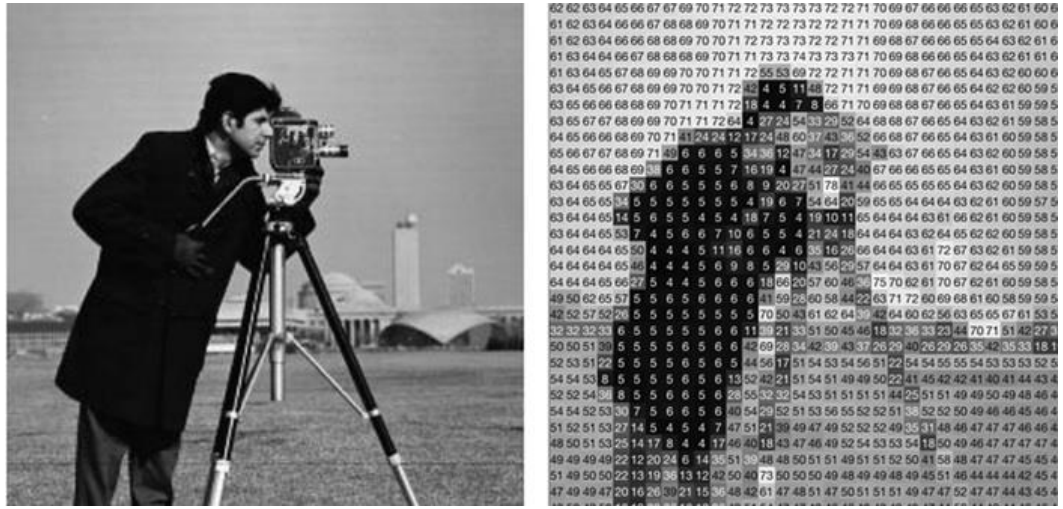

É necessário extrair a estrutura dos vários elementos de informação sobre os dados não estruturados

Textos:

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like "Huardest gefburn"? Kjift – not at all! A blind text like this gives you information about the selected font, how the letters are written and an impression of the look. This text should contain all letters of the alphabet and it should be written in of the original language. There is no need for special content, but the length of words should match the language.

24 horas de dados

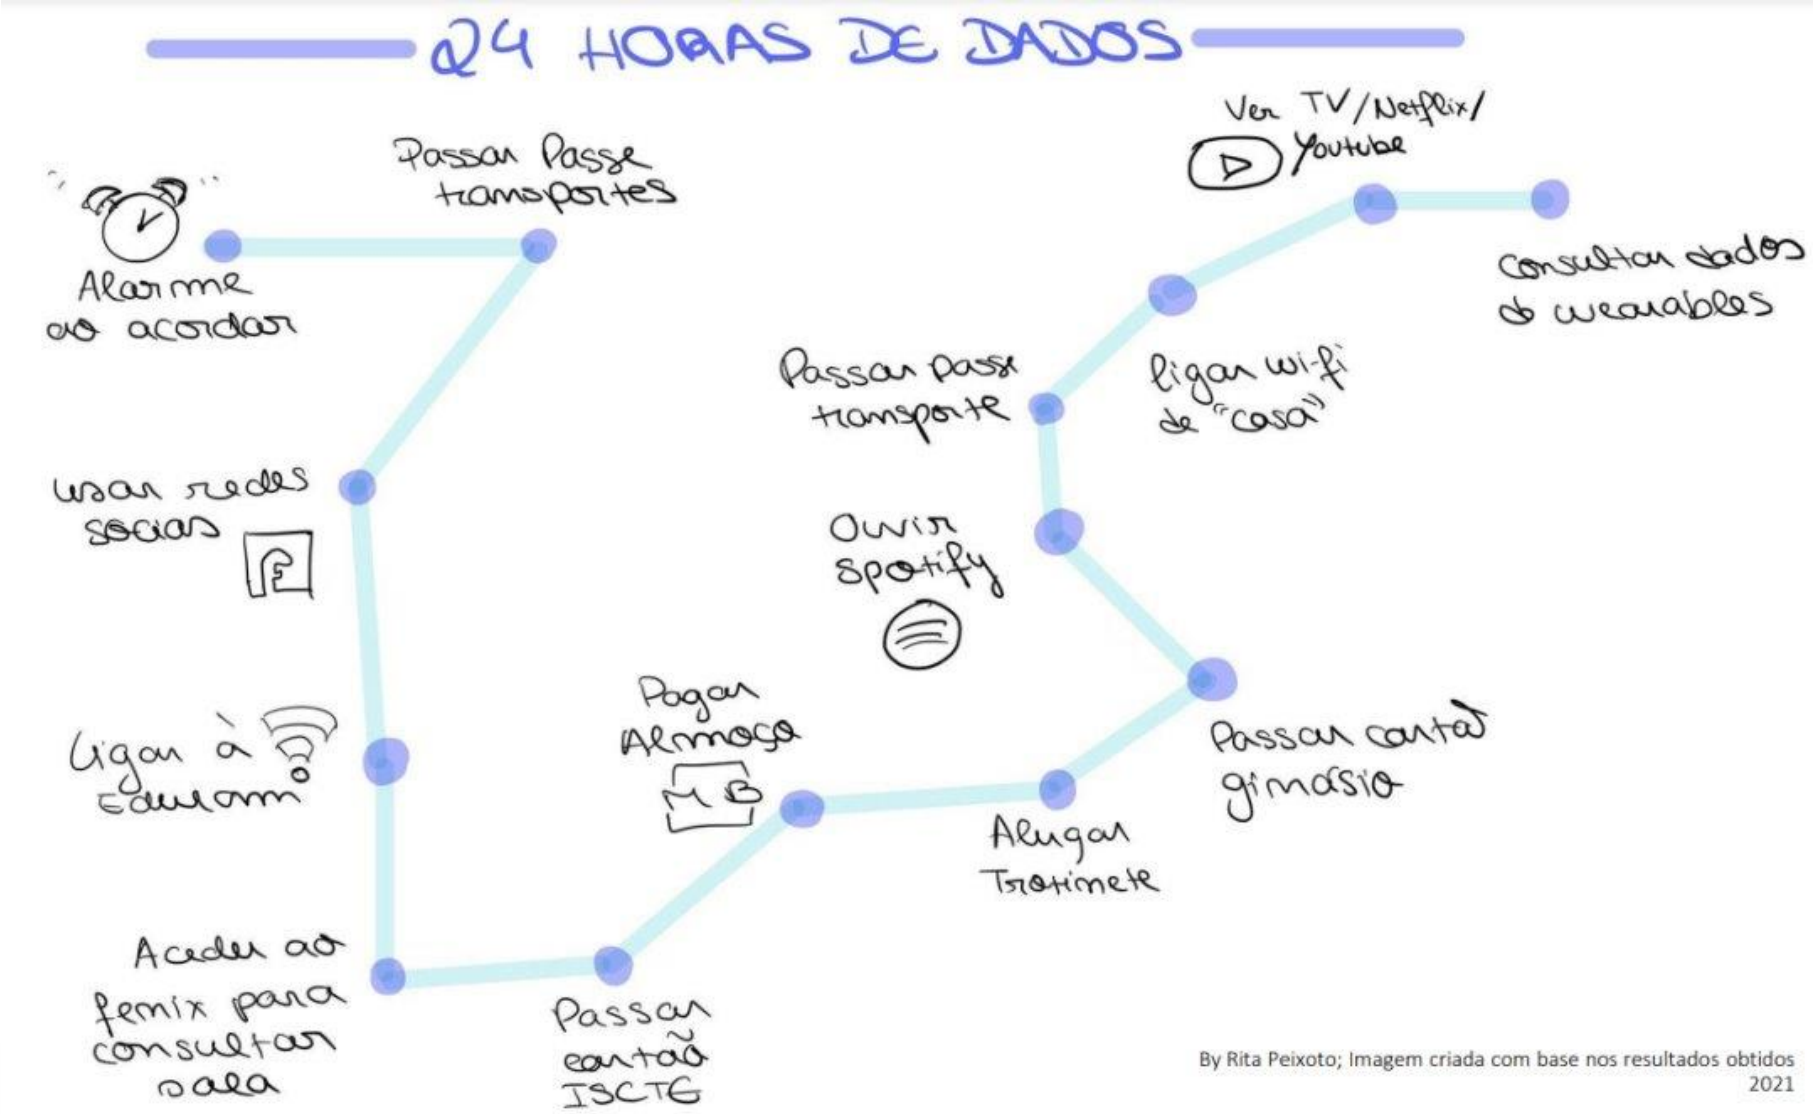

By Rita Peixoto; Imagem criada com base nos resultados obtidos 2021

#recap

- Ciência de dados é multidisciplinar e foca-se no planeamento, aquisição, análise e inferência a partir de dados.
- Dados são factos, quando contextualizados são informação, e o conhecimento obtêm-se aplicando a experiência de um determinado domínio à informação.
- Metadados fornecem contexto aos dados.
- Os dados podem ser estruturados (valores numéricos ou categóricos organizados em tabelas) ou não estruturados (imagens e textos).