INSTITUTO UNIVERSITÁRIO DE LISBOA

Introdução à Ciência de Dados

Aula 03

Ana Rita Peixoto

Martim Santos

Miguel Teodoro

2025/2026

Tarefas em CD

- Tarefas supervisionadas
- Tarefas não supervisionadas

Principais tarefas em CD

Aprendizagem

Cada dado possui um rótulo (label) a indicar que tipo de exemplo é

Supervisionadas
- Prever/Predizer

Classificação
Variáveis categóricas

Regressão
Variáveis quantitativas

Não Supervisionadas
- Descrever

Clustering

Associar

Sequenciar

Aprendizagem supervisionada

- Objetivo: construir (aprender) um modelo capaz de prever/predizer uma classe/categoria/acontecimento/valor com base em evidências passadas e na presença de incerteza

- Um algoritmo de aprendizagem supervisionada usa (aprende com) um conjunto de dados conhecidos rotulados e treina um modelo preditivo para gerar previsões razoáveis quando em presença de novas (desconhecidas) observações/exemplos

Aprendizagem supervisionada

Passo 1: Obter conjunto de treino

Passo 2: Fornecer dados **novos** para que o algoritmo estime um resultado.

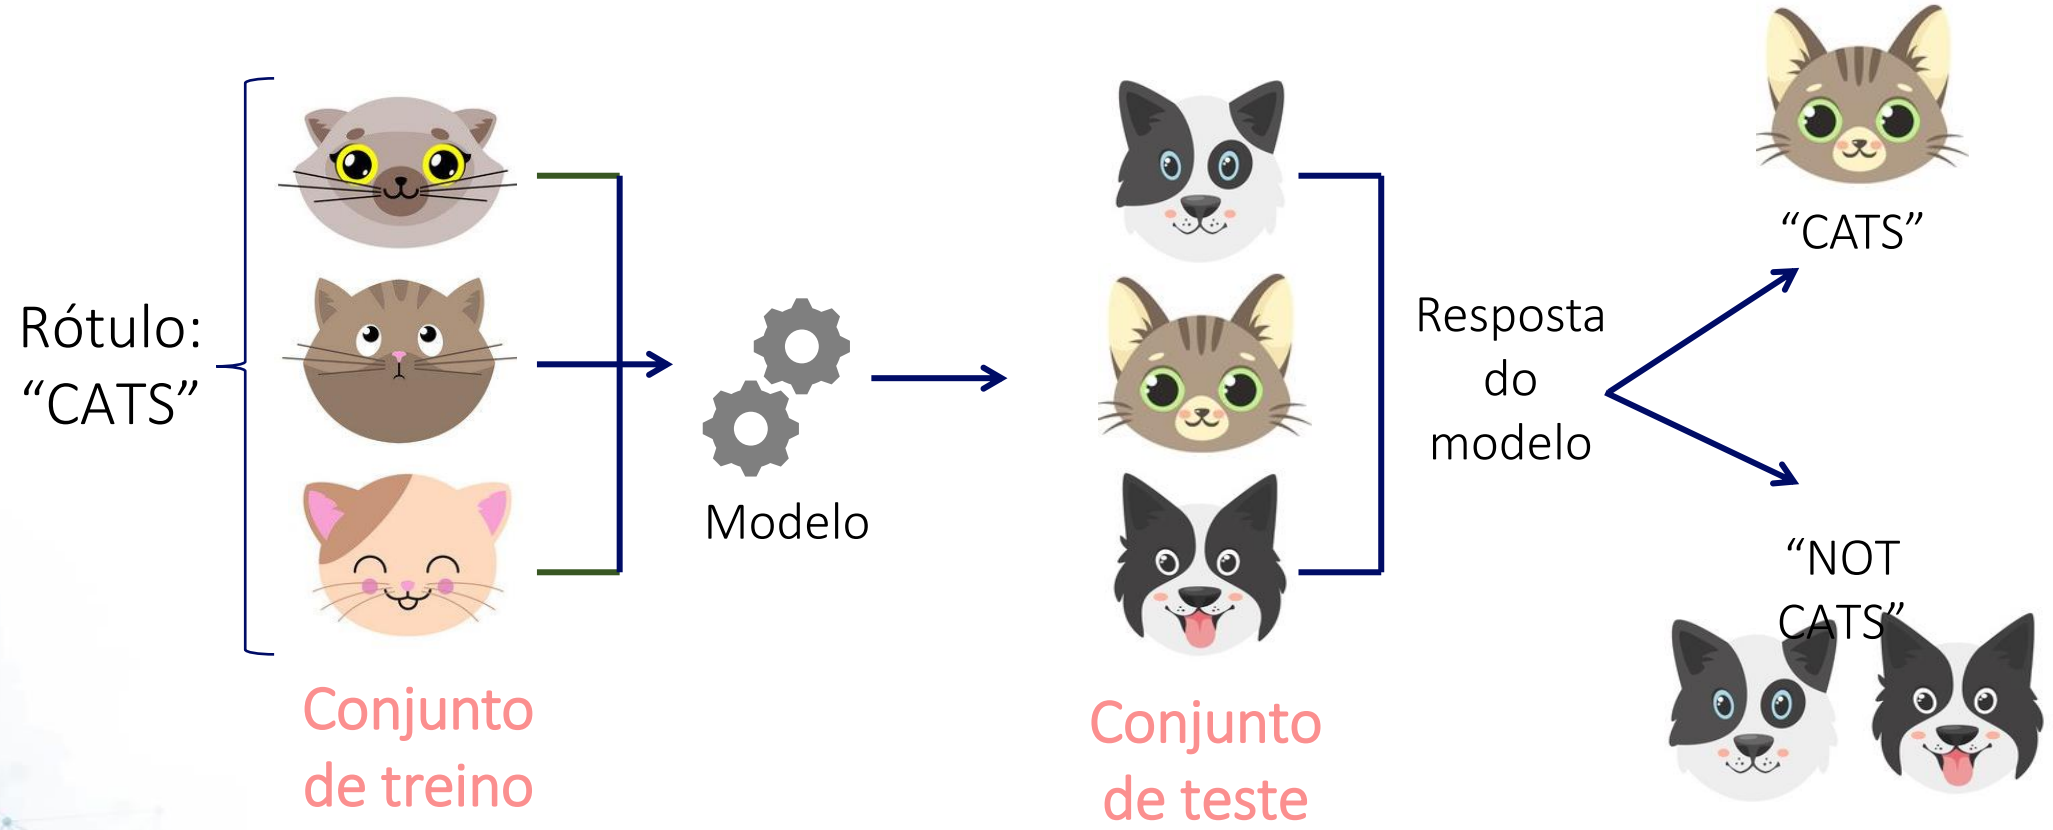

Aprendizagem supervisionada

CAT

CAT

NOT CAT

Dados rotulados/anotados (com label) Que representam uma relação

Conjunto de Treino

↓

Algoritmo

Técnica para a construção do modelo

↓

x: nova observação → Modelo → y: resultado estimado NOT CAT

Modelo: aproximação para uma função/relação/associação $f(x)$

Aprendizagem supervisionada: exemplos

Classificação

Quando a variável alvo é categórica:

Ex: identificação de animais através de imagens

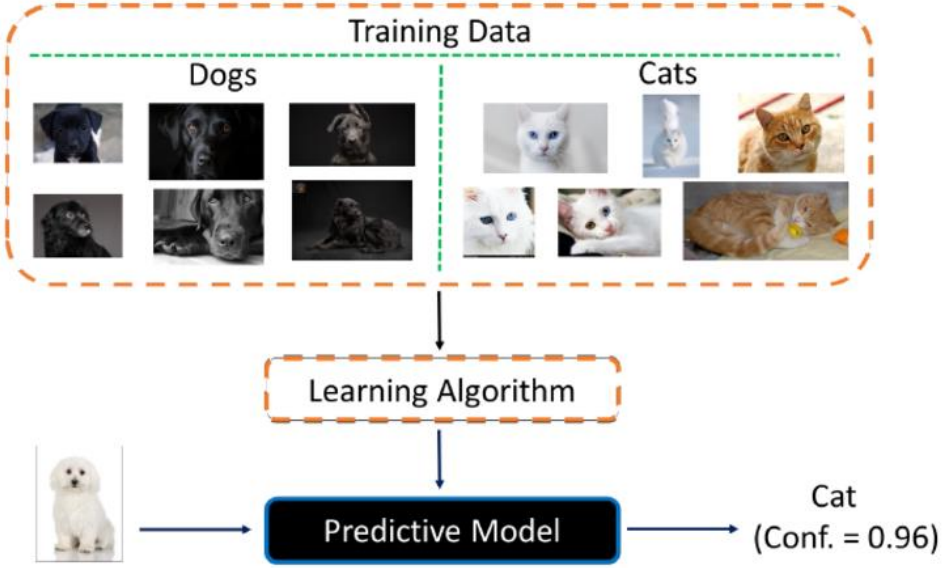

Ex: identificação se emails são spam ou não

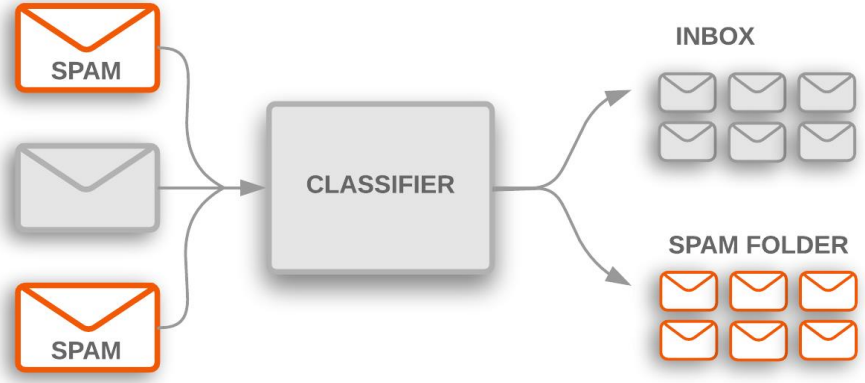

Aprendizagem supervisionada: exemplos

Regressão

Quando a variável alvo é quantitativa:

Ex: previsão do retorno (vendas) face ao valor investido, por meio de comunicação

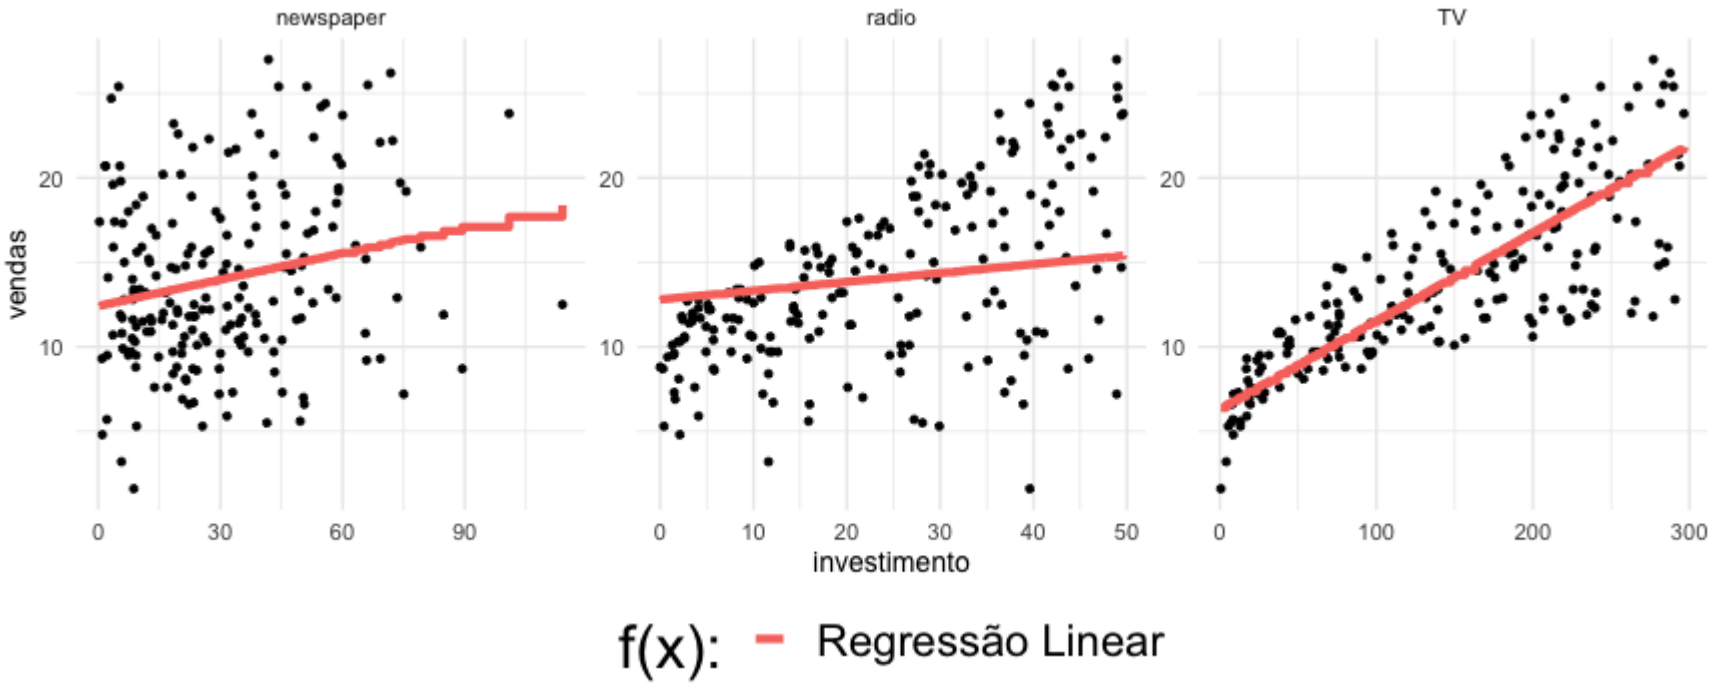

Aprendizagem não supervisionada

- Aprendizagem não supervisionada serve para encontrar padrões (estruturas, ligações) intrínsecas em dados (não classificados/rotulados/anotados).
- Estes padrões permitem explicar comportamentos e podem ser utilizados para fazer inferência.

Tipos de problema:

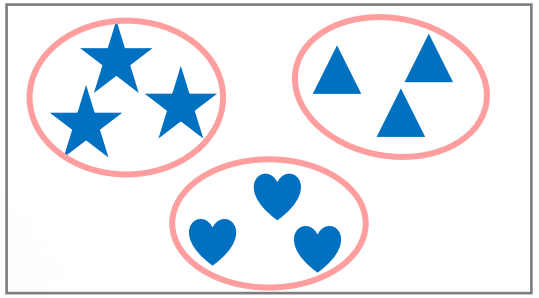

Clustering:
Identificar grupos semelhantes

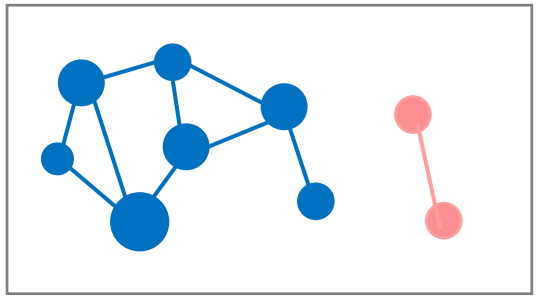

Anomaly Detection:
Identificar anomalias

Aprendizagem não supervisionada: exemplos

FIGURE 1

Clustering in market segmentation

Cluster 1: High income/high property value

Cluster 2: Middle income/middle property value

Cluster 3: High income/low property value

FIGURE 2

Clustering in fraud detection

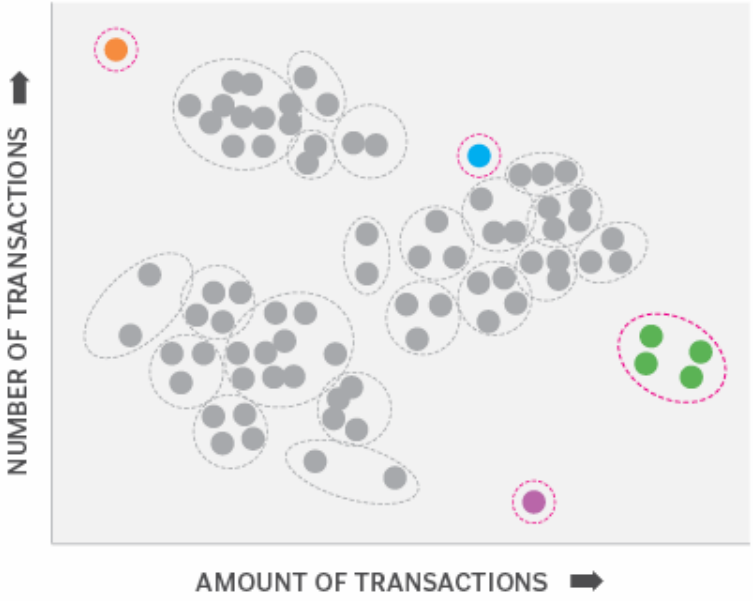

Outlying points that could be scrutinized for fraud

source: https://www.techtarget.com/searchenterpriseai/definition/clustering-in-machine-learning

Aprendizagem automática

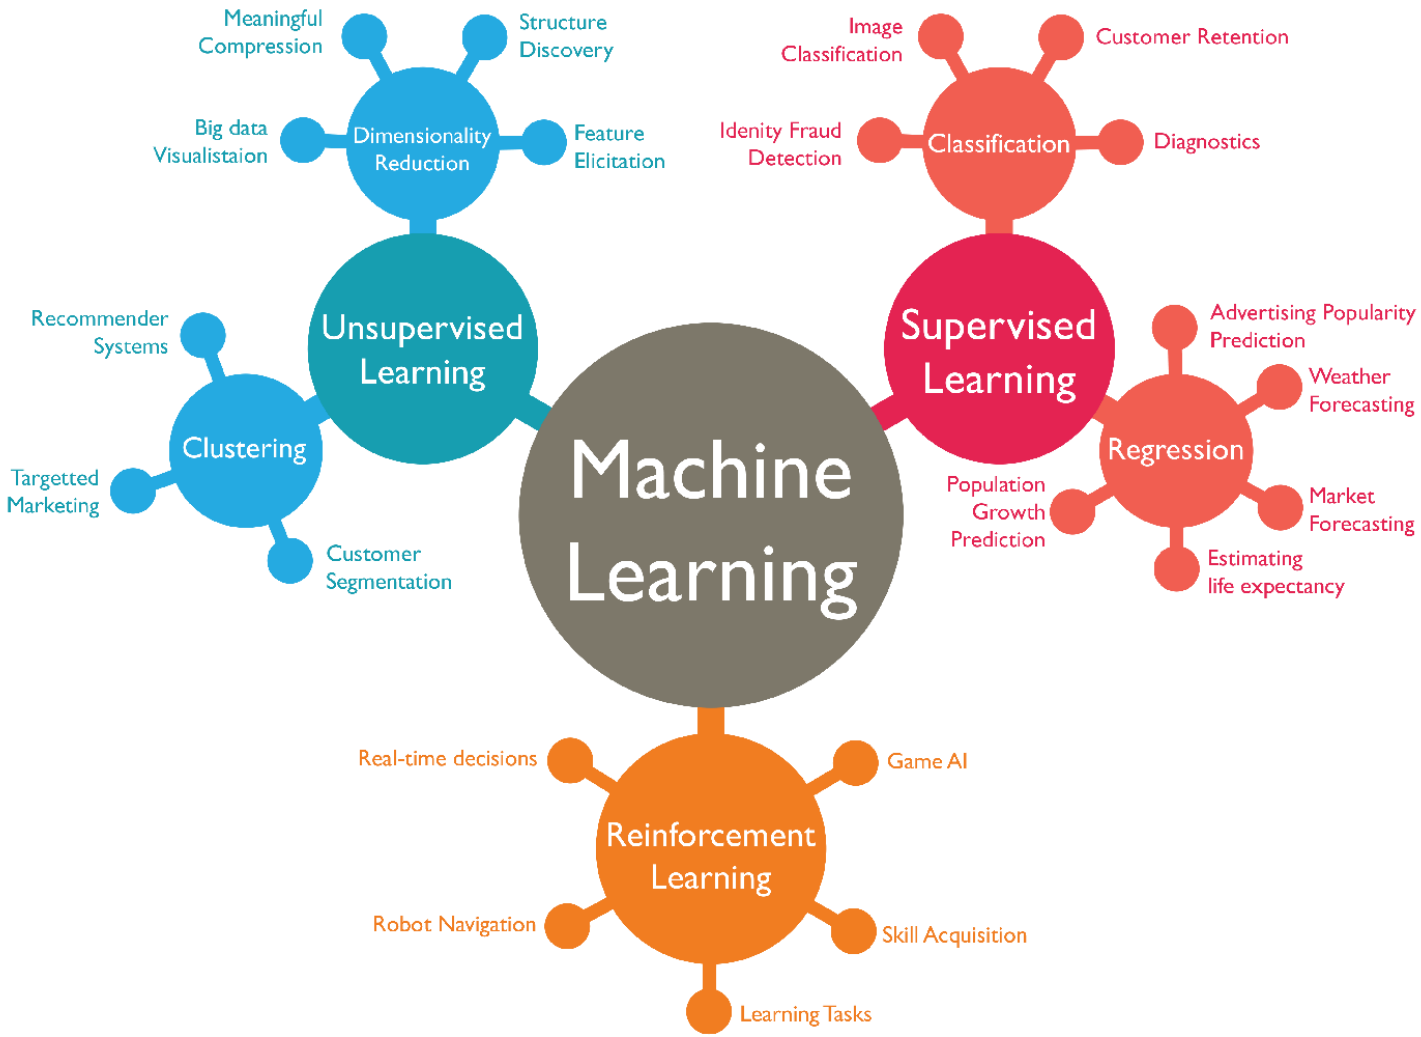

Exemplos

Considere as seguintes perguntas que podemos fazer sobre uma população de clientes.

1. Os nossos clientes caem naturalmente em grupos diferentes?
2. Podemos encontrar grupos de clientes que têm uma probabilidade particularmente elevada de cancelar o seu serviço quando a expiração dos seus contratos?
3. Será que este cliente comprará o serviço S1 se lhe for dado o incentivo A?
4. Que pacote de serviços (S1, S2, ou nenhum) um cliente poderá adquirir se lhe for dado o incentivo A?
5. Quanto será o uso de determinado cliente?

Indique justificando o tipo de problema e de aprendizagem.

Ciclo de Dados

- Metodologia CRISP-DM
- Exemplo de aplicação

Benefícios da introdução de CD nas empresas

DDD -> data-driven decisions

As DDD podem ser tomadas com base em resultados obtidos de uma forma automática.

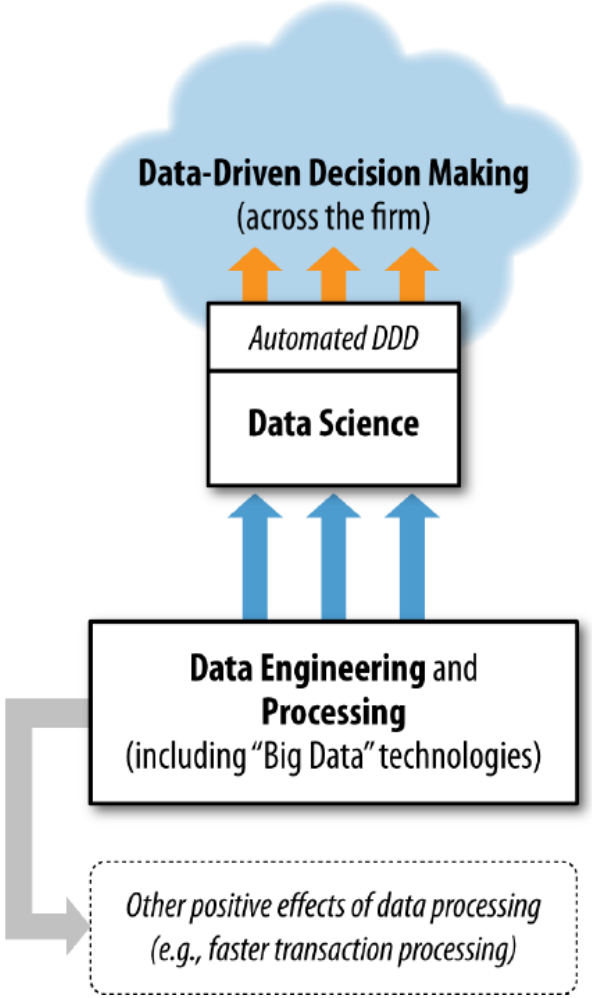

Decisão guiada por dados

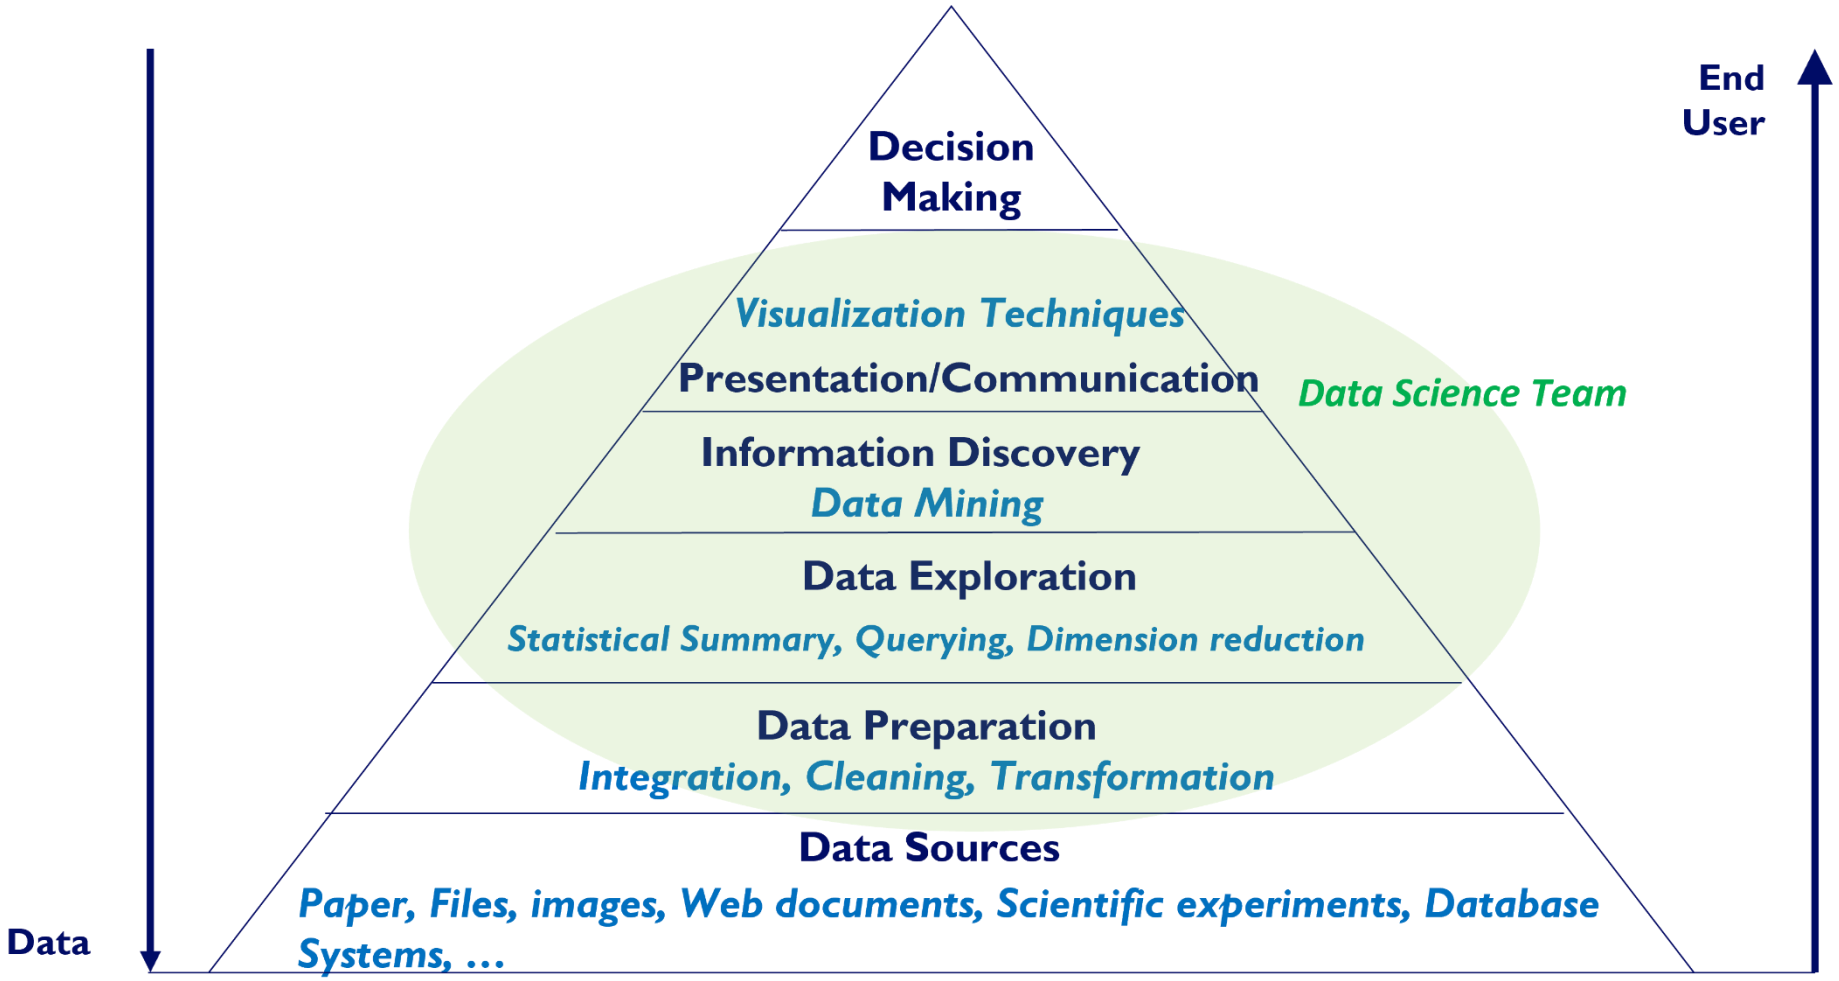

Adaptado de ©2012 Han, Kamber and Pei

Como desenvolver um processo de ciência de dados?

Os dados são valiosos, mas os dados também "podem dizer" o que quisermos!
E podem também sofrer de bias, desigualdades, …

É necessário um modelo faseado para guiar a construção de uma decisão baseada em dados (data-driven)

- Na prática, procura-se um sistema ou "solução" analítica baseada numa análise cuidada e sistémica, passível de ser avaliada ou replicada mais tarde.
- O raciocínio bem estruturado realça o valor e a verdade dos dados, providenciando o necessário apoio à tomada de decisão.
- É realçado o aspeto humano para a extração de conhecimento em dados.

Ciclo de dados!

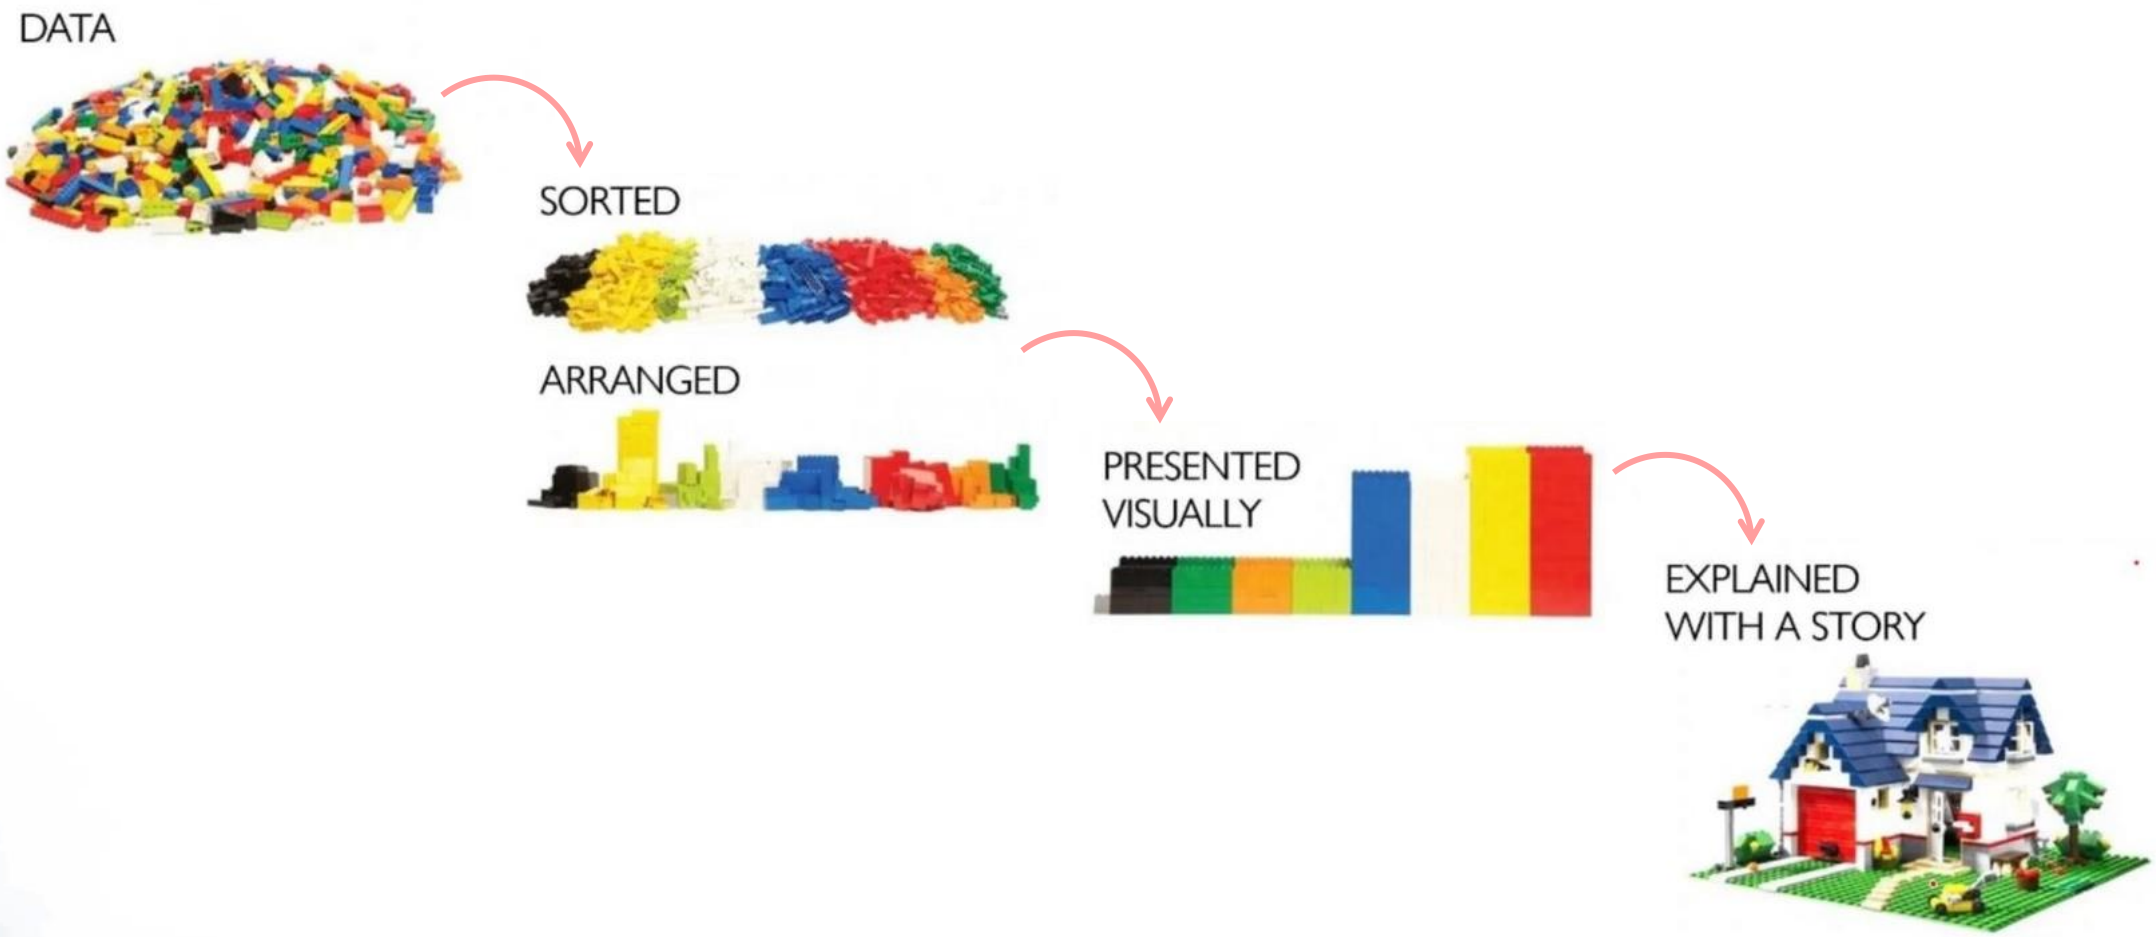

Cross Industry Standard Process for Data Mining
CRISP-DM

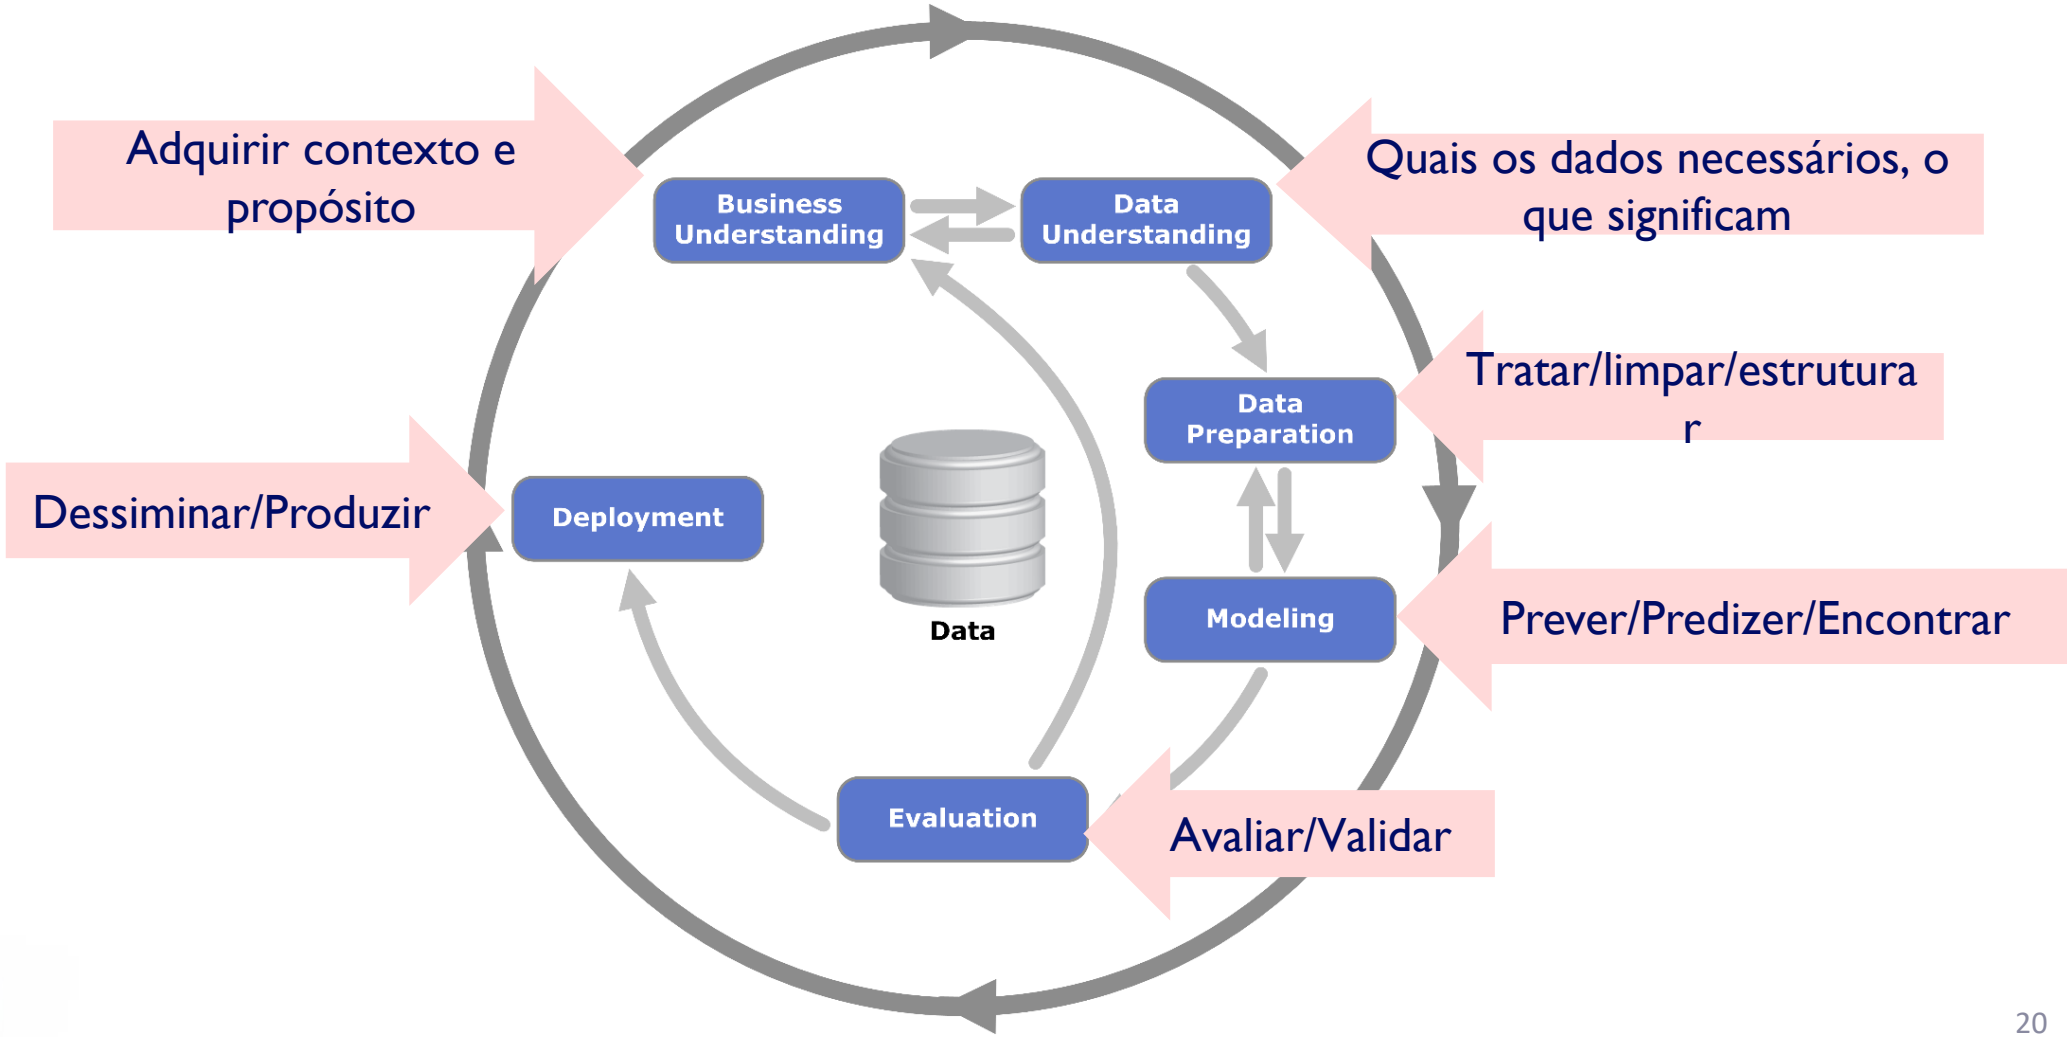

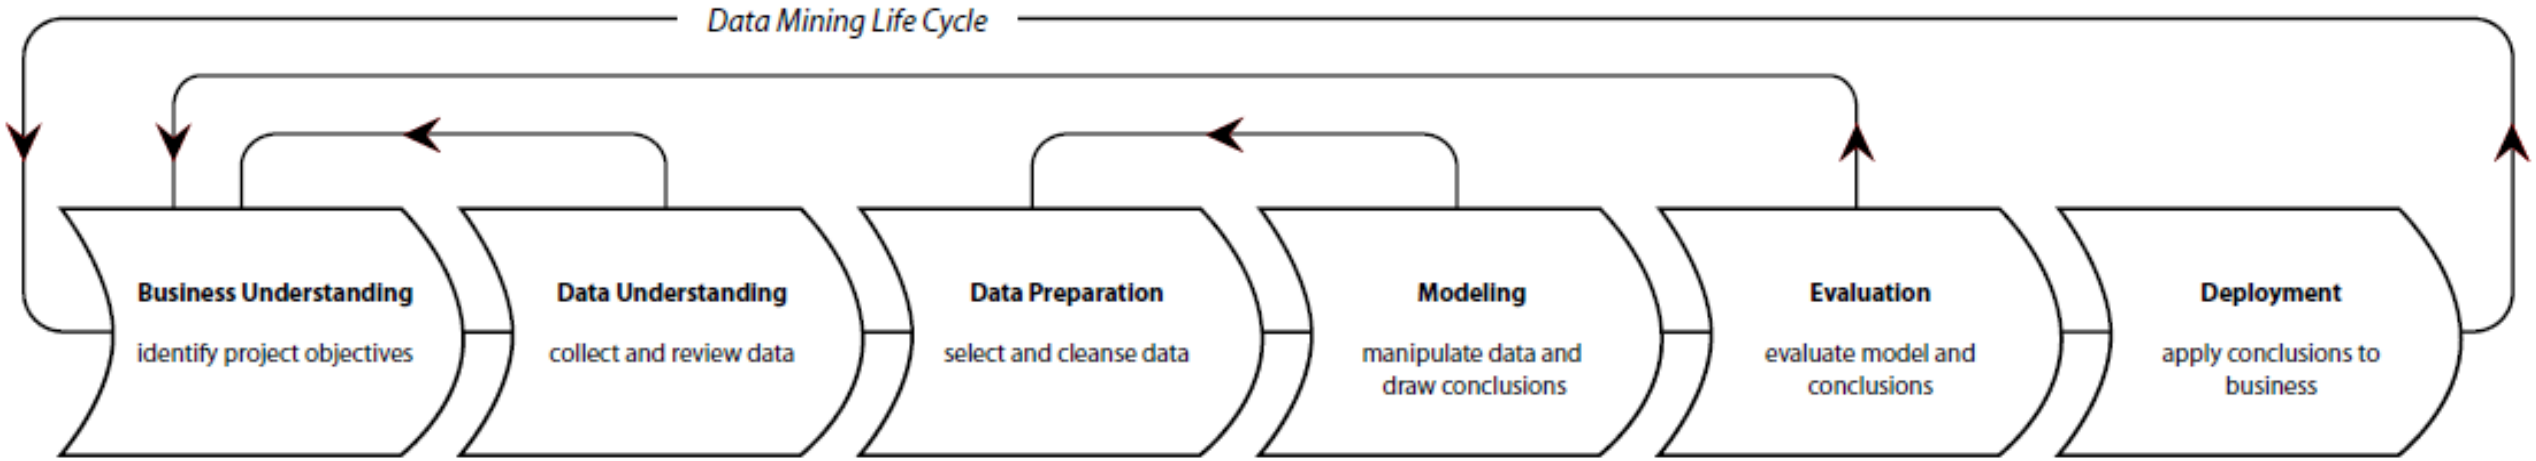

Determine Business Objectives
Background
Business Objectives
Business Success Criteria
(Log and Report Process)

Assess Situation
Inventory of Resources, Requirements, Assumptions, and Constraints
Risks and Contingencies
Terminology
Costs and Benefits
(Log and Report Process)

Determine Data Mining Goals
Data Mining Goals
Data Mining Success Criteria
(Log and Report Process)

Produce Project Plan
Project Plan
Initial Assessment of Tools and Techniques
(Log and Report Process)

Collect Initial Data
Initial Data Collection Report
(Log and Report Process)

Describe Data
Data Description Report
(Log and Report Process)

Explore Data
Data Exploration Report
(Log and Report Process)

Verify Data Quality
Data Quality Report
(Log and Report Process)

Data Set
Data Set Description
(Log and Report Process)

Select Data
Rationale for Inclusion/ Exclusion
(Log and Report Process)

Clean Data
Data Cleaning Report
(Log and Report Process)

Construct Data
Derived Attributes
Generated Records
(Log and Report Process)

Integrate Data
Merged Data
(Log and Report Process)

Format Data
Reformatted Data
(Log and Report Process)

Select Modeling Technique
Modeling Technique
Modeling Assumptions
(Log and Report Process)

Generate Test Design
Test Design
(Log and Report Process)

Build Model Parameter Settings
Models
Model Description
(Log and Report Process)

Assess Model
Model Assessment
Revised Parameter
(Log and Report Process)

Evaluate Results
Align Assessment of Data Mining Results with Business Success Criteria
(Log and Report Process)

Approved Models
Review Process
Review of Process
(Log and Report Process)

Determine Next Steps
List of Possible Actions
Decision
(Log and Report Process)

Plan Deployment
Deployment Plan
(Log and Report Process)

Plan Monitoring and Maintenance
Monitoring and Maintenance Plan
(Log and Report Process)

Produce Final Report
Final Report
Final Presentation
(Log and Report Process)

Review Project
Experience Documentation
(Log and Report Process)

a visual guide to CRISP-DM methodology

Business Understanding

Compreender os objetivos e os requisitos do projeto

- Nesta fase, é feito um "reconhecimento" do negócio e é definido o "problema" a resolver
- Uma compreensão clara das necessidades do negócio permite alcançar uma definição do problema de extração de dados
- Esta definição os critérios de avaliação do modelo e os objetivos finais do processo
- Os objetivos do processo podem ser vistos de duas perspetivas, nomeadamente o objetivo do processo de extração de dados e o objetivo de negócio

Business Understanding
identify project objectives

Determine Business Objectives
Background
Business Objectives Business
Success Criteria
(Log and Report Process)

Assess Situation
Inventory of Resources, Requirements, Assumptions, and Constraints
Risks and Contingencies
Terminology
Costs and Benefits
(Log and Report Process)

Determine Data Mining Goals
Data Mining Goals
Data Mining Success Criteria
(Log and Report Process)

Produce Project Plan
Project Plan
Initial Assessment of Tools and Techniques
(Log and Report Process)

Data Understanding

Alcançar um conhecimento profundo dos dados

- Adquirir, colecionar, obter: Listar os conjuntos de dados
- Descrever os dados: Volume, tipos de dados, perceber o significado e valor de cada atributo, sumariar cada atributo
- Explorar: Analisar propriedades de atributos interessantes, distribuições, análises estatísticas simples
- Aferir a qualidade dos dados: Atributos em falta, campos em branco ou informação inválida, verificação de erros ortográficos, duplicados, valores inconsistentes, …

Data Understanding
collect and review data

Collect Initial Data
Initial Data Collection Report
(Log and Report Process)

Describe Data
Data Description Report
(Log and Report Process)

Explore Data
Data Exploration Report
(Log and Report Process)

Verify Data Quality
Data Quality Report
(Log and Report Process)

Data Preparation

Seleção e preparação de dados, que resulta no conjunto de dados final para ser utilizado para treinar e testar modelos

- Selecionar
- Limpar e/ou corrigir
- Adquirir novos dados
- Ajustar, codificar (ex: features encoding, feature scaling)
- Integrar
- Construir/agregar (ex: feature engineering)
- (re)formatar

Data Preparation
select and cleanse data

Data Set
Data Set Description
(Log and Report Process)

Select Data
Rationale for Inclusion/Exclusion
(Log and Report Process)

Clean Data
Data Cleaning Report
(Log and Report Process)

Construct Data
Derived Attributes Generated Records
(Log and Report Process)

Integrate Data
Merged Data
(Log and Report Process)

Format Data
Reformatted Data
(Log and Report Process)

Modeling

Construção de um modelo que representa o conhecimento existente, através de ferramentas de machine learning

- Seleção dos algoritmos a utilizar
- Desenvolvimento de cenários de treino/aprendizagem e de teste (incluindo a partição do conjunto de dados de base)
- Criação do modelo
- Avaliação do modelo

Modelling
Manipulate data and draw conclusions

Select Modeling Technique
Modelling Technique
Modeling Assumptions
(Log and Report Process)

Generate Test Design
Test design
(Log and Report Process)

Build Model Parameter Settings
Models
Model Description
(Log and Report Process)

Assess Model
Model Assessment
Revised Parameter
(Log and Report Process)

Evaluation

Avaliar o desempenho e a utilidade do modelo

- Avaliação dos resultados da modelização, o que implica compreender os resultados do processo de extração de dados e a sua relação com os objetivos definidos
- Alinhamento com objetivos de extração de dados e o objetivo de negócio
- Descoberta de novos objetivos e/ou necessidades?
- Processo sem defeitos, fugas, características sub/sobrevalorizadas?

Evaluation
Evaluate model and conclusions

Evaluate Results
Align Assessment of Data Mining Results with Business Success Criteria
(Log and Report Process)

Approved models
Review Process
Review of Process
(Log and Report Process)

Determine Next Steps
List of Possible Actions
Decision
(Log and Report Process)

Deployment

Implementação da solução

- Definir como os resultados serão utilizados, por quem e com que frequência (implementação)
- A monitorização e a manutenção são cruciais para as soluções de extração de dados.
- Relatório: forma como os objetivos do processo de extração de dados foram atingidos ou as novas descobertas obtidas pelo processo

Deployment
Apply conclusions to business

Plan Deployment
Deployment Plan
(Log and Report Process)

Plan Monitoring and Maintenance
Monitoring and Maintenance Plan
(Log and Report Process)

Produce Final Report
Final Report
Final Presentation
(Log and Report Process)

Review Project
Experience Documentation
(Log and Report Process)

CRISP-DM

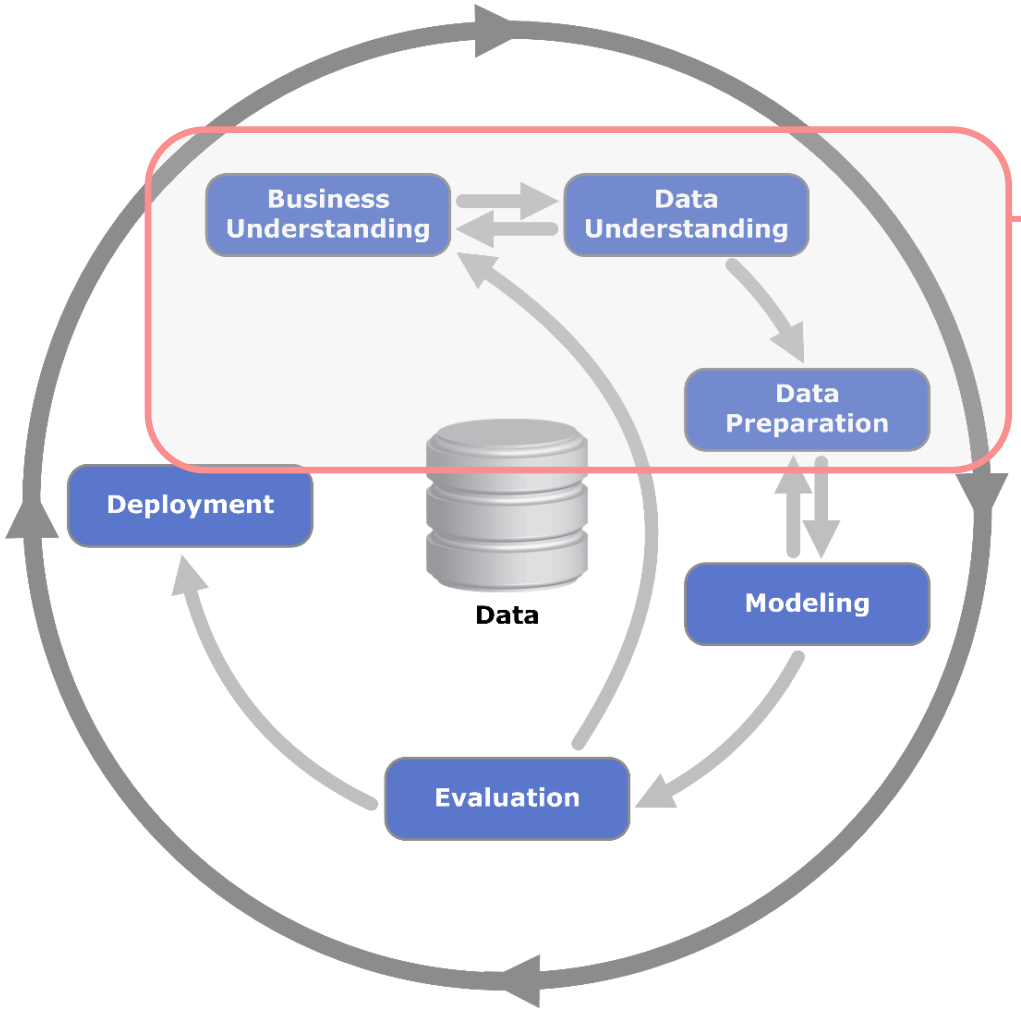

80% a 90% do tempo da ciência de dados é passada nestas fases iniciais

CRISP-DM

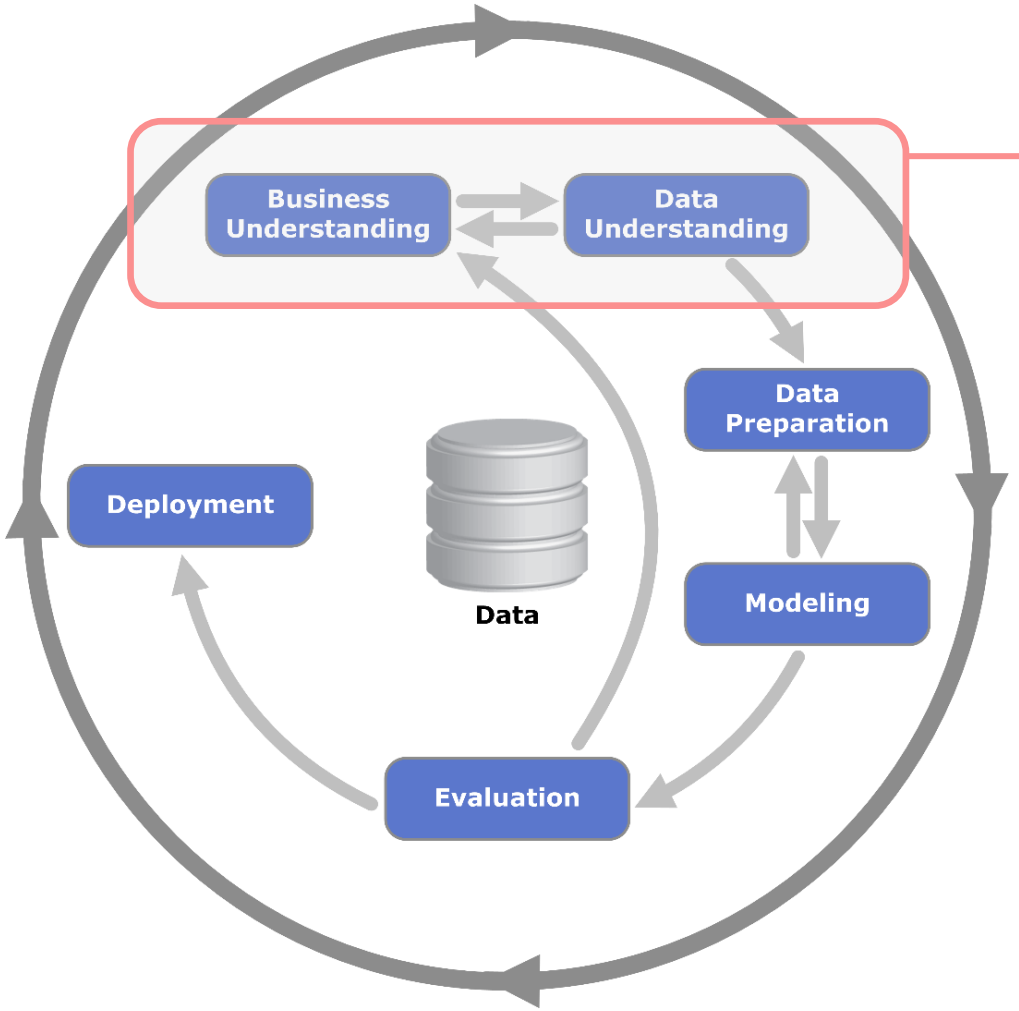

Neste *loop*, é analisado que dados são necessários para responder aos nossos propósitos

E vice-versa, se os dados possibilitam a resposta aos propósitos

CRISP-DM

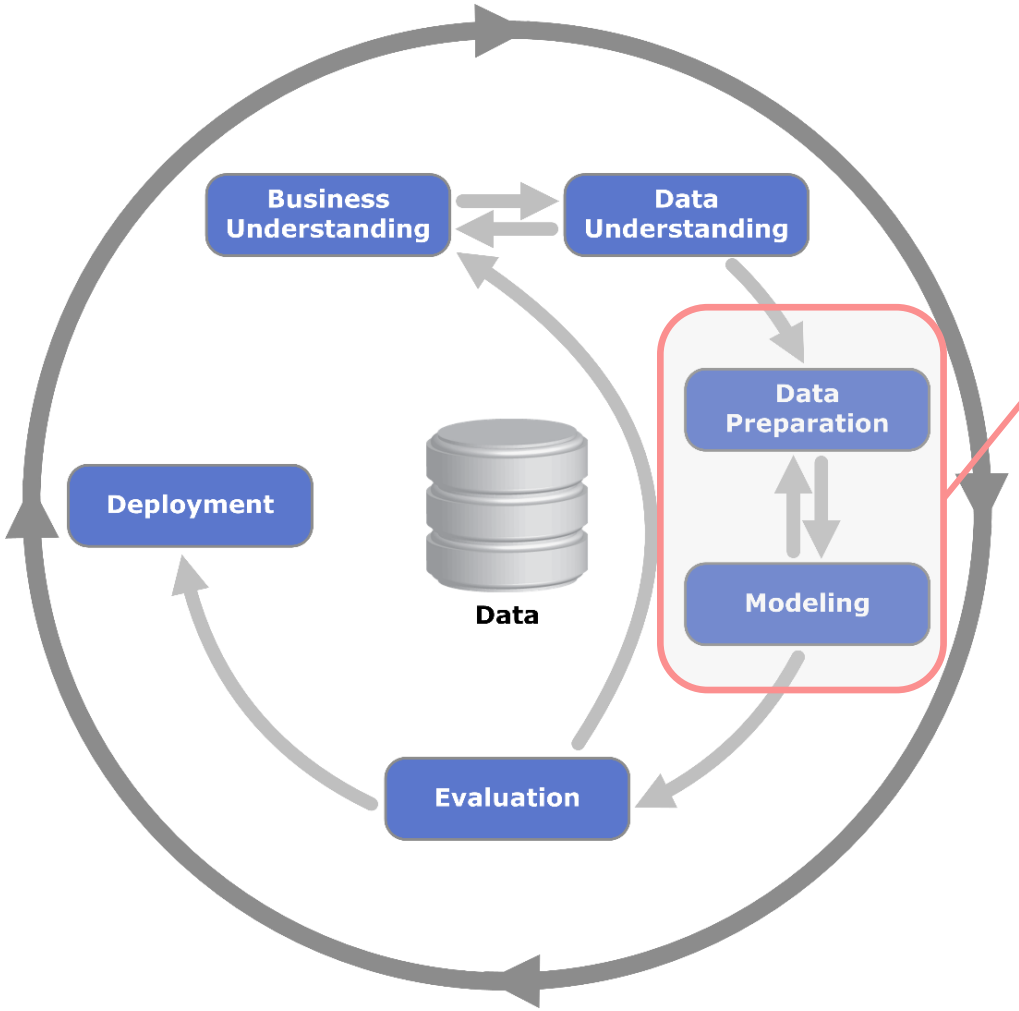

Neste loop, são preparados os dados para criar os modelos que irão responder aos nossos propósitos

E vice-versa, pois por vezes a preparação necessita de ser refeita de modo a melhorar os modelos criados

Previsão de Desempenho Académico de Estudantes numa Universidade

CRISP-DM aplicado

Uma universidade europeia quer implementar um sistema de previsão de desempenho académico para identificar estudantes em risco de reprovação ou abandono, com o objetivo de melhorar as taxas de sucesso e apoiar os alunos de forma proativa.

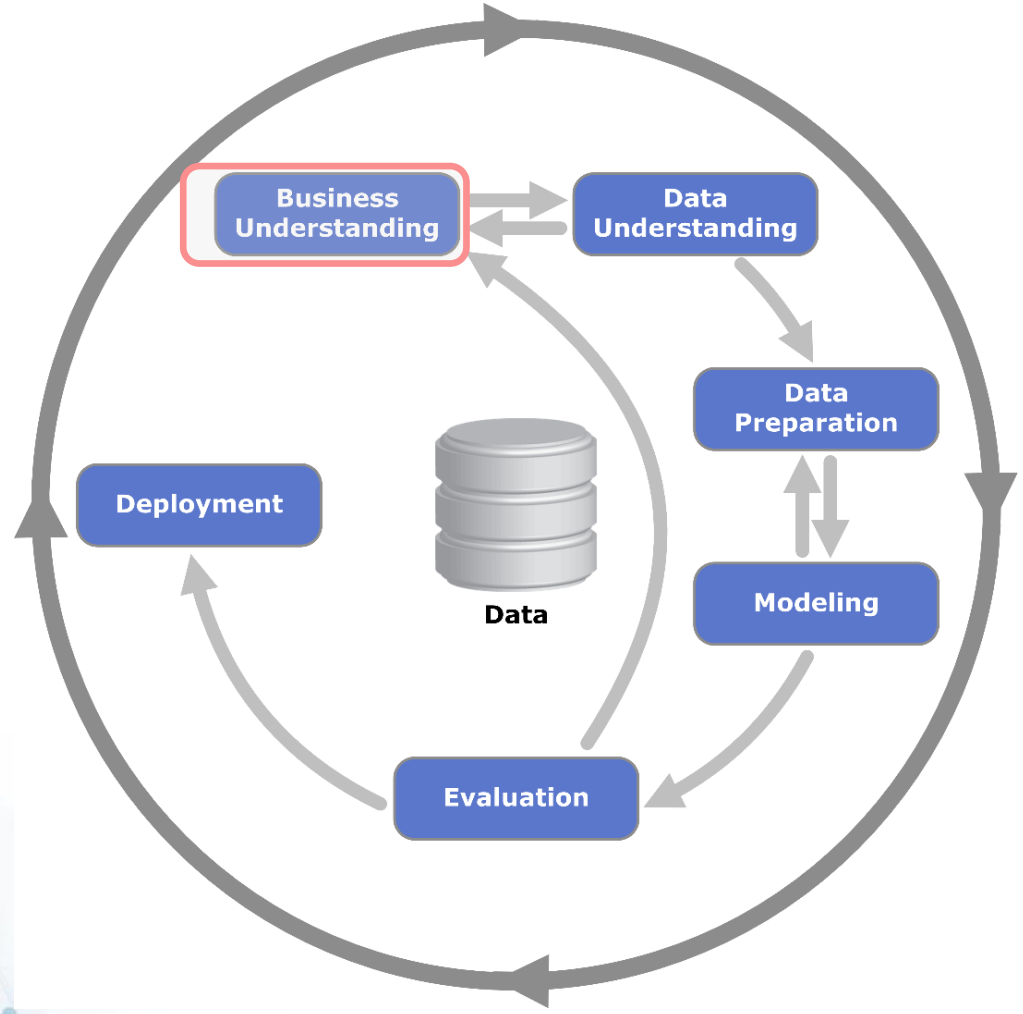

Business Understanding:

- **Definir Objetivos de Negócio**: O objetivo principal é compreender o que afeta a aprovação e o abandono escolar, para futuramente garantir que os estudantes recebem o suporte necessário.
- **Estabelecer Critérios de Sucesso:** Definir métricas como o aumento da taxa de aprovação, diminuição da taxa de abandono e número de estudantes que melhoraram o desempenho após intervenções.
- **Plano de Projeto:** Estabelecer cronogramas, equipas responsáveis e dados necessários. Definir um calendário para recolha de dados, desenvolvimento do modelo e implementação de ações baseadas nos resultados.

Previsão de Desempenho Académico de Estudantes numa Universidade

CRISP-DM aplicado

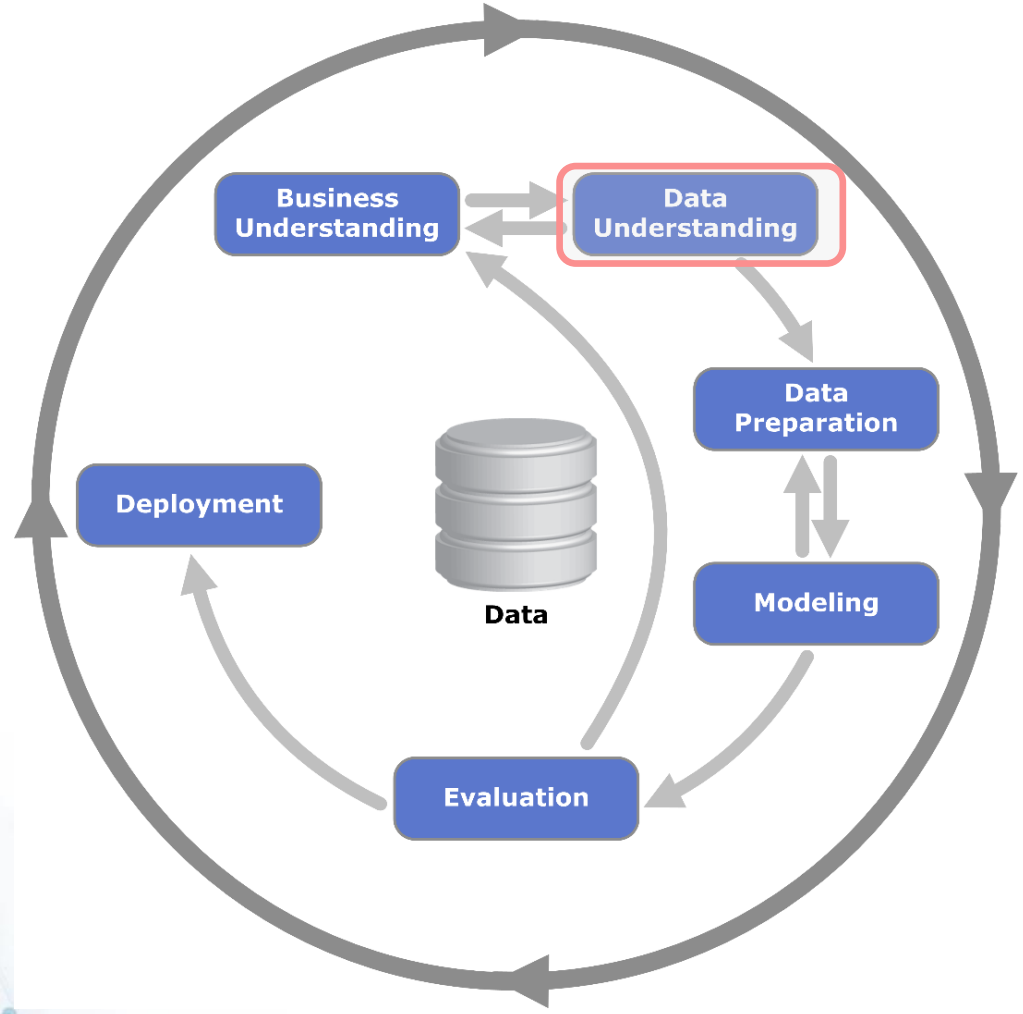

Data Understanding:

- **Recolha de Dados Iniciais**: Recolher dados como registos de matrícula, notas anteriores, frequência às aulas, participação em atividades extracurriculares, interações com a plataforma de e-learning, e dados socioeconómicos (caso permitido).
- **Descrição dos Dados**: Analisar a quantidade e os tipos de dados. Identificar variáveis importantes, como a média de notas, presenças e a utilização de recursos de apoio.
- **Exploração dos Dados**: Analisar correlações e padrões iniciais entre as variáveis, como por exemplo, a relação entre presença nas aulas e média de notas. Identificar comportamentos comuns nos alunos que têm um desempenho inferior.
- **Verificação da Qualidade dos Dados**: Detetar valores em falta, inconsistências, ou duplicados. Por exemplo, verificar se há notas em falta ou se a frequência às aulas foi registada corretamente.

Previsão de Desempenho Académico de Estudantes numa Universidade

CRISP-DM aplicado

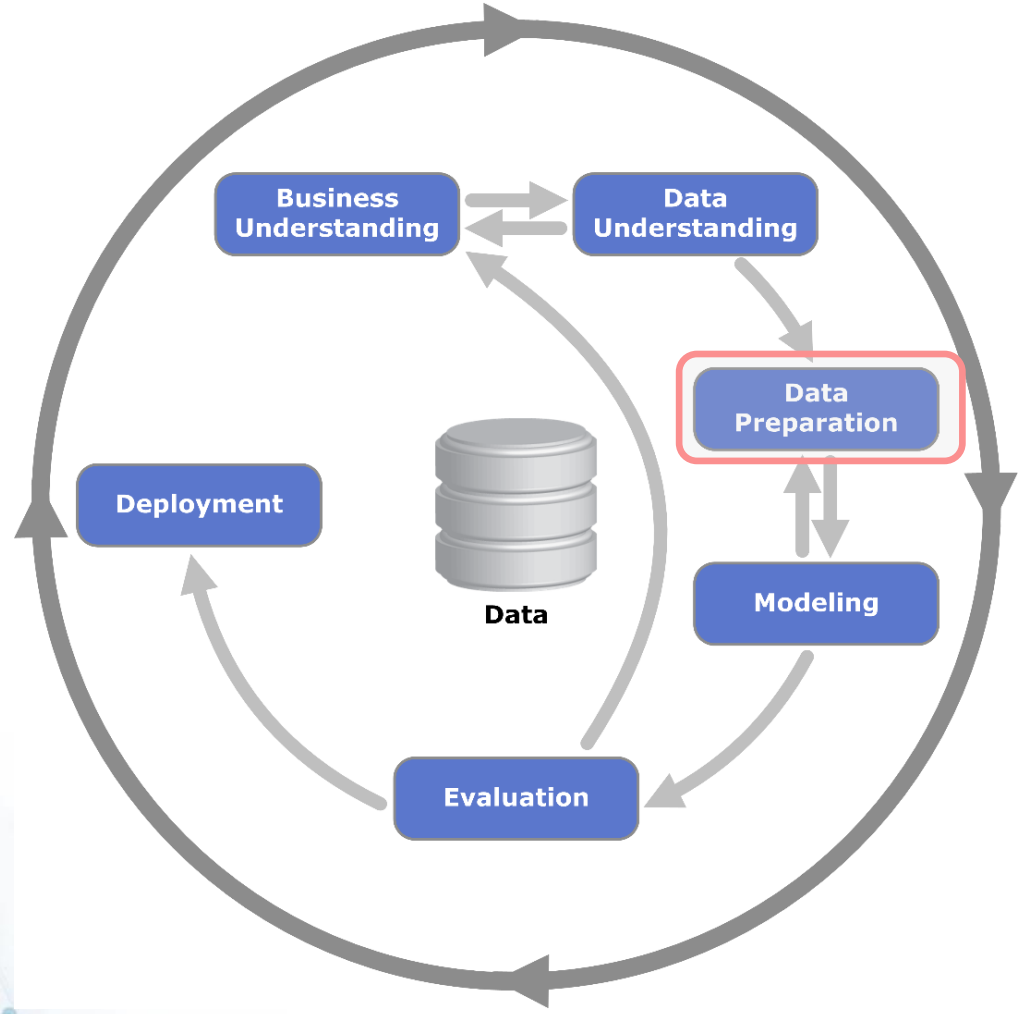

Data Preparation:

- **Limpeza dos Dados:** Preencher valores em falta (por exemplo, estimar a nota de uma disciplina com base nas outras), eliminar duplicados, e normalizar variáveis (como escalas de notas diferentes).
- **Engenharia de Variáveis:** Criar novas variáveis, como a "Média de Notas Semestral“ ou "Interações Semanais na Plataforma de E-learning". Estas variáveis podem fornecer um contexto adicional sobre o comportamento dos estudantes.
- **Transformação dos Dados:** Normalizar variáveis numéricas e codificar variáveis categóricas, como a área de estudo ou o tipo de apoio recebido.
- **Seleção de Variáveis:** Selecionar as variáveis que mais contribuem para a previsão, utilizando técnicas como análise de correlação, importância de variáveis em árvores de decisão ou redução de dimensionalidade.

Previsão de Desempenho Académico de Estudantes numa Universidade

CRISP-DM aplicado

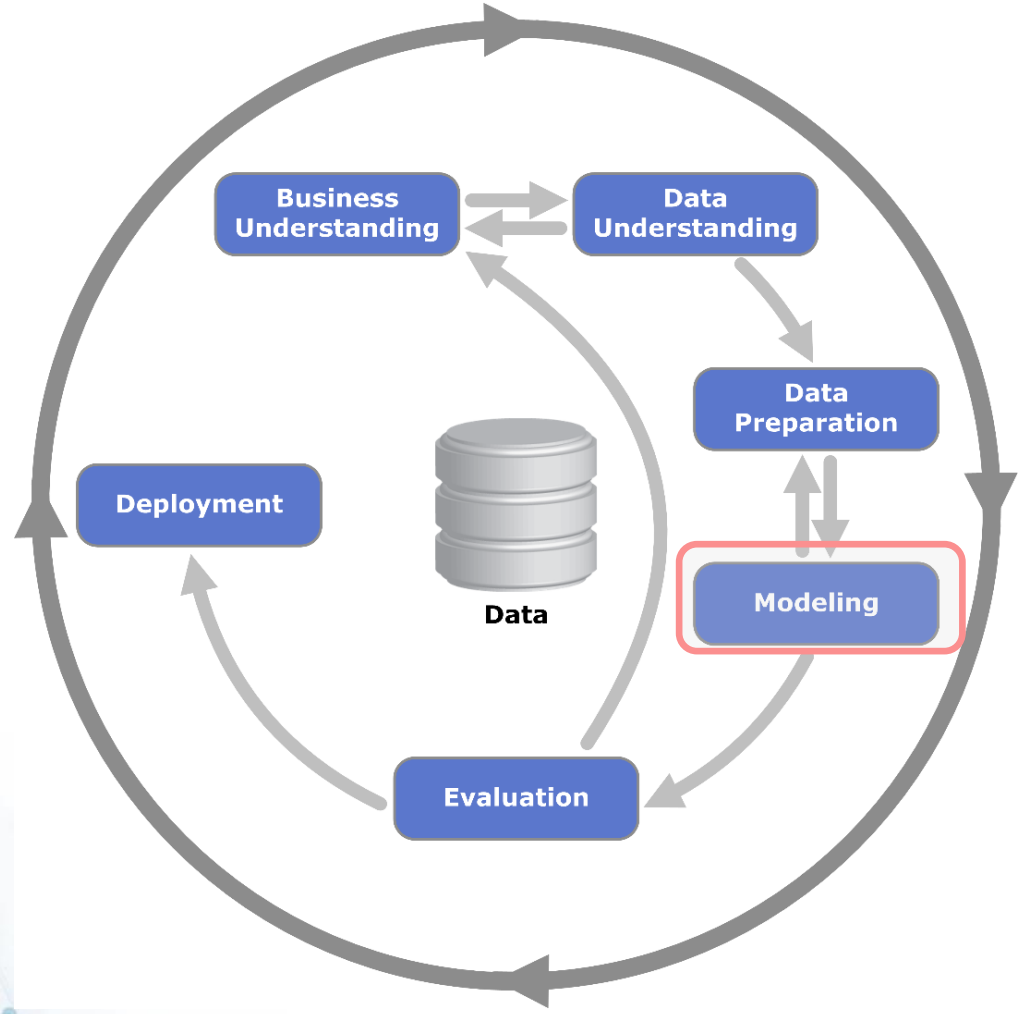

Modelation:

- **Seleção de Técnicas de Modelação:** Escolher algoritmos apropriados, como regressão linear, árvores de decisão, *random forest* ou modelos baseados em redes neuronais.
- **Treinar os modelos:** Dividir os dados em conjuntos de treino e teste e treinar os modelos.
- **Avaliação dos Modelos:** Utilizar métricas como a precisão (*accuracy*), a área sob a curva ROC (AUC-ROC), a *F1-Score*, e a matriz de confusão para avaliar o desempenho do modelo no conjunto de teste.
- **Comparação de Modelos:** Comparar diferentes modelos e selecionar o que apresenta melhores resultados com base nos critérios definidos (por exemplo, um modelo com alto *recall* para identificar a maioria dos estudantes em risco).

Previsão de Desempenho Académico de Estudantes numa Universidade

CRISP-DM aplicado

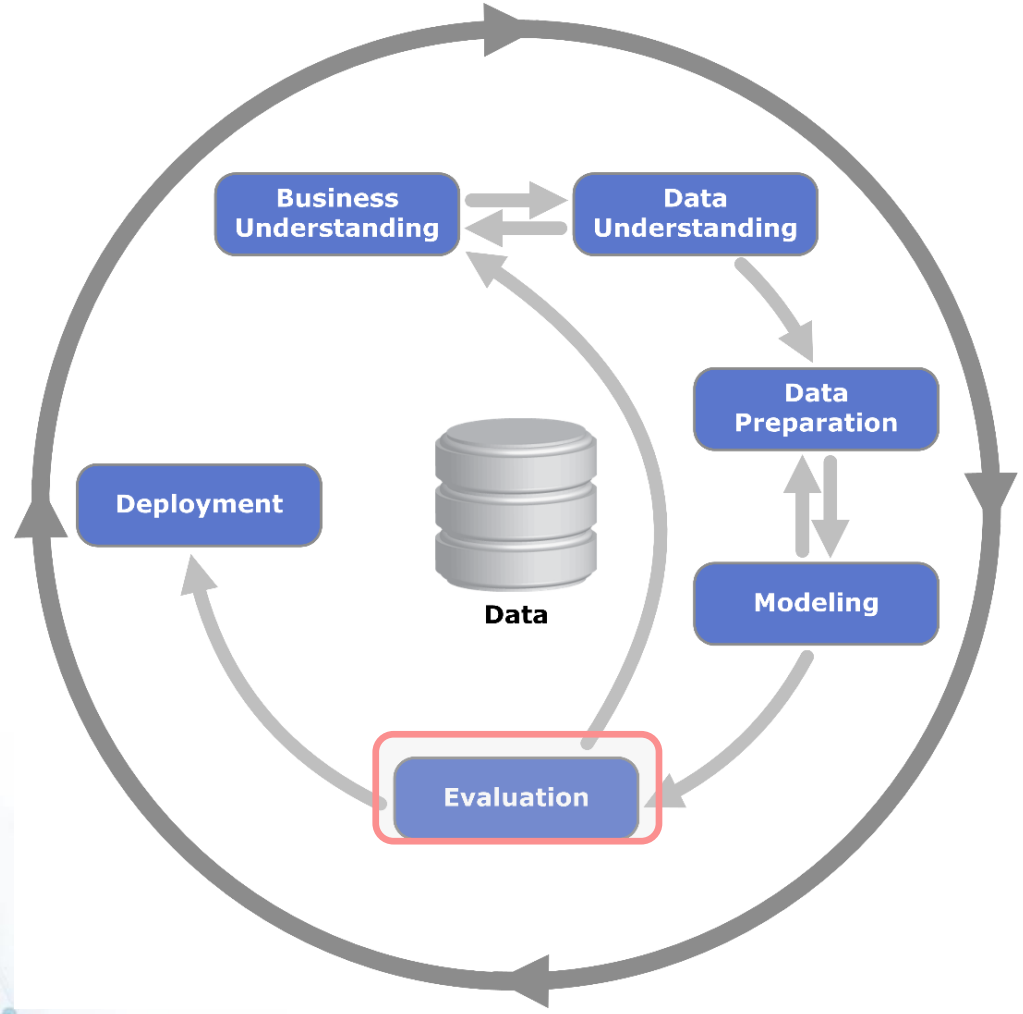

Evaluation:

- **Revisão de Desempenho do Modelo:** Avaliar se o modelo satisfaz os critérios de sucesso. Validar se a previsão consegue identificar a tempo os alunos que necessitam de apoio.
- **Validação com os *Stakeholders*:** Apresentar os resultados aos professores e conselheiros para verificar se o modelo se adequa ao contexto pedagógico. Discutir os casos identificados e planear ações de intervenção.
- **Documentação dos Resultados:** Registar todos os insights e apresentar um relatório final com as conclusões e recomendações para o processo de intervenção.

Previsão de Desempenho Académico de Estudantes numa Universidade

CRISP-DM aplicado

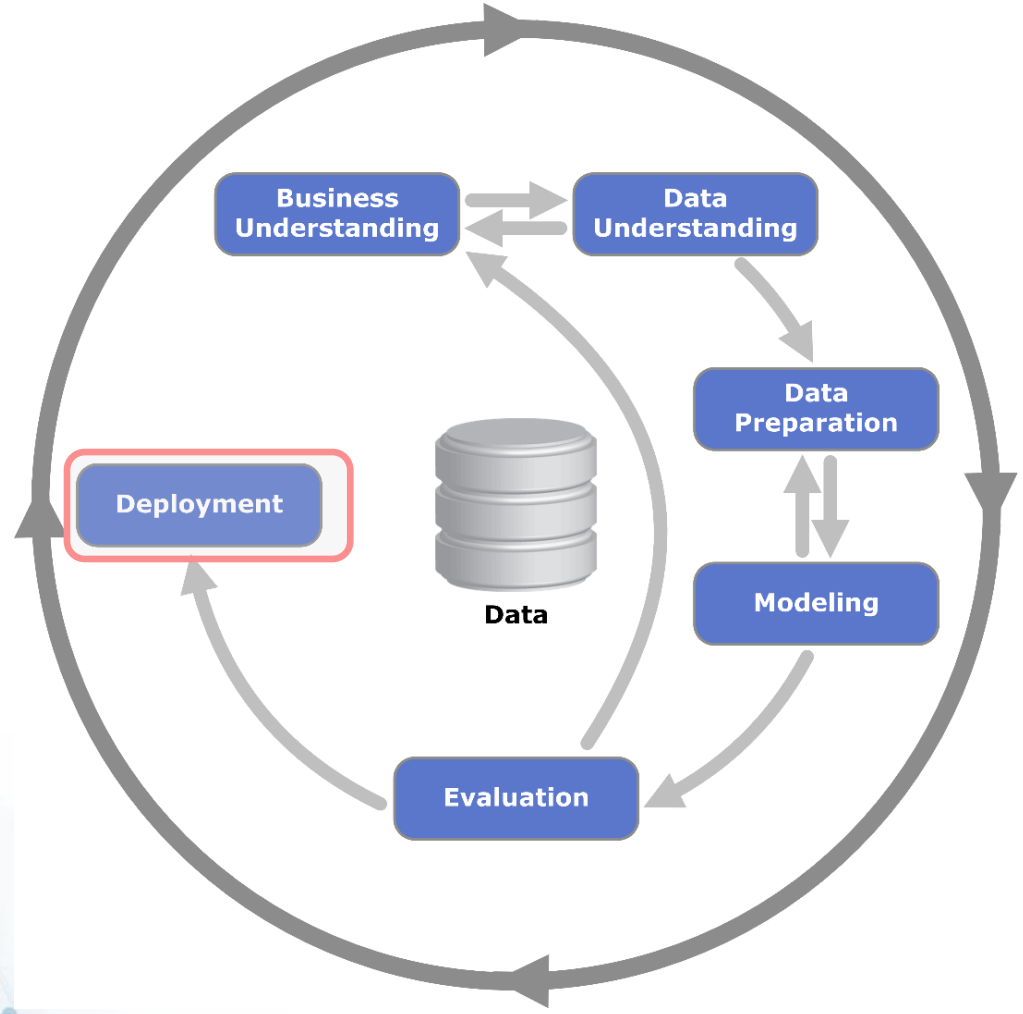

Deployment:

- **Implementar o Modelo:** Integrar o modelo no sistema de gestão académica para monitorizar o desempenho dos estudantes em tempo real. Gerar relatórios periódicos para identificar alunos em risco.
- **Definir Planos de Intervenção:** Desenvolver ações específicas, como tutorias, workshops, ou sessões de orientação para os estudantes identificados.
- **Monitorização e Manutenção do Modelo:** Acompanhar a performance do modelo ao longo do tempo. Atualizar o modelo com novos dados no final de cada semestre para garantir a sua validade.
- **Comunicação dos Resultados:** Partilhar os resultados e melhorias alcançadas com os departamentos envolvidos, como pedagogia e apoio ao estudante, para ajustar estratégias educacionais conforme necessário.

#recap

- As tarefas em CD podem ser:
  - Supervisonadas, com conjunto de treino com dados rotulados que resolvem problemas de previsão através de:
    - Classificação: variável target categórica
    - Regressão: variável target numérica
  - Não supervisionadas, em que o objetivo é encontrar padrões nos dados
- A metodologia CRISP-DM é um ciclo com dependências entre as suas 6 etapas:
  1. Business Understanding
  2. Data Understanding
  3. Data Preparation
  4. Modelation
  5. Evaluation
  6. Deployment