iscte

INSTITUTO UNIVERSITÁRIO DE LISBOA

Introdução à Ciência de Dados

Aula 07

Docentes

Ana Rita Peixoto Fábio Ferreira

Miguel Teodoro Martim Santos

2024/2025

Preparação de Dados Estruturados

- Atividades da preparação dos dados
- Exemplos
- Aplicação no Orange

(slides adaptados dos materiais da Professora Anabela Costa)

Dados #recap

Estruturados

- São dados que estão armazenados de forma organizada.
- Exemplo: Classificações dos alunos na UC de ICD organizadas num tabela:

Número de aluno	Classificação
129073	18
(...)	(...)

  - Cada linha representa um registo/instância da base de dados;
  - Cada registo é definido por um conjunto de atributos (neste exemplo: Número aluno e Classificação)

Não Estruturados

- Quando não é possível identificar uma organização clara dos dados armazenados.
- Exemplos:
  - Textos diversos (páginas da internet, documentos, e-mails, …);
  - Imagens (fotos, gráficos, ilustrações, …);
  - Arquivos de áudio (música, streaming, …);
  - Arquivos de vídeo (filmes, documentários, …);
  - Redes sociais (blogs, Facebook, Twitter, Instagram, Linkedin, …).

Atividades da preparação dos dados

Coleção

Processo de adquirir dados, de diversas fontes e tipos, que estão relacionados com o problema em estudo.

Outliers

Processo que identifica os registos/ instâncias com comportamento fora do comum e analisa-os de acordo com o objetivo.

Equilibrar dataset

Equilibrar o dataset é necessário quando um atributo categórico possui significativamente menos amostras de uma das classes.

Integração

Processo que envolve a combinação de dados existentes.

Análise Estatística

Ao longo da Preparação dos dados, são executadas diversas análises estatísticas e visuais para auxiliar nas análises e atividades envolvidas.

Limpeza

Processo que consiste em eliminar ruídos (dados incorretos; dados redundantes), inconsistências e problemas de estrutura.

Transformação de Dados

Processo que transforma o conjunto de dados de forma a prepará-lo para a etapa de modelação (por exemplo, transforma os valores de uma variável através da aplicação de uma função específica).

Tratamento de Dados Omissos

Processo que trata de dados que não estão no conjunto e que podem ser úteis para a análise.

Redução da Dimensão

Processo que envolve: eliminação das características (atributos) redundantes; escolha das melhores características; seleção das principais componentes dos dados.

Atividade: Limpeza de dados

Limpeza

Processo que consiste em eliminar ruídos (dados incorretos; dados redundantes), inconsistências e problemas de estrutura.

Dado repetido, ficar só com uma instância

22 > 20 (nota máxima) talvez eliminar este valor

Número de aluno	Classificação
129073	18
129073	18
87654	22
98765	16
12345	2
92345	16

Neste excerto de dados, a nota 2 pode aparecer como um outlier, eliminar?? Se calhar neste contexto não faz sentido, deve-se manter!

Limpar os dados dos atributos (colunas) procurando anomalias, tais como:

- Outliers, valores for a do interval comum
- Erros tipográficos
- Instâncias em que alguns atributos possuem valores desatualizados

Relembrando que os dados não vivem sem o contexto

Atividade: Tratamento dos valores omissos

Tratamento de Dados Omissos

Processo que trata de dados que não estão no conjunto e que podem ser úteis para a análise.

Importância do Tratamento dos Valores Omissos:

- Em alguns algoritmos de modelização é exigido que todos os atributos, de cada instância, têm que ter um valor.
- Nos algoritmos em que podem existir valores omissos, se a percentagem for elevada então será muito difícil extrair informação de qualidade.

Formas de Tratamento:

- Eliminar as instâncias que possuem valores omissos.
- Não considerar o atributo caso este possua um número significativo de valores omissos.
- Inferir os valores omissos à custa dos valores conhecidos:
  - Valores <u>numéricos</u>: pela média, mediana ou moda
  - Valores <u>categóricos</u>: pela moda ou valor mais frequente
  - Pode se usar outras abordagens como por exemplo o k-vizinhos mais próximos e usar os valores dos grupos mais próximos em vez de para os dados todos.
- Considerar os valores omissos de cada atributo como um valor especial a ser incluído no domínio do respetivo atributo.

Número de aluno	Classificação
129073	18
Nan	17
98765	16
12345	Nan
92345	16

O que fazer aqui?
Talvez eliminar instância

E aqui?
Talvez a média

Atividade: Transformação de dados

Transformação de Dados

Processo que transforma o conjunto de dados de forma a prepará-lo para a etapa de modelação (por exemplo, transforma os valores de uma variável através da aplicação de uma função específica).

Transformações usuais:

- Aplicação de filtros
- Recodificação de variáveis categóricas em numéricas e vice-versa
- Normalização dos Dados
  - Minimiza os problemas utilização de unidades e dispersões distintas entre as medidas dos atributos.
  - Alguns algoritmos de modelizacão exigem a normalizacão dos dados.

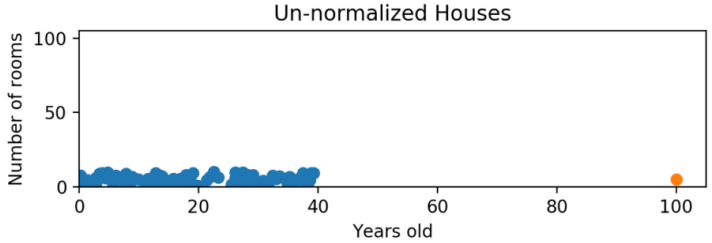

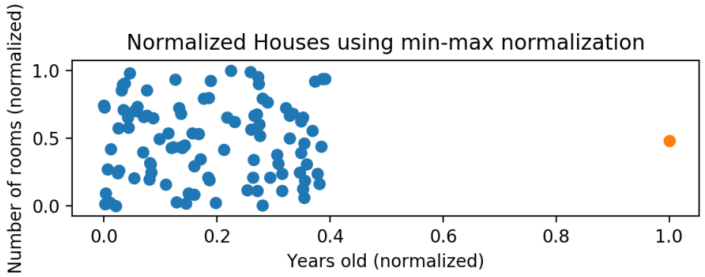

https://cyberhoot.com/cybrary/data-normalization/

Atividade: Transformação de dados

Exemplo 1: Normalização de valores numéricos numa escala [0,1]
Considere a variável X – distância, em km, do hotel ao centro da cidade

Hotel	X
1	2.80
2	1.90
3	1.90
4	1.10
5	1.90
6	1.90
7	1.20
8	1.60
9	1.90

Normalização [0,1] →

Hotel	X'
1	1
2	0.35
3	0.47
4	0
5	0.47
6	0.47
7	0.06
8	0.29
9	0.47

$$X' = \frac{X - \min(X)}{\max(X) - \min(X)}$$

Atividade: Transformação de dados

Exemplo 2: Representação numérica de dados categóricos
Considere o seguinte quadro de dados:

Número Aluno	Regime
129073	Diurno
129080	Diurno
98763	Pós-laboral
98765	Pós-laboral
12345	Diurno
92345	Diurno
129074	Pós-laboral

Transformação de variável categórica, com duas classes em variável numérica binária

Número Aluno	Regime Pós-laboral
129073	0
129080	0
98763	1
98765	1
12345	0
92345	0
129074	1

Atividade: Transformação de dados

Exemplo 3: Representação categórica de dados numéricos
Considere o seguinte quadro de dados:

Número Aluno	Idade
129073	18
129080	25
98763	35
98765	30
12345	24
92345	18
129074	20

Transformação de variável numérica contínua em variável categórica que representa um intervalo

Número Aluno	Faixa etária
129073	[18-22]
129073	[23-30]
98763	>30
98765	[23-30]
12345	[23-30]
92345	[18-22]
129073	[18-22]

Atividade: Identificação de outliers

Outliers

Processo que identifica os registos/ instâncias com comportamento fora do comum e analisa-os de acordo com o objetivo.

Outliers:

- são valores que se diferenciam drasticamente de todos os outros valores que o respetivo atributo assume.

Importância da Análise dos Outliers

- Os outliers podem prejudicar o resultado da análise de dados.
- O comportamento dos outliers pode ser exatamente o conhecimento que se procura ao realizar uma análise de dados.

Após a identificação dos outliers há que decidir como tratar:

- Excluir
- Realizar um análise separada
- Atribuir valores

Atividade: Identificação de Outliers

Exemplo 1: Identificação de outliers a partir da representação gráfica dos dados

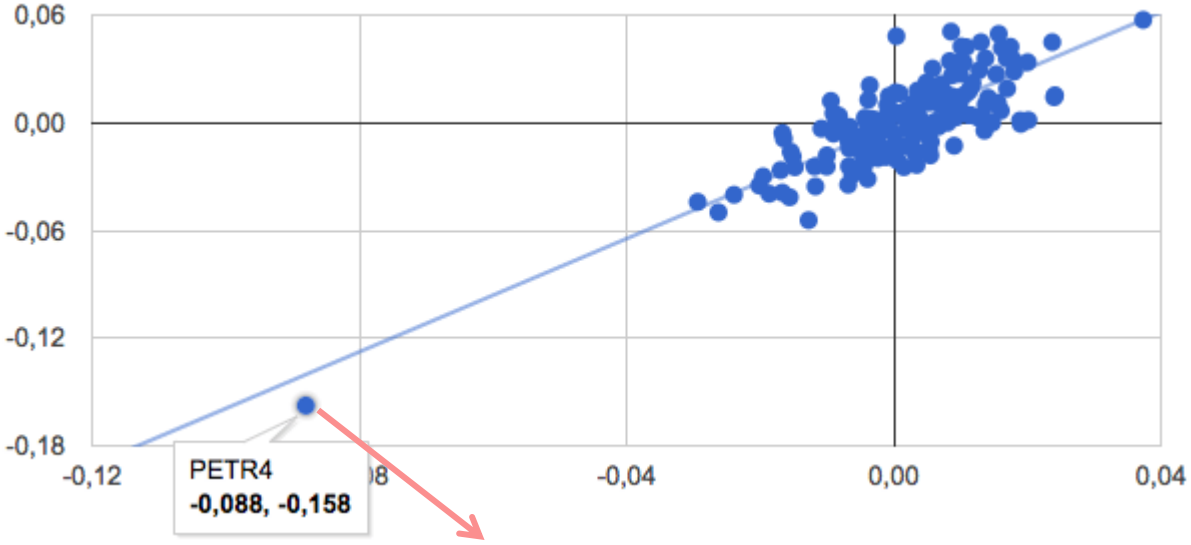

Fonte imagem

Este registo é um outlier

Atividade: Identificação de Outliers

Exemplo 2: Identificação de outliers a partir da observação direta dos dados

Qual o outlier?

Número Aluno	Idade
129073	18
129073	25
98763	35
98765	30
12345	110
92345	18
129073	20

Este registo é um outlier

Atividade: Identificação de Outliers

Exemplo 3: Identificação de outliers a partir de uma Regra Prática (**Método de Tukey**)

Qual o outlier?

Notas dos alunos (nº alunos = 48)					
75	84	63	42	65	78
99	80	95	90	68	79
76	92	53	77	71	77
93	80	62	70	69	64
98	87	86	75	59	27
66	89	55	79	57	88
60	83	81	49	78	58
85	74	84	62	90	73

Um valor é um outlier se estiver mais de **1,5 x AQ** acima do terceiro quartil (Q3) ou abaixo do primeiro quartil (Q1), em que AQ é a amplitude interquartis (**AQ = Q3 – Q1**)

- Outliers inferiores são valores abaixo de
  - **Q1 – 1,5 x AQ**
- Outliers superiores são os valores acima de
  - **Q3 + 1,5 x AQ**

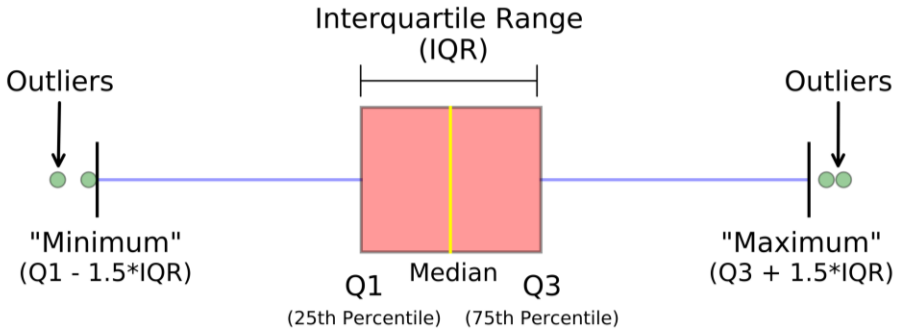

Atividade: Identificação de Outliers

Exemplo 3: Identificação de outliers a partir de uma Regra Prática (**Método de Tukey**)

Qual o outlier?

Notas dos alunos (nº alunos = 48)					
75	84	63	42	65	78
99	80	95	90	68	79
76	92	53	77	71	77
93	80	62	70	69	64
98	87	86	75	59	27
66	89	55	79	57	88
60	83	81	49	78	58
85	74	84	62	90	73

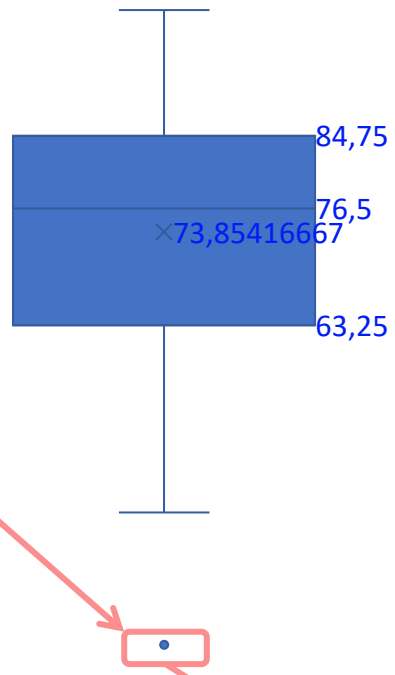

(**AQ = Q3 – Q1**)

AQ = 84,75 – 63,25 = 21,5

- Outliers inferiores são valores abaixo de
  - **Q1 – 1,5 x AQ =**
    63,25 – 1,5 x 21,5 = 31
- Outliers superiores são os valores acima de
  - **Q3 + 1,5 x AQ =**
    84,75 – 1,5 x 21,5 = 117

Qual é este valor?
= 27 um outlier inferior

Atividade: Redução da dimensão

Redução da Dimensão

Processo que envolve: eliminação das características (atributos) redundantes; escolha das melhores características; seleção das principais componentes dos dados.

Examplo: Feature Selection

- Imagine o seguinte cenário em que queremos prever o género de uma pessoa através dos atributos apresentados.

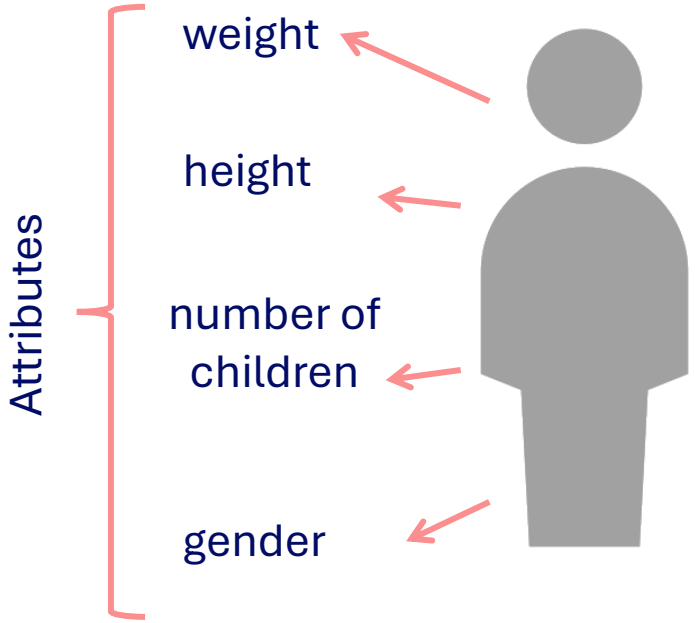

Precisamos do número de crianças por pessoa para isso?

Atividade: Equilibrar dados

Equilibrar dataset

Equilibrar o dataset é necessário quando a variável **target é categórica** e possui significativamente menos amostras de uma das classes.

Existem duas abordagens:

- undersampling
- oversampling

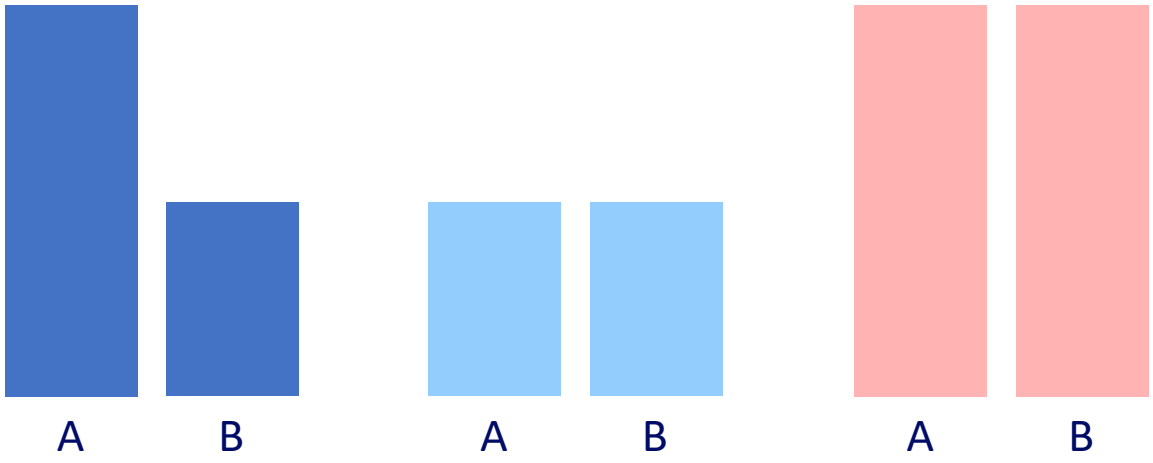

Original dataset
(representation of a variable of two classes {A,B})

Undersampling
Decrease the entries of the class A to the number of entries of the class B

Oversampling
Increase the entries of the class B to the number of entries of the class A

Limpeza de dados

Dataset: housing_to_clean

A) Verifica se existem valores na variável *price* que não fazem sentido neste dataset, cujo objetivo é analisar quais as variáveis que mais interferem com o preço das casas. Remove as linhas/entradas se necessário.

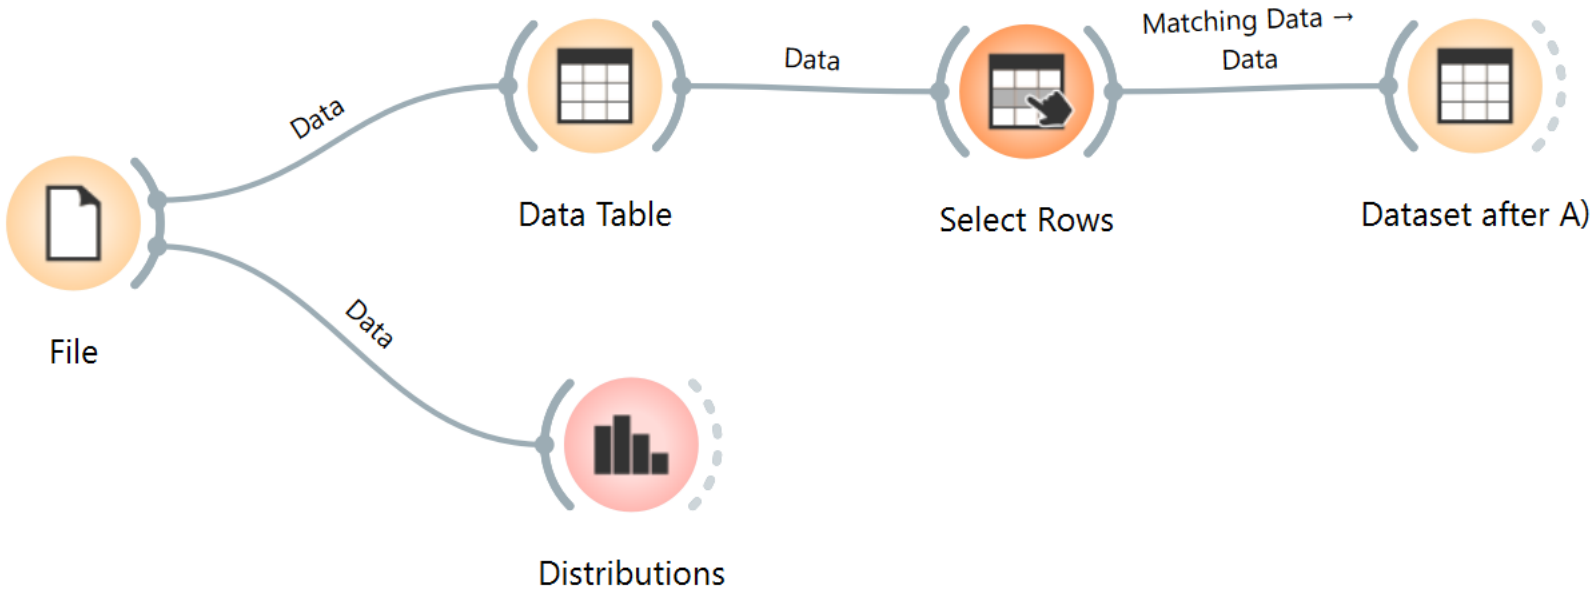

Valores omissos

Dataset: housing_to_clean

B) Substitui os valores omissos pela sua média.

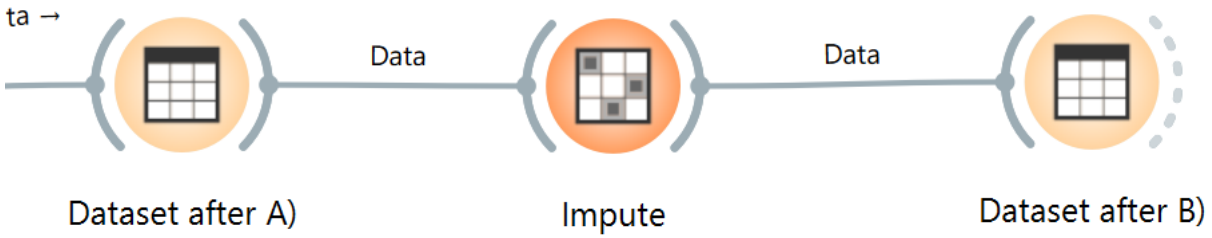

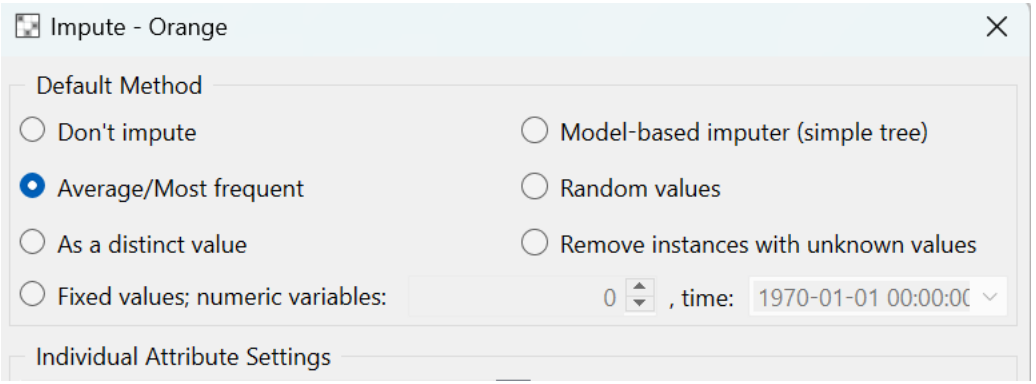

Feature Selection

Dataset: housing_to_clean

C) Quais as variáveis que à partida não são úteis para prever o valor das casas? Cria um dataset sem essas variáveis.

Outliers

Dataset: housing_to_clean

D) Verifica se existem outliers na variável *price* através de visualização. Remove os outliers usando o widget do Orange.

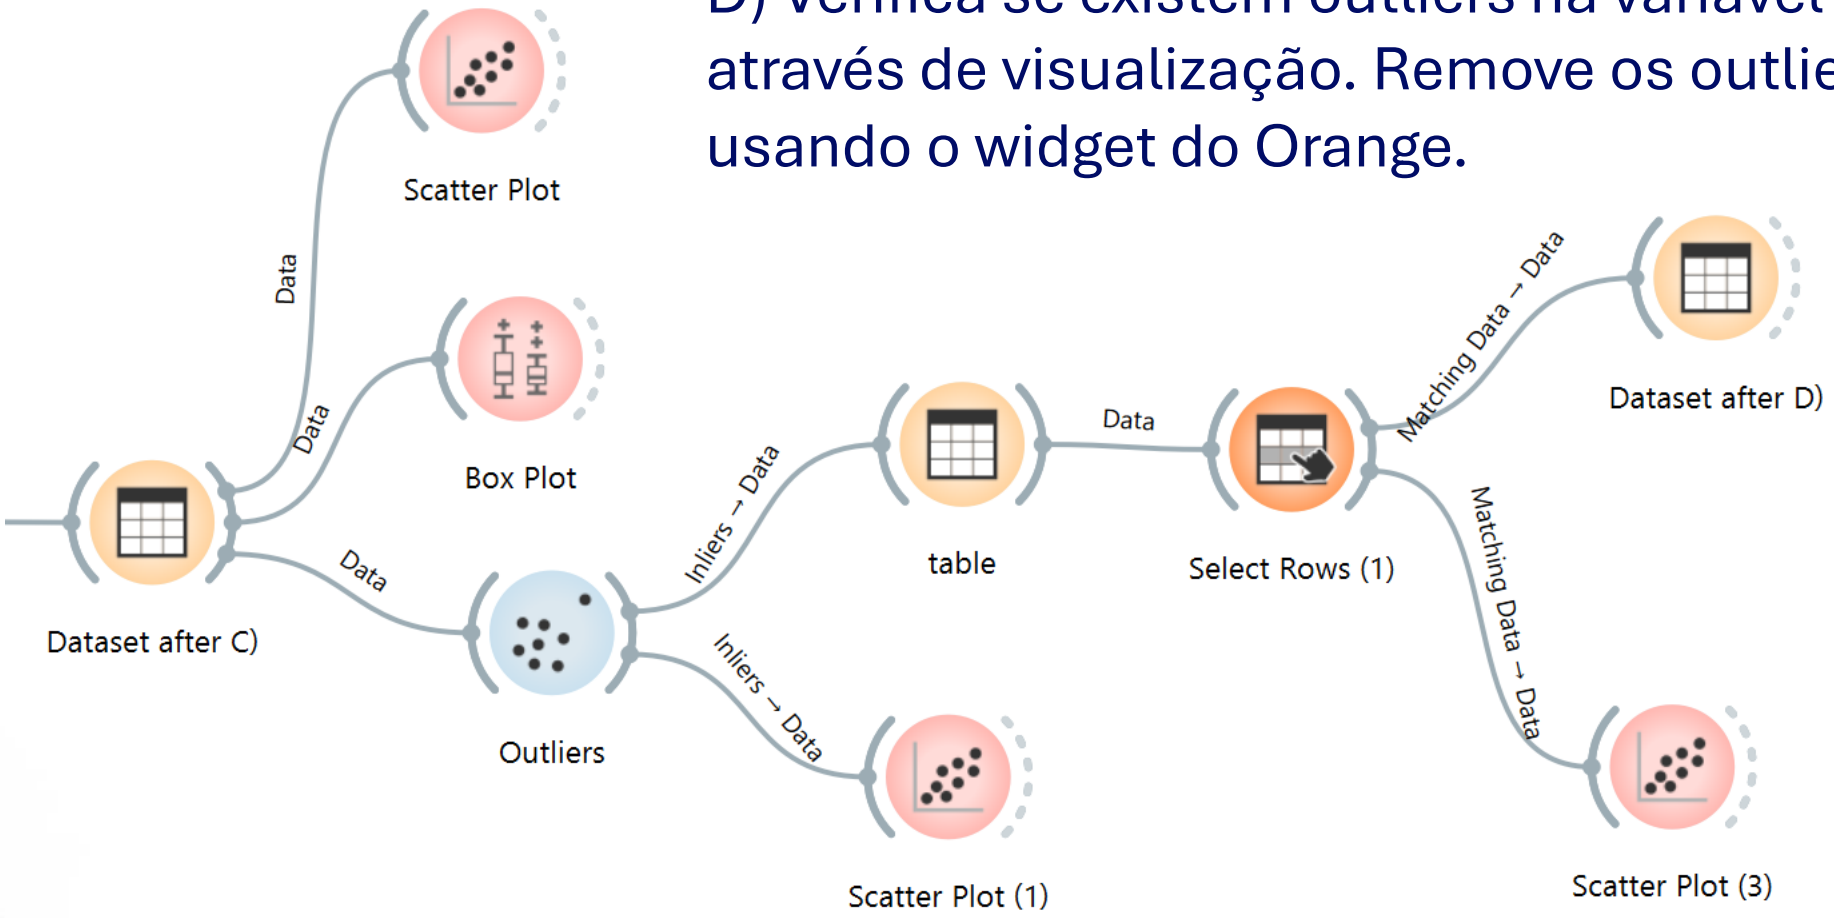

Normalização de variáveis

Dataset: housing_to_clean

E) Normaliza para um intervalo de [0-1] a variável *price*.

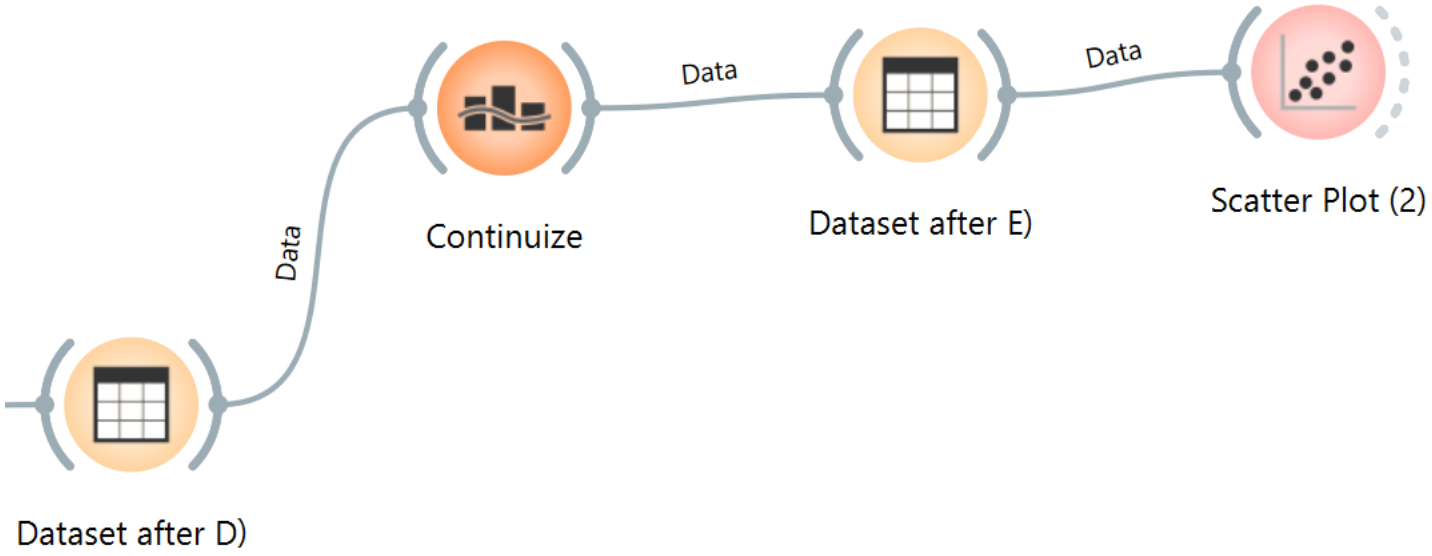

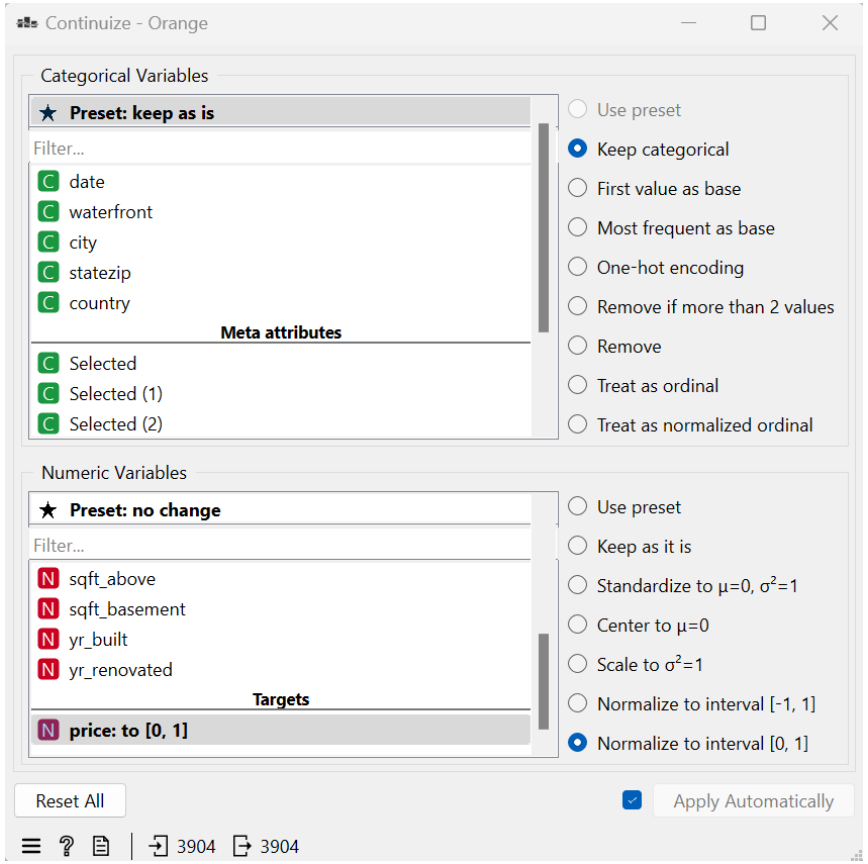

Transformação de variáveis

Dataset: housing_to_clean

F) Transforma a variável *yr_renovate* numa variável categórica com as seguintes classes: **no_renovation**, se o valor é 0, **old_renovation**, se o valor é inferior a 2010 e **recent_renovation** se foi renovado em 2010 ou mais recente.

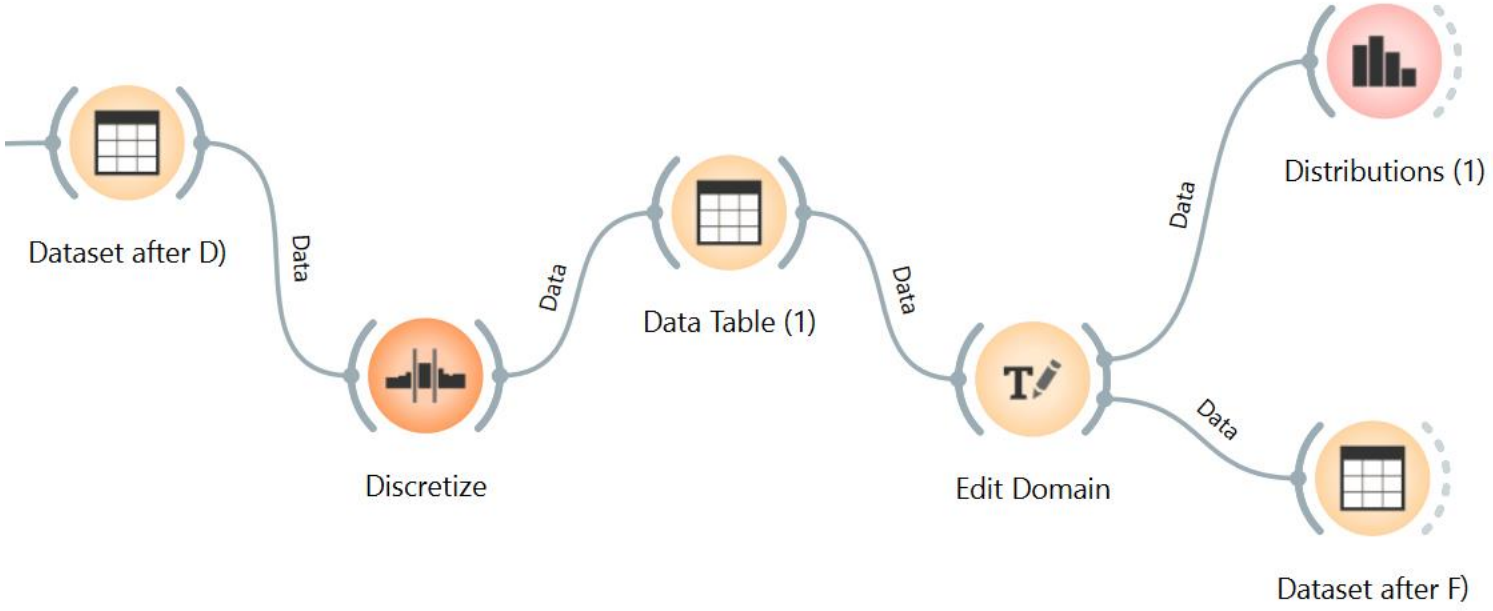

Equilibrar dataset

Dataset: housing_to_clean
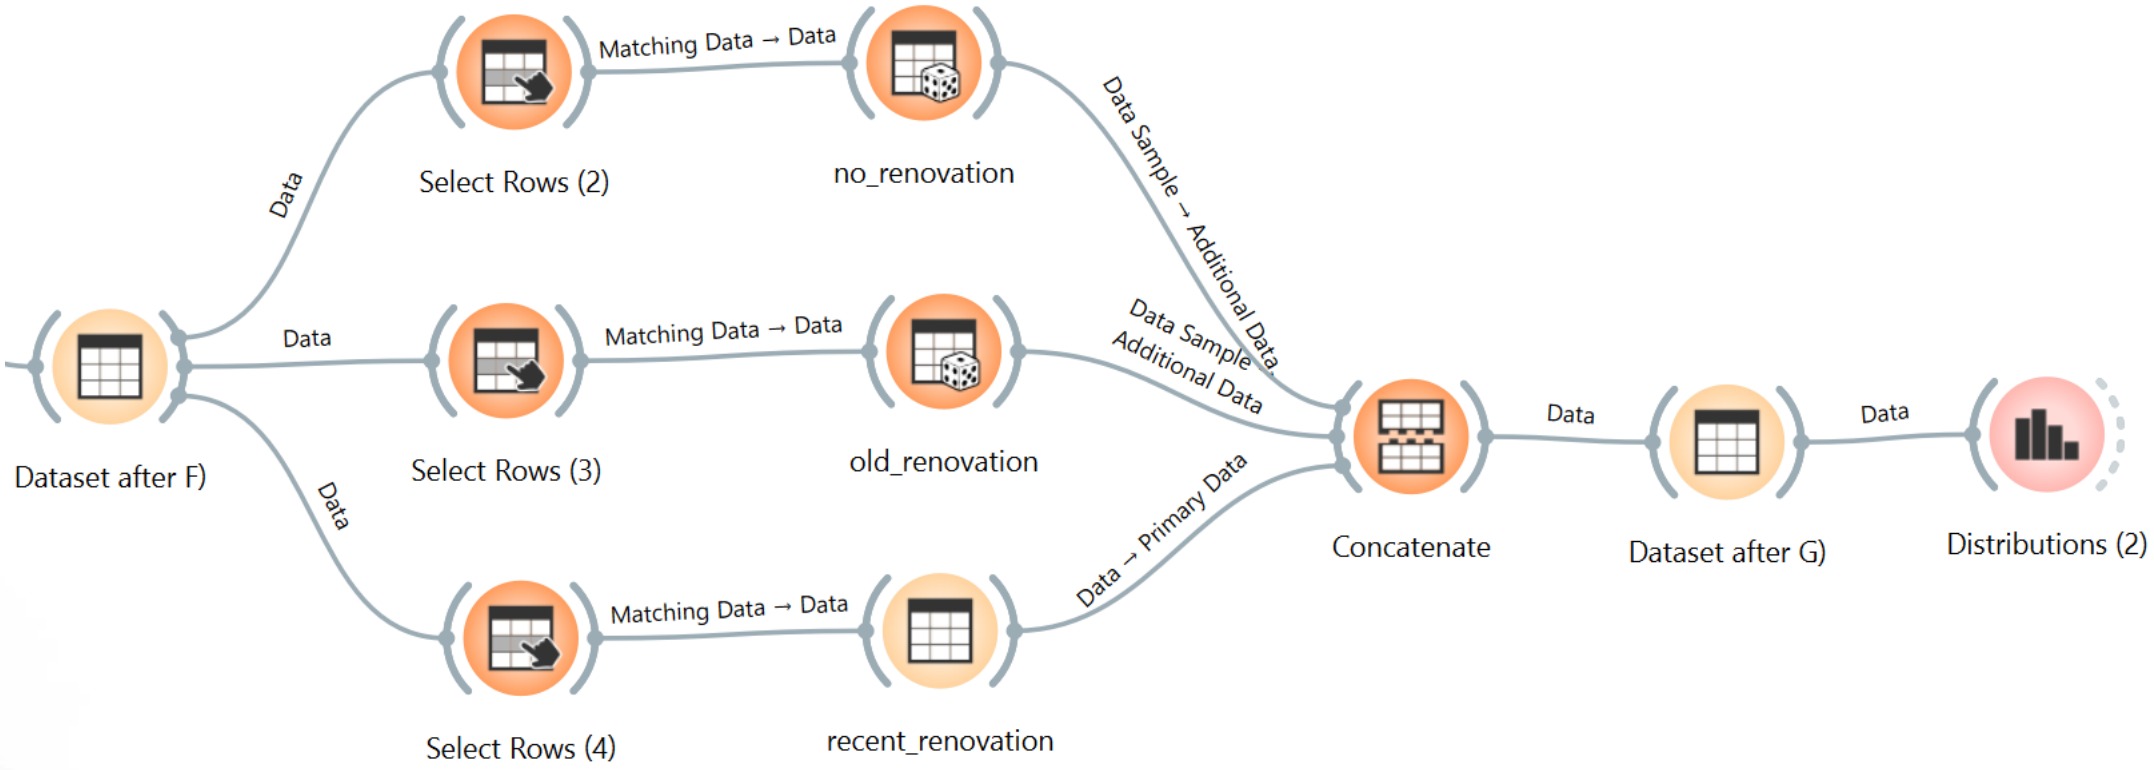
G) Esta nova variável não é equilibrada, equilibra criando um novo dataset usando a técnica de undersampling.