iscte

INSTITUTO UNIVERSITÁRIO DE LISBOA

Introdução à Ciência de Dados

Aula 07

Docentes

Ana Rita Peixoto

Miguel Teodoro

Martim Santos

2025/2026

CRISP-DM #recap

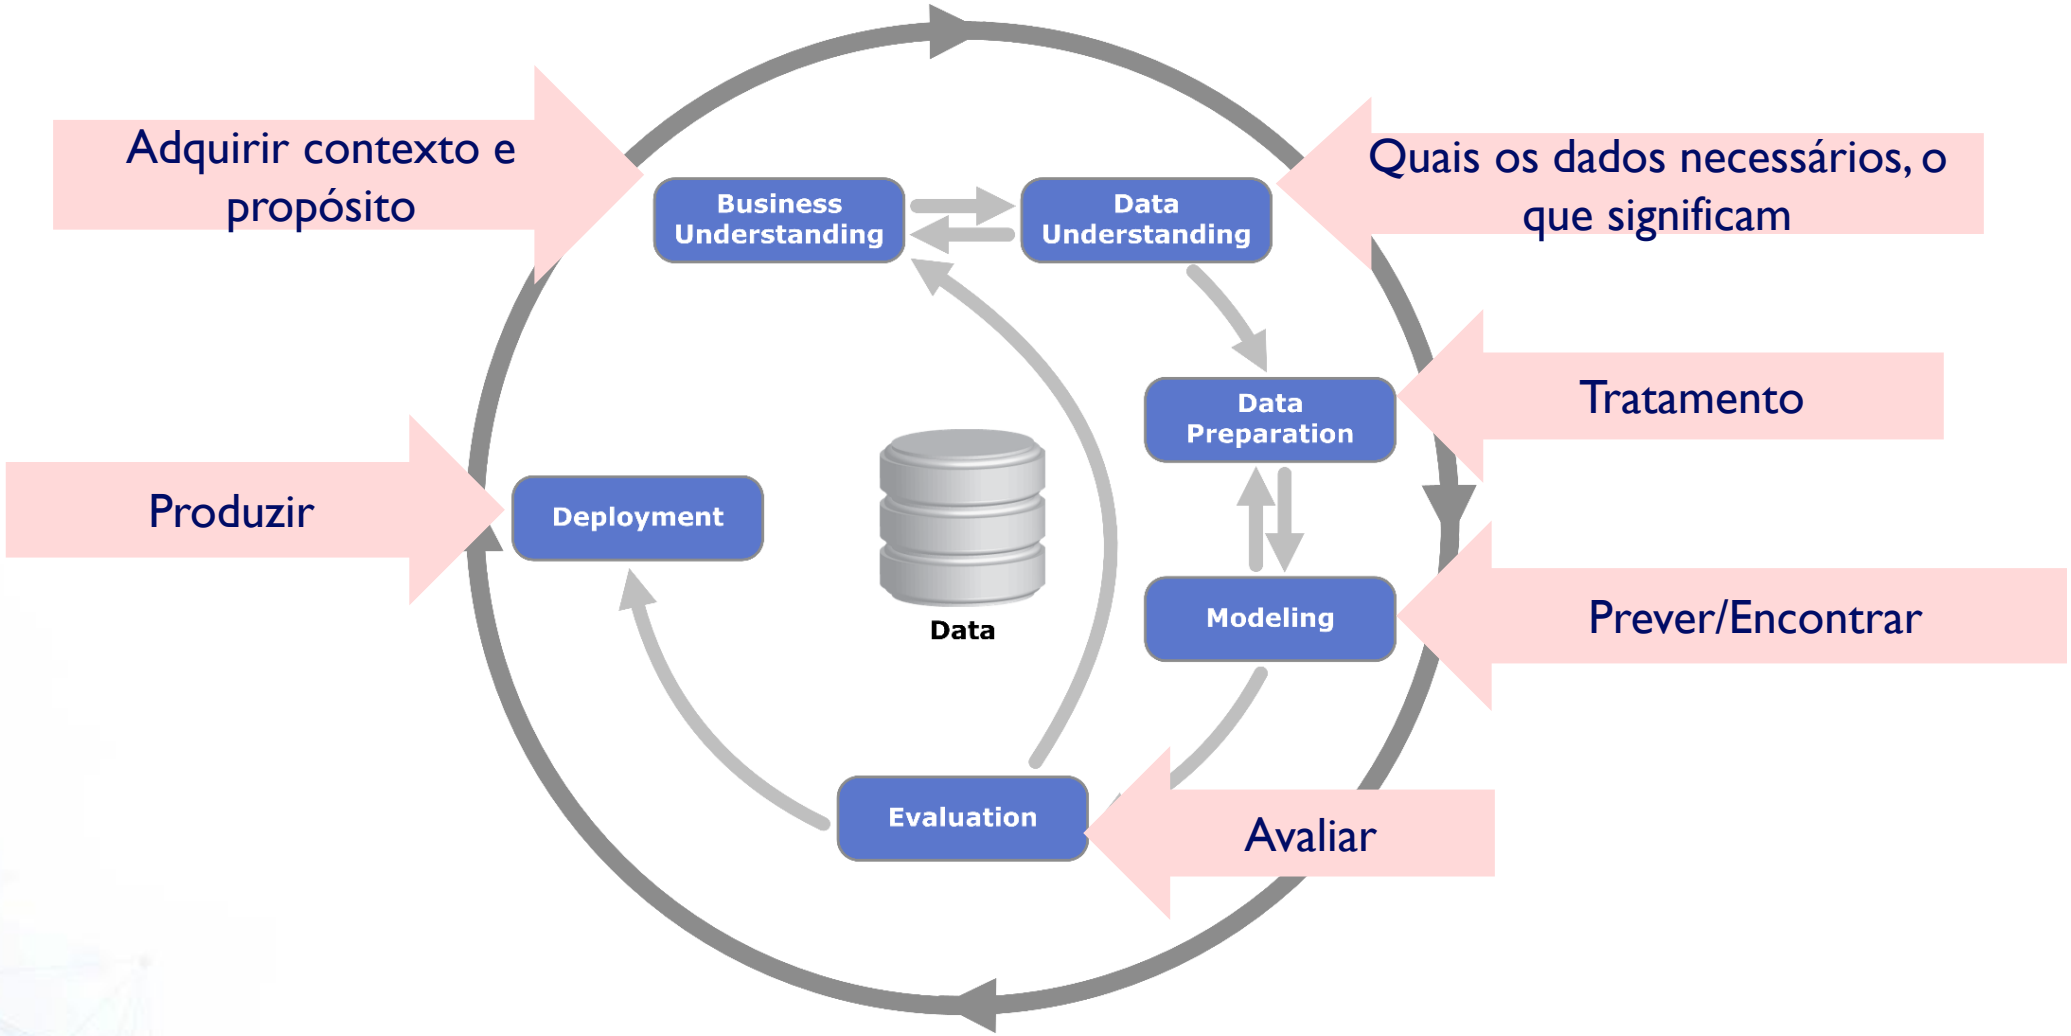

Principais tarefas em CD #recap

Aprendizagem

- **Supervisionadas**
  - Previsão
  - **Classificação**
    Variáveis categóricas
  - **Regressão**
    Variáveis quantitativas
- **Não Supervisionadas**
  - Descrever
  - **Clustering**
  - **Associar**
  - **Sequenciar**

Tipos de problema e abordagens possíveis

- **Descritiva**: usa análise de dados para conhecer o que se passou
  - Descriptive Analytics, Unsupervised Learning

- **Preditiva:** usa métodos de ML para prever o futuro
  - Predictive Analytics, Supervised Learning

- **Prescritiva:** usa algoritmos de simulação para saber o que vai ser preciso fazer
  - Prescriptive Analytics, Decision Sciences

Modelação

- Construção de modelos de aprendizagem supervisionada
- Algoritmos de regressão e classificação
- Avaliação de modelos
- Escolha de features

Terminologia

Modelação	É o processo que incorpora a informação existente numa ferramenta (algortimo) capaz de fazer previsões
Modelo	Um objeto complexo que recebe um input e devolve um output
Algoritmo	Conjunto de passos necessário para processar e calcular um modelo
Machine Learning	É sobre "aprender" modelos que conseguem generalizar da melhor forma possível.
Algoritmos de ML	• Aprendizagem supervisionada: regressão, classificação • Aprendizagem não-supervisionada: clustering, padrões • Aprendizagem por reforço
Avaliação de Resultados	Avaliação de resultados: encontrar uma medida (numérica, gráfica) que nos da qualidade (acurácia, precisão) do modelo, do output e da previsão

Construção de modelos de aprendizagem supervisionada

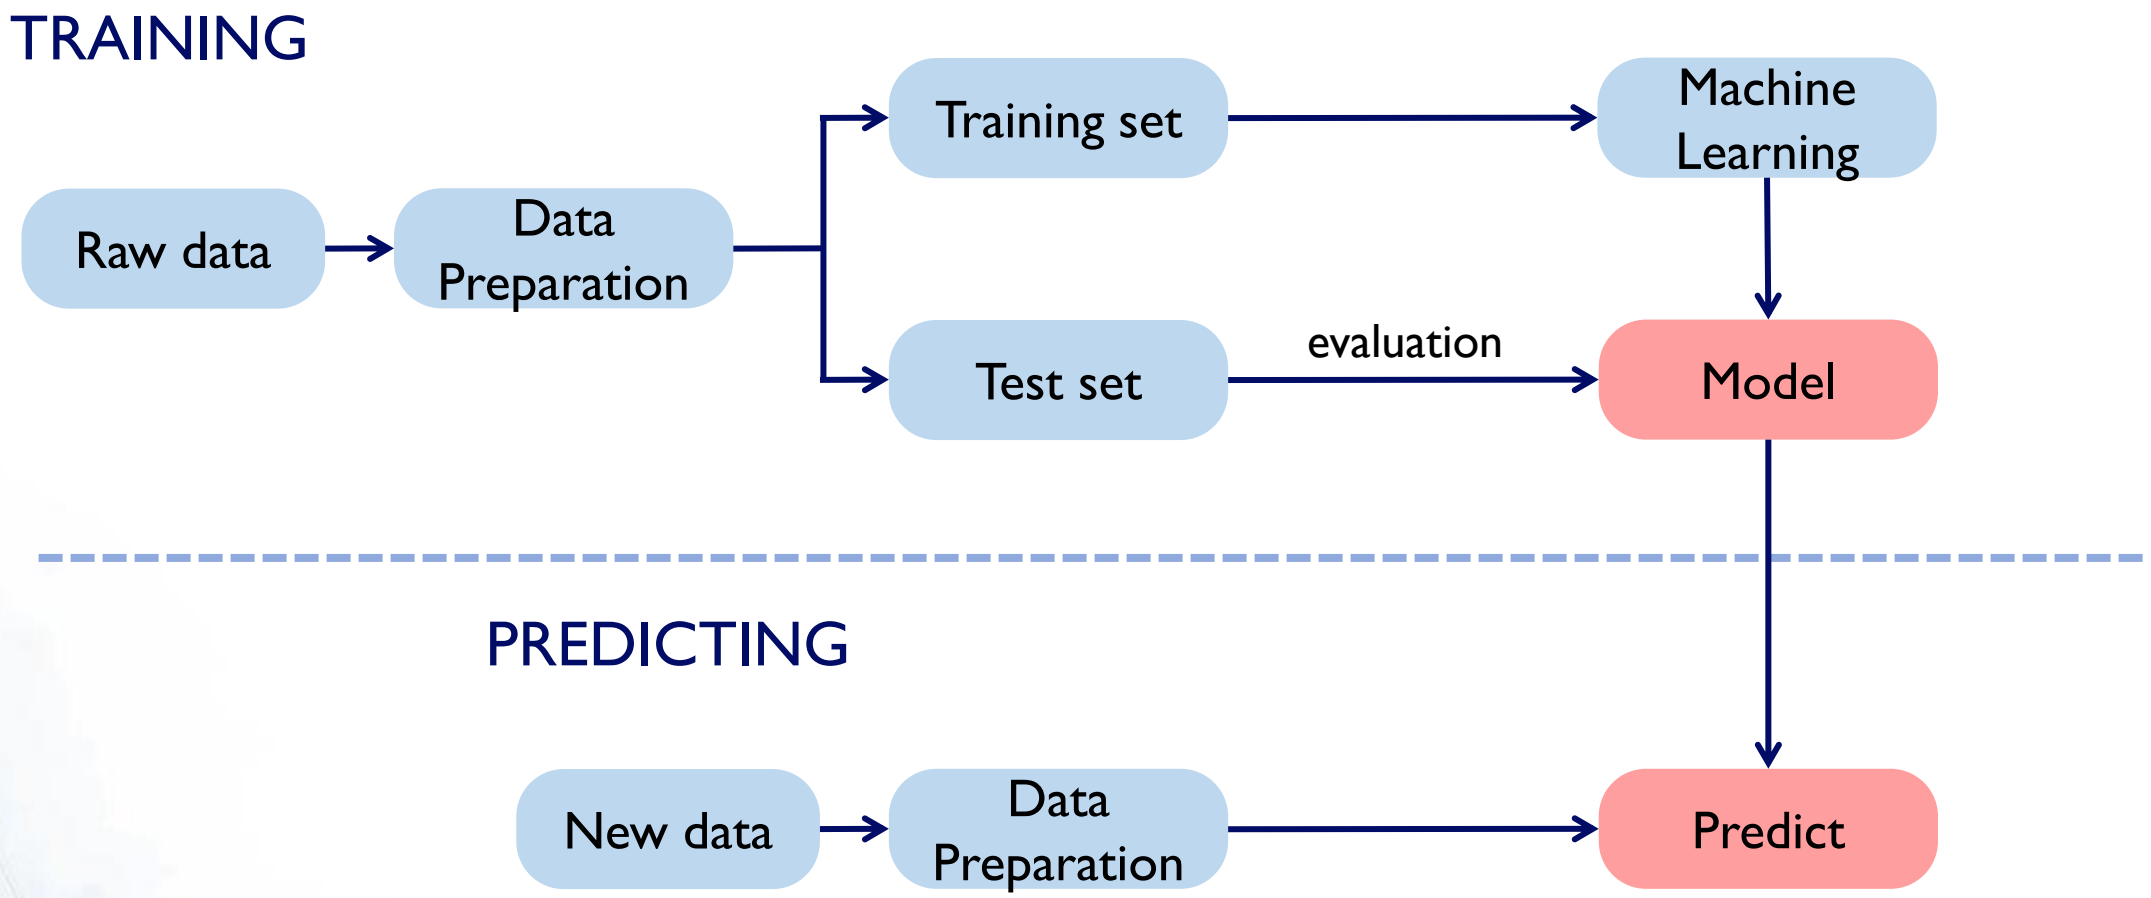

Training sets: split the data

Training set

- Tipicamente 70% ou mais do dataset original
- É usado para construir o modelo

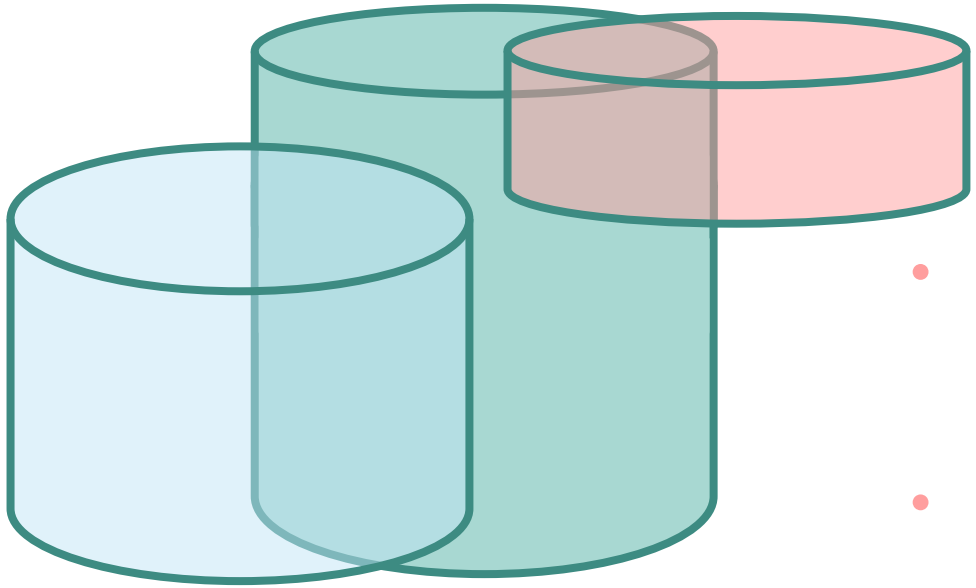

Original Dataset

Test set

- Tipicamente 30% ou menos do dataset original
- É usado para testar/validar o modelo

Training sets: split the data

- Sempre que possível, a divisão em conjuntos de treino e teste deve ser aleatória.

- No entanto, para um problema de classificação, pode haver necessidade de manter a representatividade relativa de cada classe, por existirem diferençar consistentes e coerentes. Nesse caso, deve-se fazer um divisão estratificada, de modo a manter as razões de representatividade no conjunto de treino.

- Para o teste, deve ser sempre usada a técnica de "teste por oclusão" ou "holdout": guardar o conjunto de teste de modo a nunca ser usado na fase de treino.

Training sets: k-cross validation

- O conjunto de dados é dividido em k subconjuntos e são efetuadas k training/testing experiências.
  - Dividir o dataset em k subconjuntos
  - Fazer k treinos
  - Calcular métricas de avaliação para cada treino e usar um **valor combinado**, tipicamente a média.

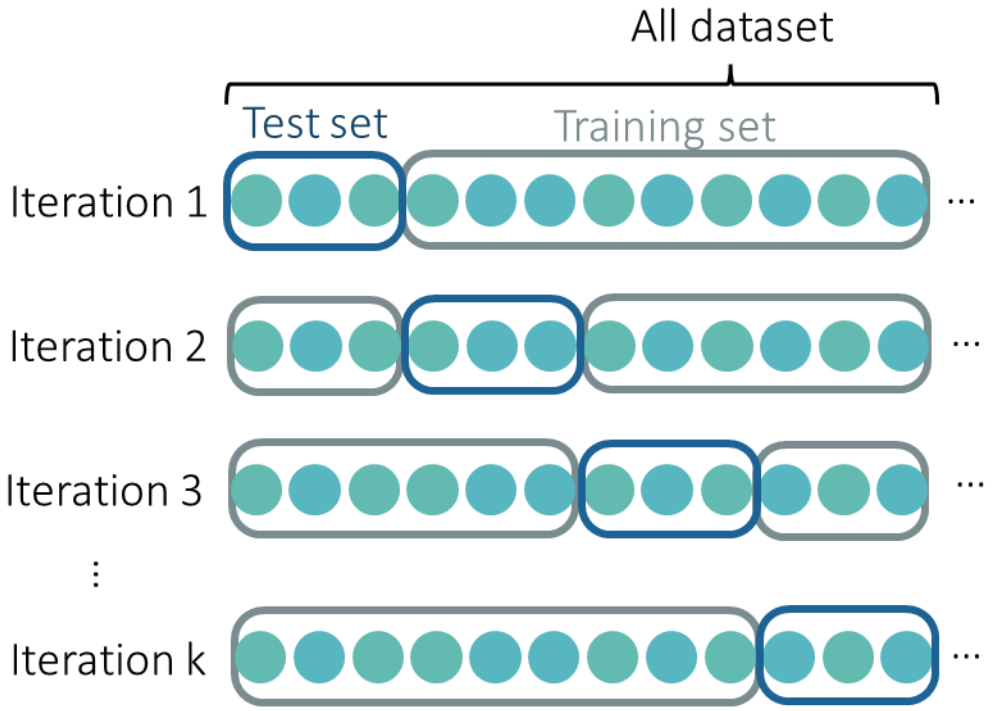

Training sets: um exemplo com teste por oclusão

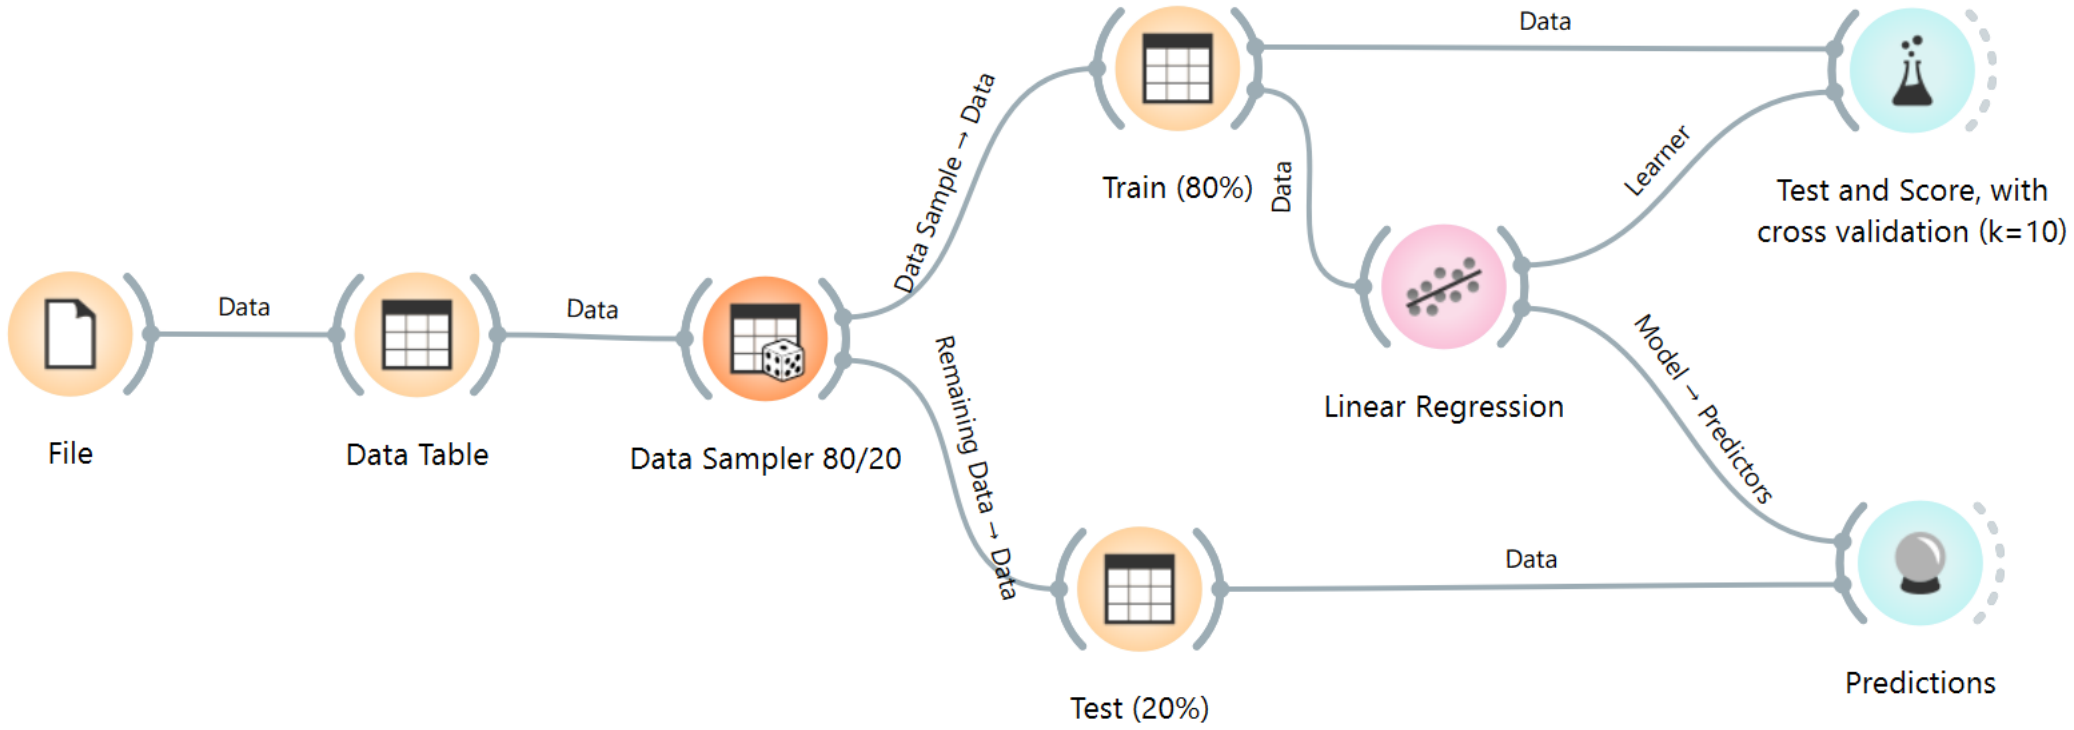

Training sets: um exemplo com teste por oclusão

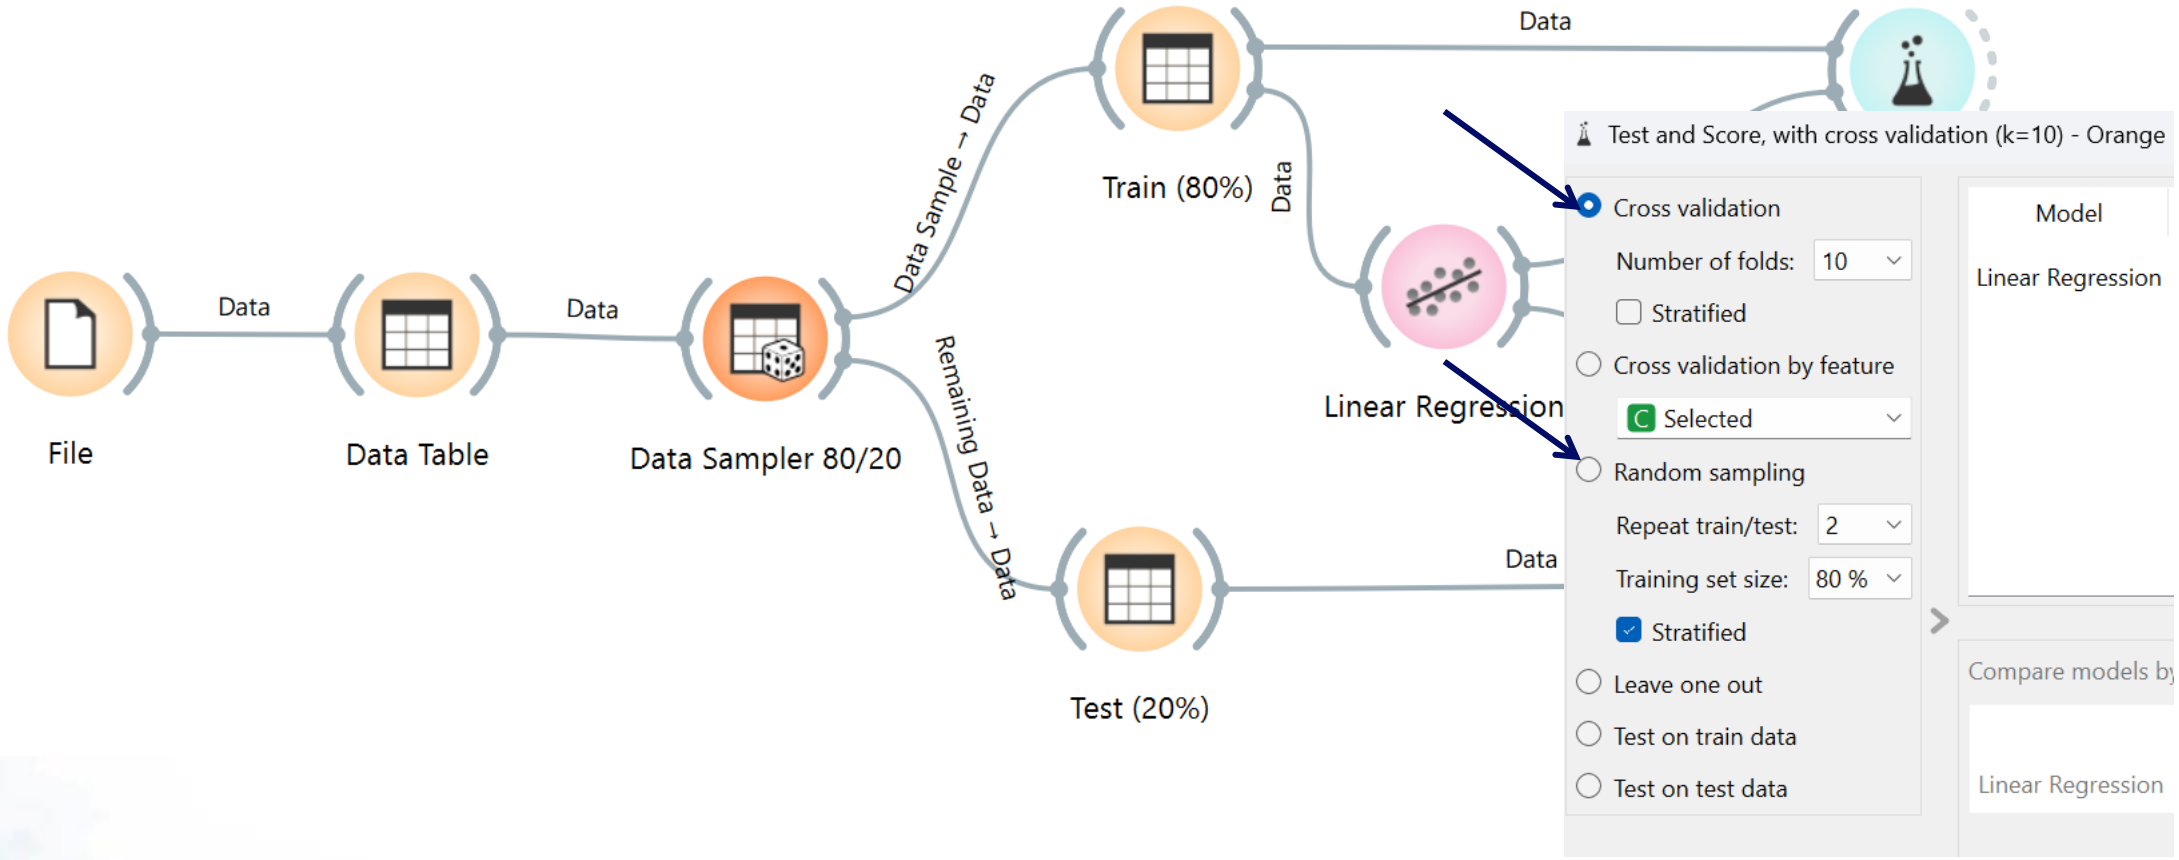

Regressão

Regressão

Variável target: **contínua**

Exemplo: Prever o retorno (vendas) em relação ao montante investido, através da comunicação

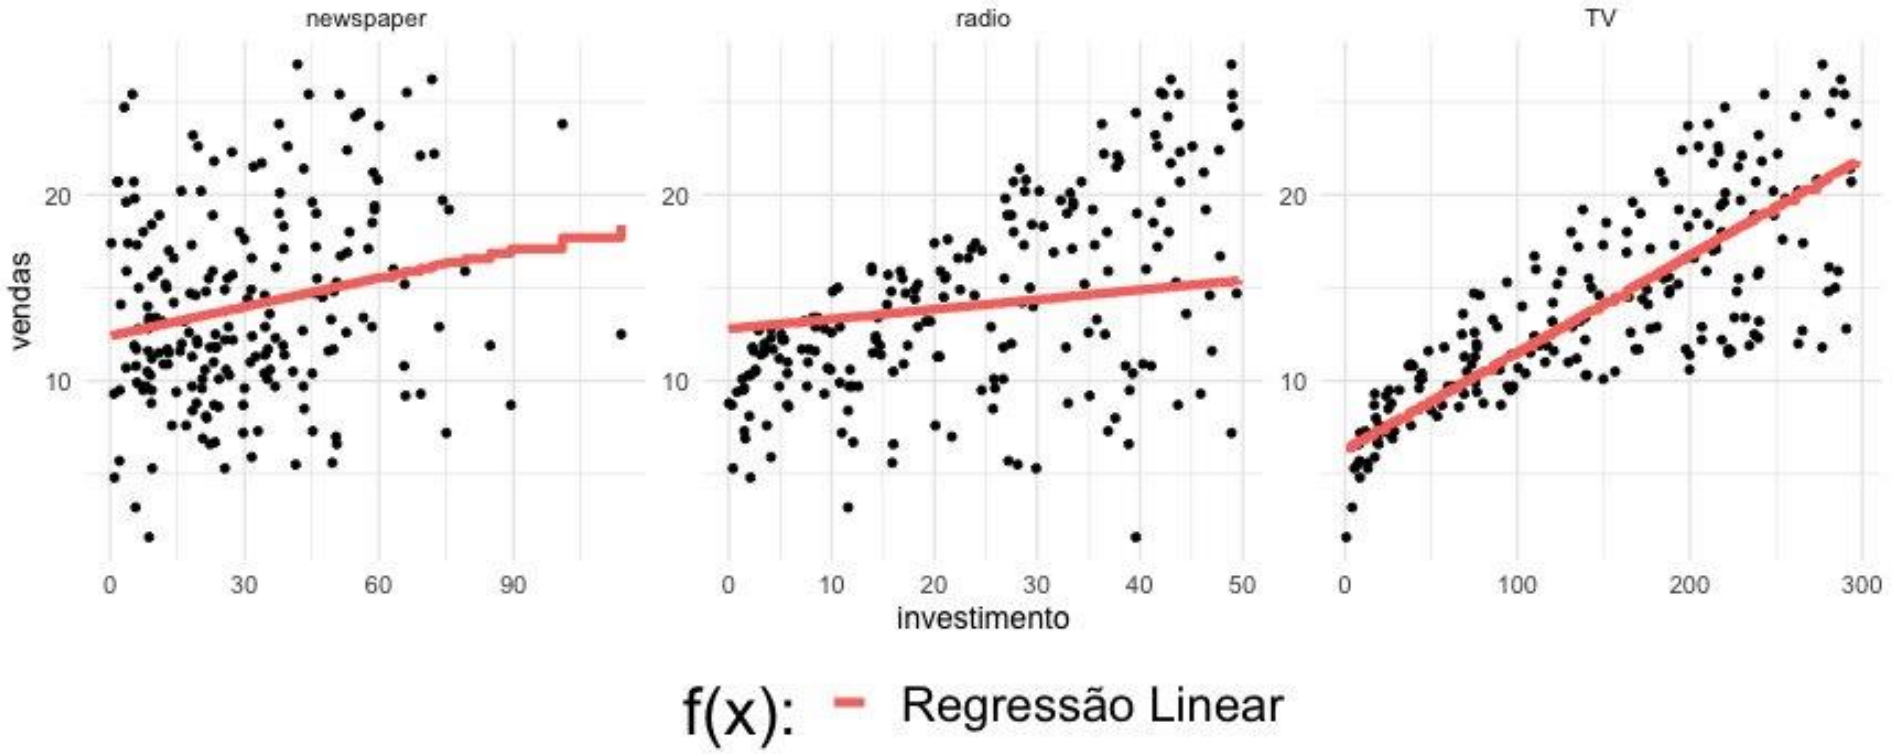

Regressão Linear

Objetivo: Prever uma variável target contínua (por exemplo, preços, temperaturas) com base numa ou mais variáveis (*features*) (independentes).

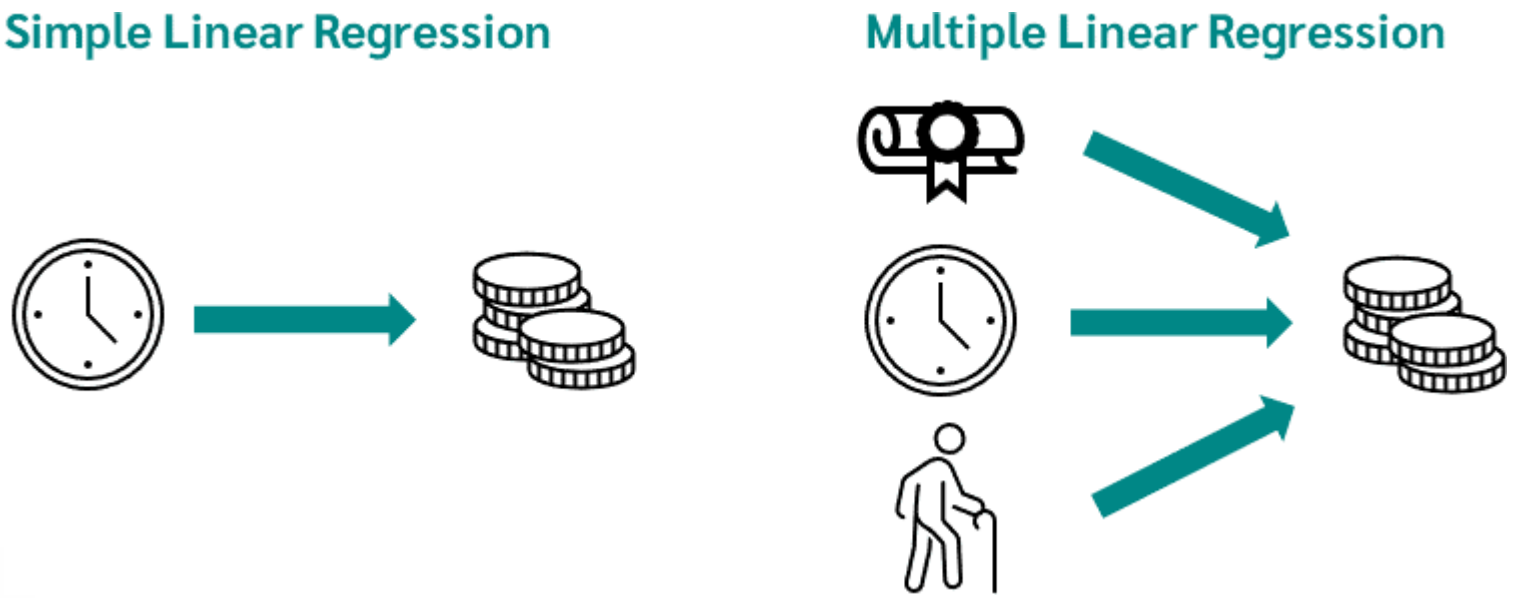

Regressão Linear

Equação: O modelo representa uma relação linear como:

$$y = \beta_0 + \beta_1 x_1 + \ldots + \beta_n x_n$$

y: variável target
β_0: interceção
(valor de y quando $x = 0$)
$\beta_1, \ldots, \beta_n$: coeficientes que representam o efeito das variáveis independente $(x_1, \ldots, x_n)$ na variável dependente

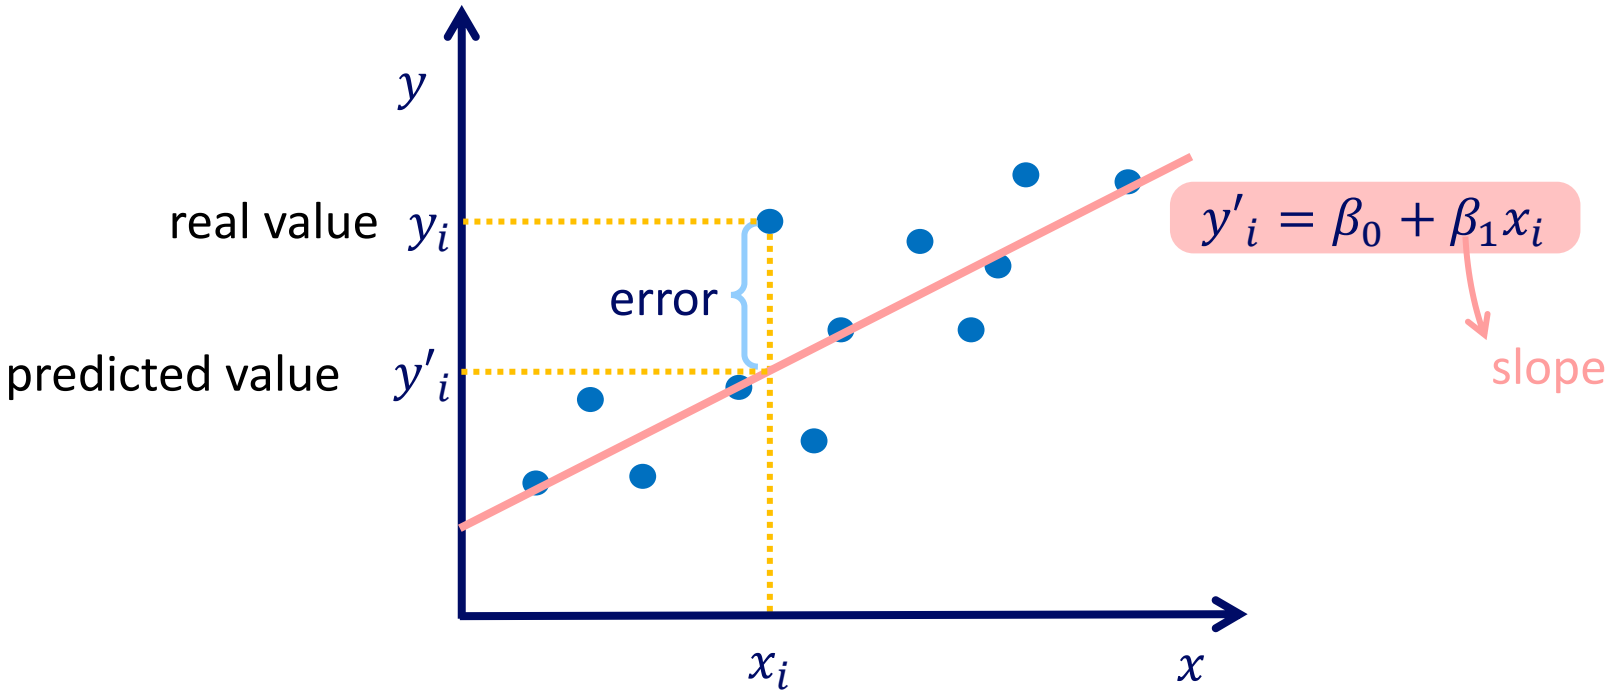

Regressão Linear

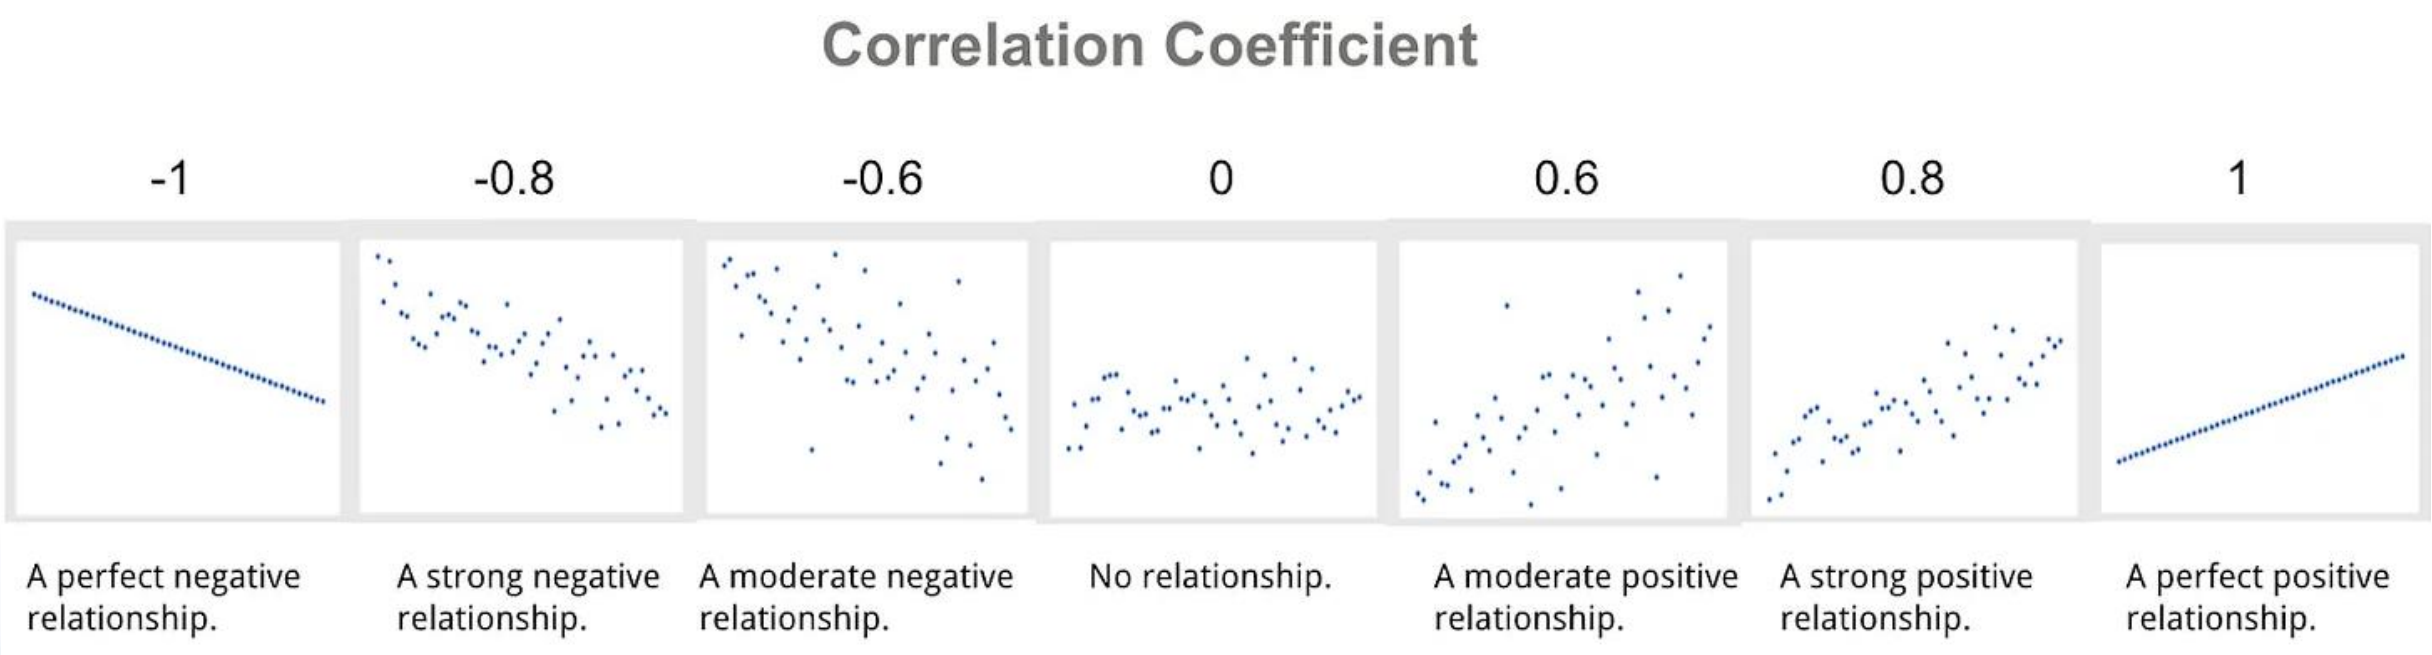

A análise de correlação diz respeito ao grau de uma relação entre duas variáveis (quando uma variável muda, a outra também muda).O resultado é um valor entre -1,0 e 1,0, em que 1,0 representa a correlação positiva mais elevada, -1,0 representa a correlação negativa mais elevada e 0 significa que não existe correlação.

Regressão Linear

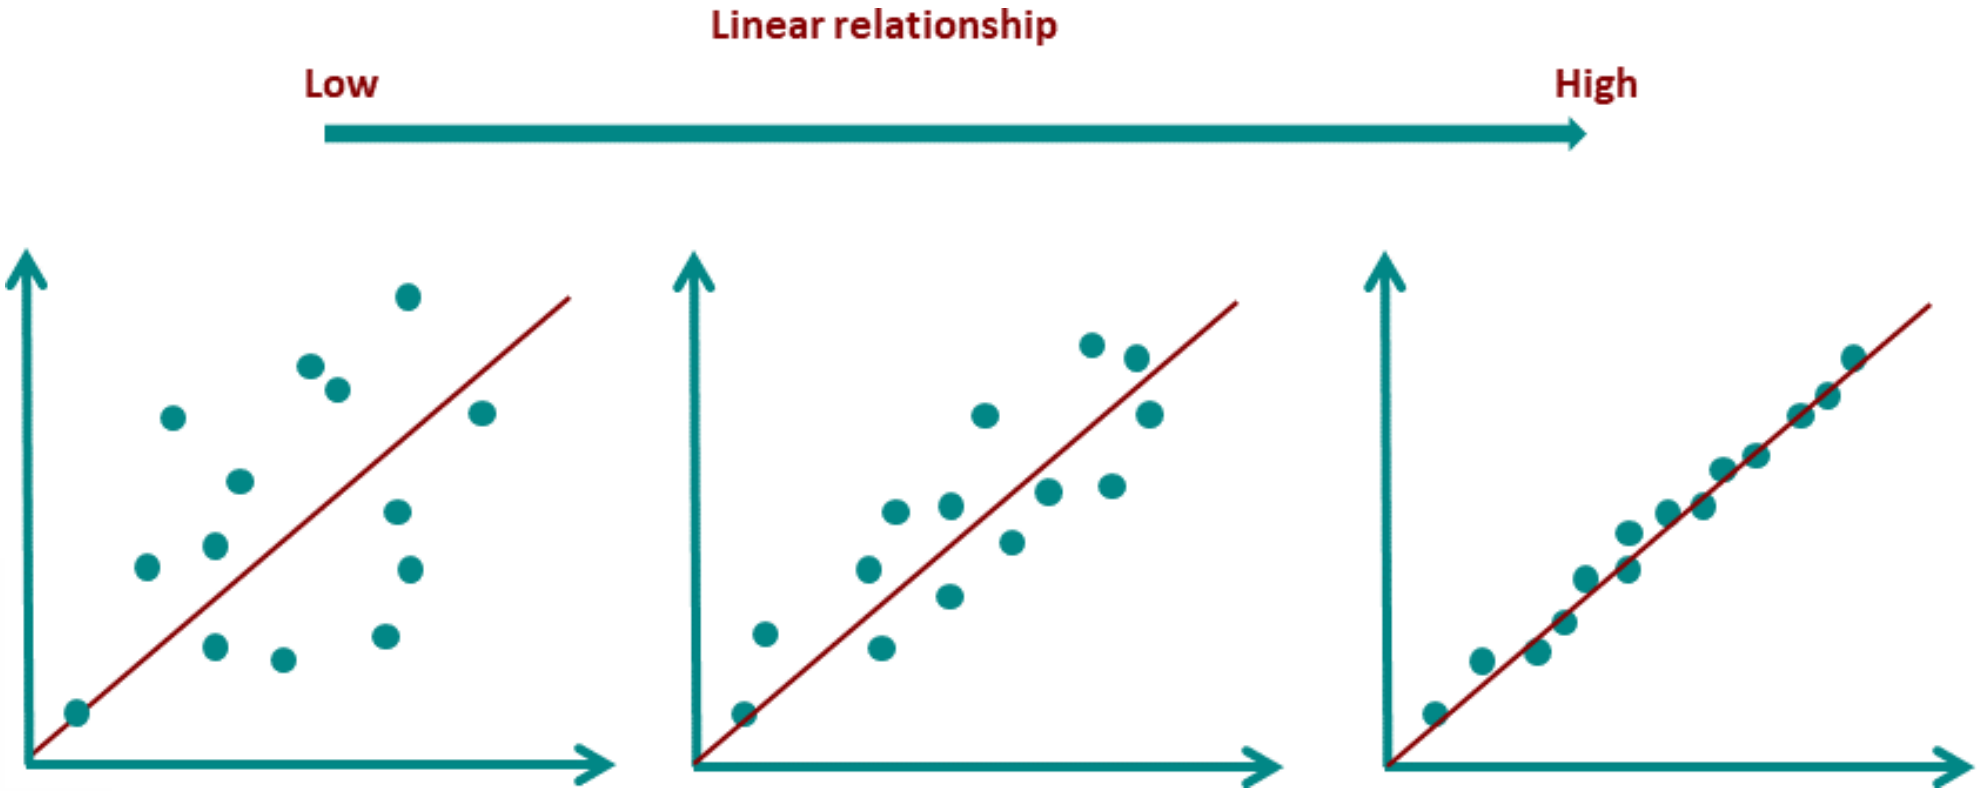

Regressão: Avaliação dos resultados

- Precisamos determinar a qualidade dos modelos:
  - Erro absoluto: $\text{erro} = |\, y_{predicted} - y_{real} |$
  - Erro absoluto médio (MAE): $\text{MAE} = \frac{1}{n}\sum_{i=1}^{n} |\, y_{predicted_i} - y_{real_i} |$
  - Erro médio quadrado (MSE): $\text{MSE} = \frac{1}{n}\sum_{i=1}^{n} (\, y_{predicted_i} - y_{real_i})^2$
  - RMSE: $\sqrt{MSE}$
  - R^2 (r-squared): não prova casualidade apenas indica o grau da relação entre as variáveis independentes e a dependente, varia entre 0 e 1:
    - 1 (100%) – os valores previstos são iguais aos valores reais (sem erro)
    - 0 (0%) – o modelo não explica a relação entre as variáveis

Classificação

Classificação

Variável target: **categórica**

Exemplo: Identificação de e-mails de spam

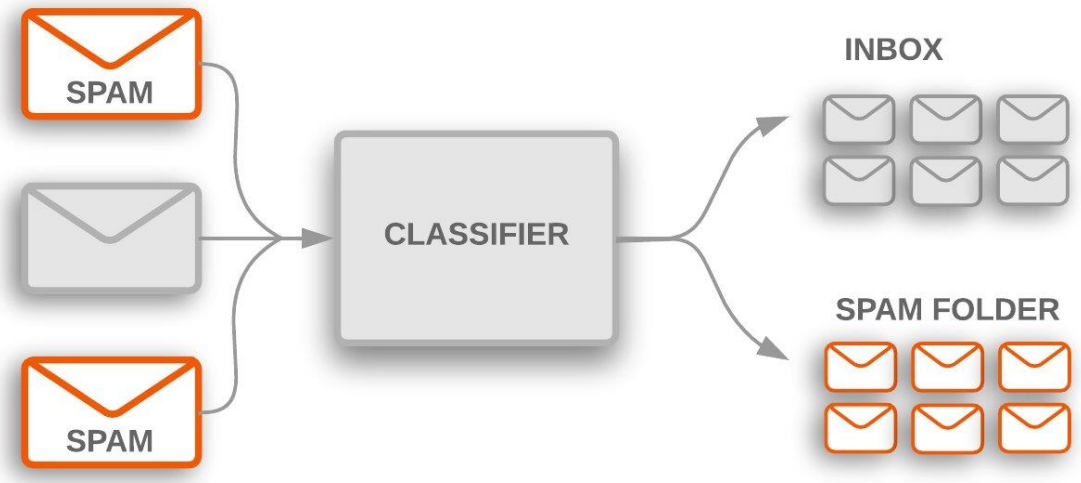

Exemplo: Identificação de animais em imagens

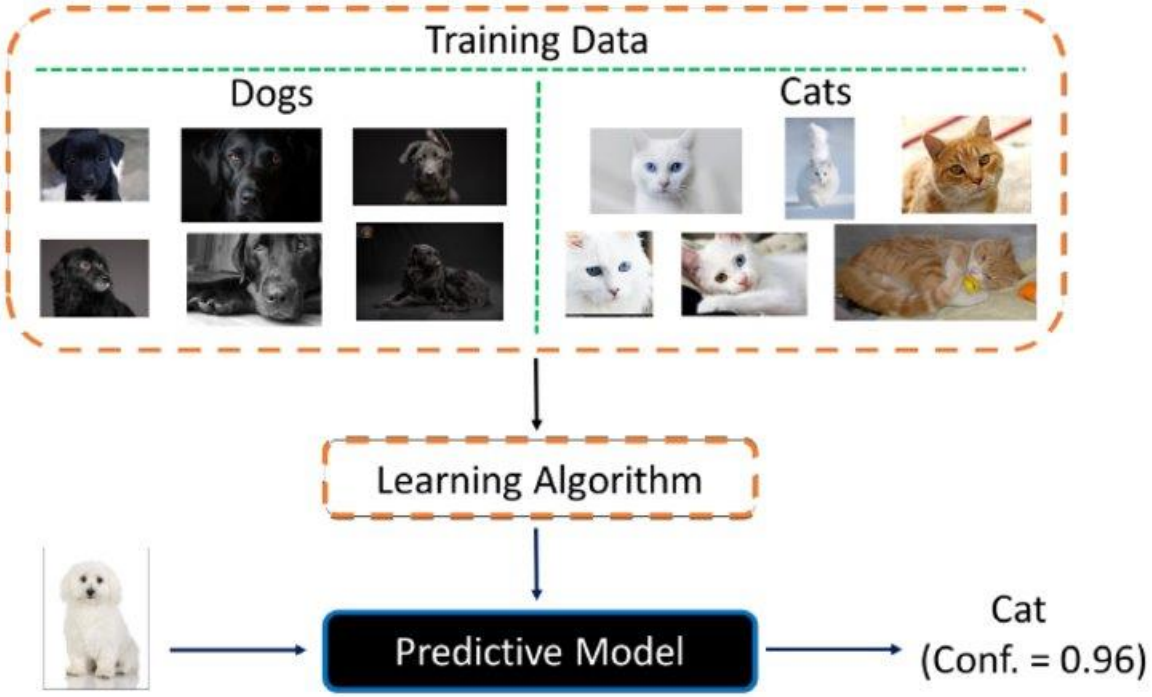

Regressão Logística

Objetivo: A regressão logística é um método estatístico de previsão de resultados binários (0 ou 1) com base numa ou mais variáveis de previsão (*features*).

Estrutura: Função *sigmoid*: A função logística transforma combinações lineares de caraterísticas de entrada numa pontuação de probabilidade que varia entre 0 e 1.

$$y = \frac{1}{1 + e^{-x}}$$

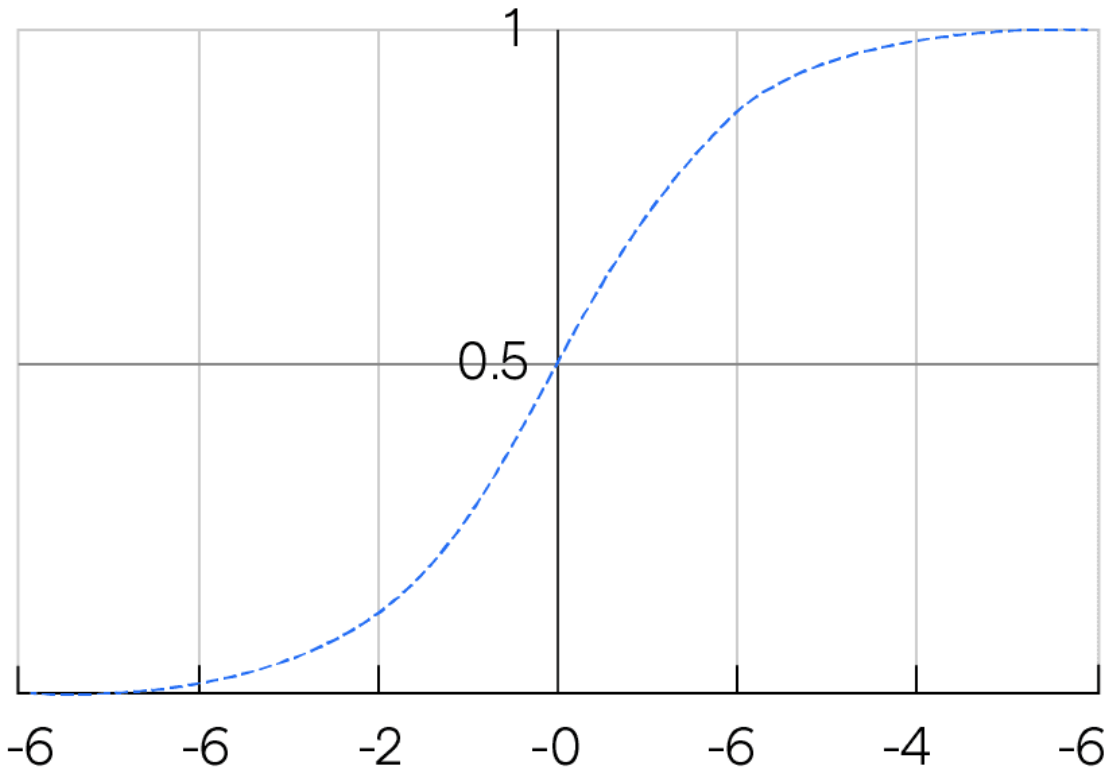

Regressão Logística

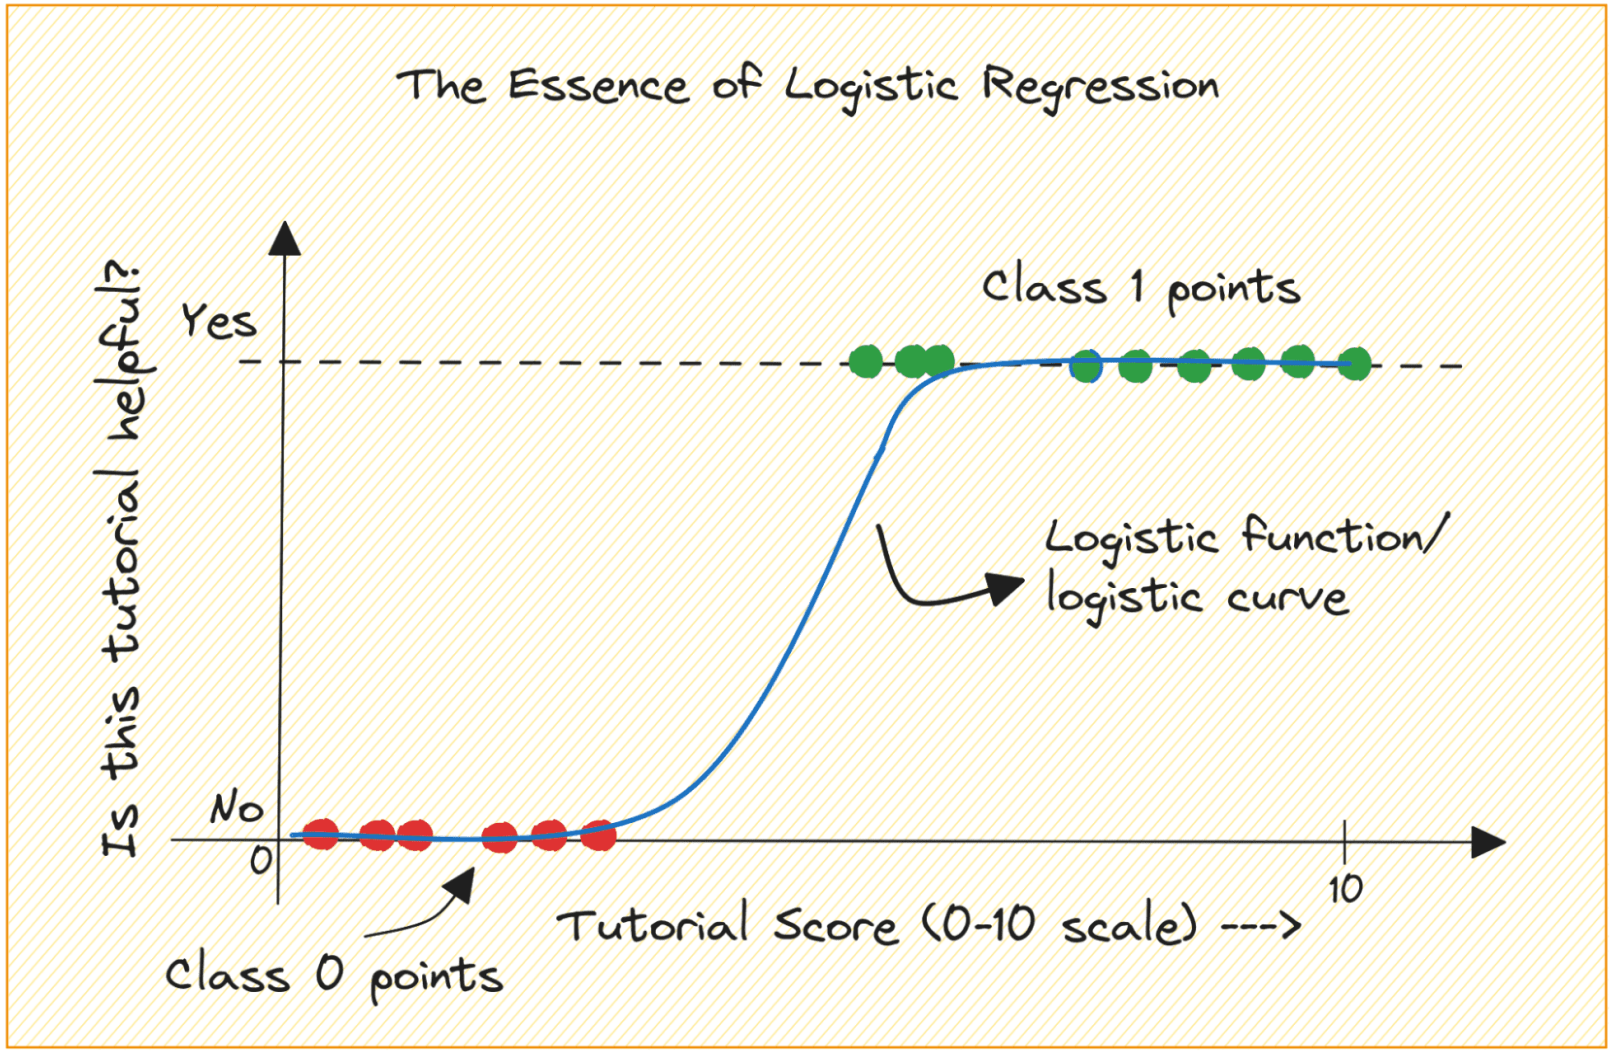

Classificação: Avaliação dos resultados

- Matriz de confusão:

	Actual values		
Predicted values	True Positive (TP)	False Positive (FP)	Sum of predicted Positive
	False Negative (FN)	True Negative (TN)	Sum of predicted Negative
	Sum of actual Positive	Sum of actual Negative	Total set size

- Accuracy: $\frac{TP+TN}{TP+TN+FP+FN}$
- Precisão: $\frac{TP}{TP+FP}$
- Recall: $\frac{TP}{TP+FN}$
- F-Score: $2\frac{Precion \times Recall}{Precion+Recall}$
- True positive rate (TPR): $\frac{TP}{TP+FN}$
- False positive rate (FPR): $\frac{FP}{FP+TN}$

Classificação: Avaliação dos resultados

- Matriz de confusão: Classificação de images em {CAT, NOT CAT}

		Actual values		
		CAT	NOT CAT	
Predicted values	CAT	104 (TP)	23 (FP)	127
	NOT CAT	12 (FN)	110 (TN)	122
		116	133	249

- Accuracy: $\frac{\mathrm{TP+TN}}{\mathrm{TP+TN+FP+FN}} =$
- Precisão: $\frac{\mathrm{TP}}{\mathrm{TP+FP}} =$
- Recall: $\frac{\mathrm{TP}}{\mathrm{TP+\ FN}} =$
- F-Score: $2\,\frac{\mathrm{Precion \times Recall}}{\mathrm{Precion+Recall}} =$
- True positive rate (TPR): $\frac{\mathrm{TP}}{\mathrm{TP+FN}} =$ Recall
- False positive rate (FPR): $\frac{\mathrm{FP}}{\mathrm{FP+TN}} =$

Classificação: Avaliação dos resultados

- Curva ROC: é o rácio entre a taxa de verdadeiro positivo (TPR – True positive rate) e a taxa de falso positivo (FPR – false positive rate)

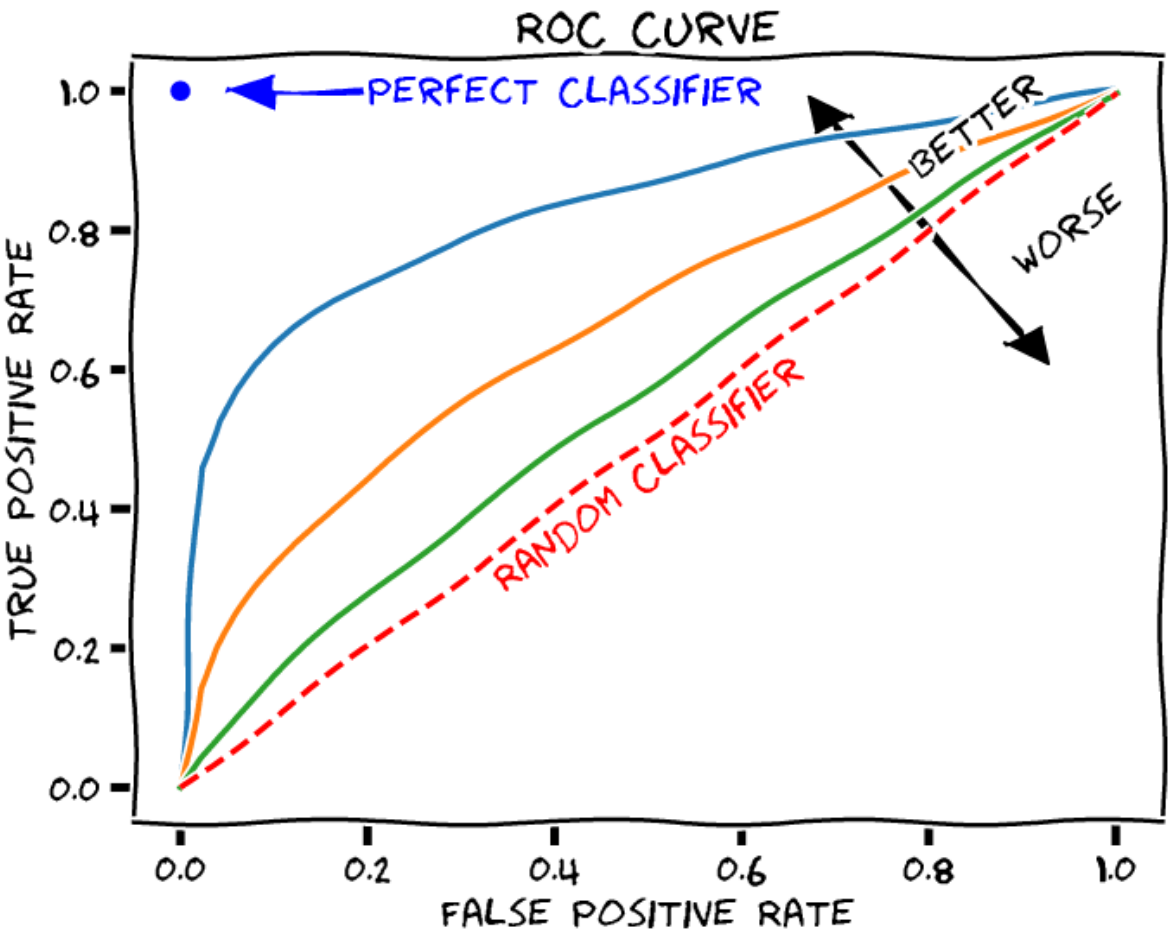

Escolha das *features* e árvores de decisão

Escolha das features

- As árvores de decisão testam todas as features, e selecionam apenas as que mais influenciam a variável target.
- Outros algoritmos, como a regressão logística e a regressão linear, usam as features que lhes forem dadas.
- É importante selecionar apenas features que se relacionem com a target:
  - Remover as que só adicionam ruído
  - Remover as que têm uma correlação >=0.9 com outra feature (features equivalentes)

Árvores de Decisão

Variável target:
contínua ou **categórica**

És fit?

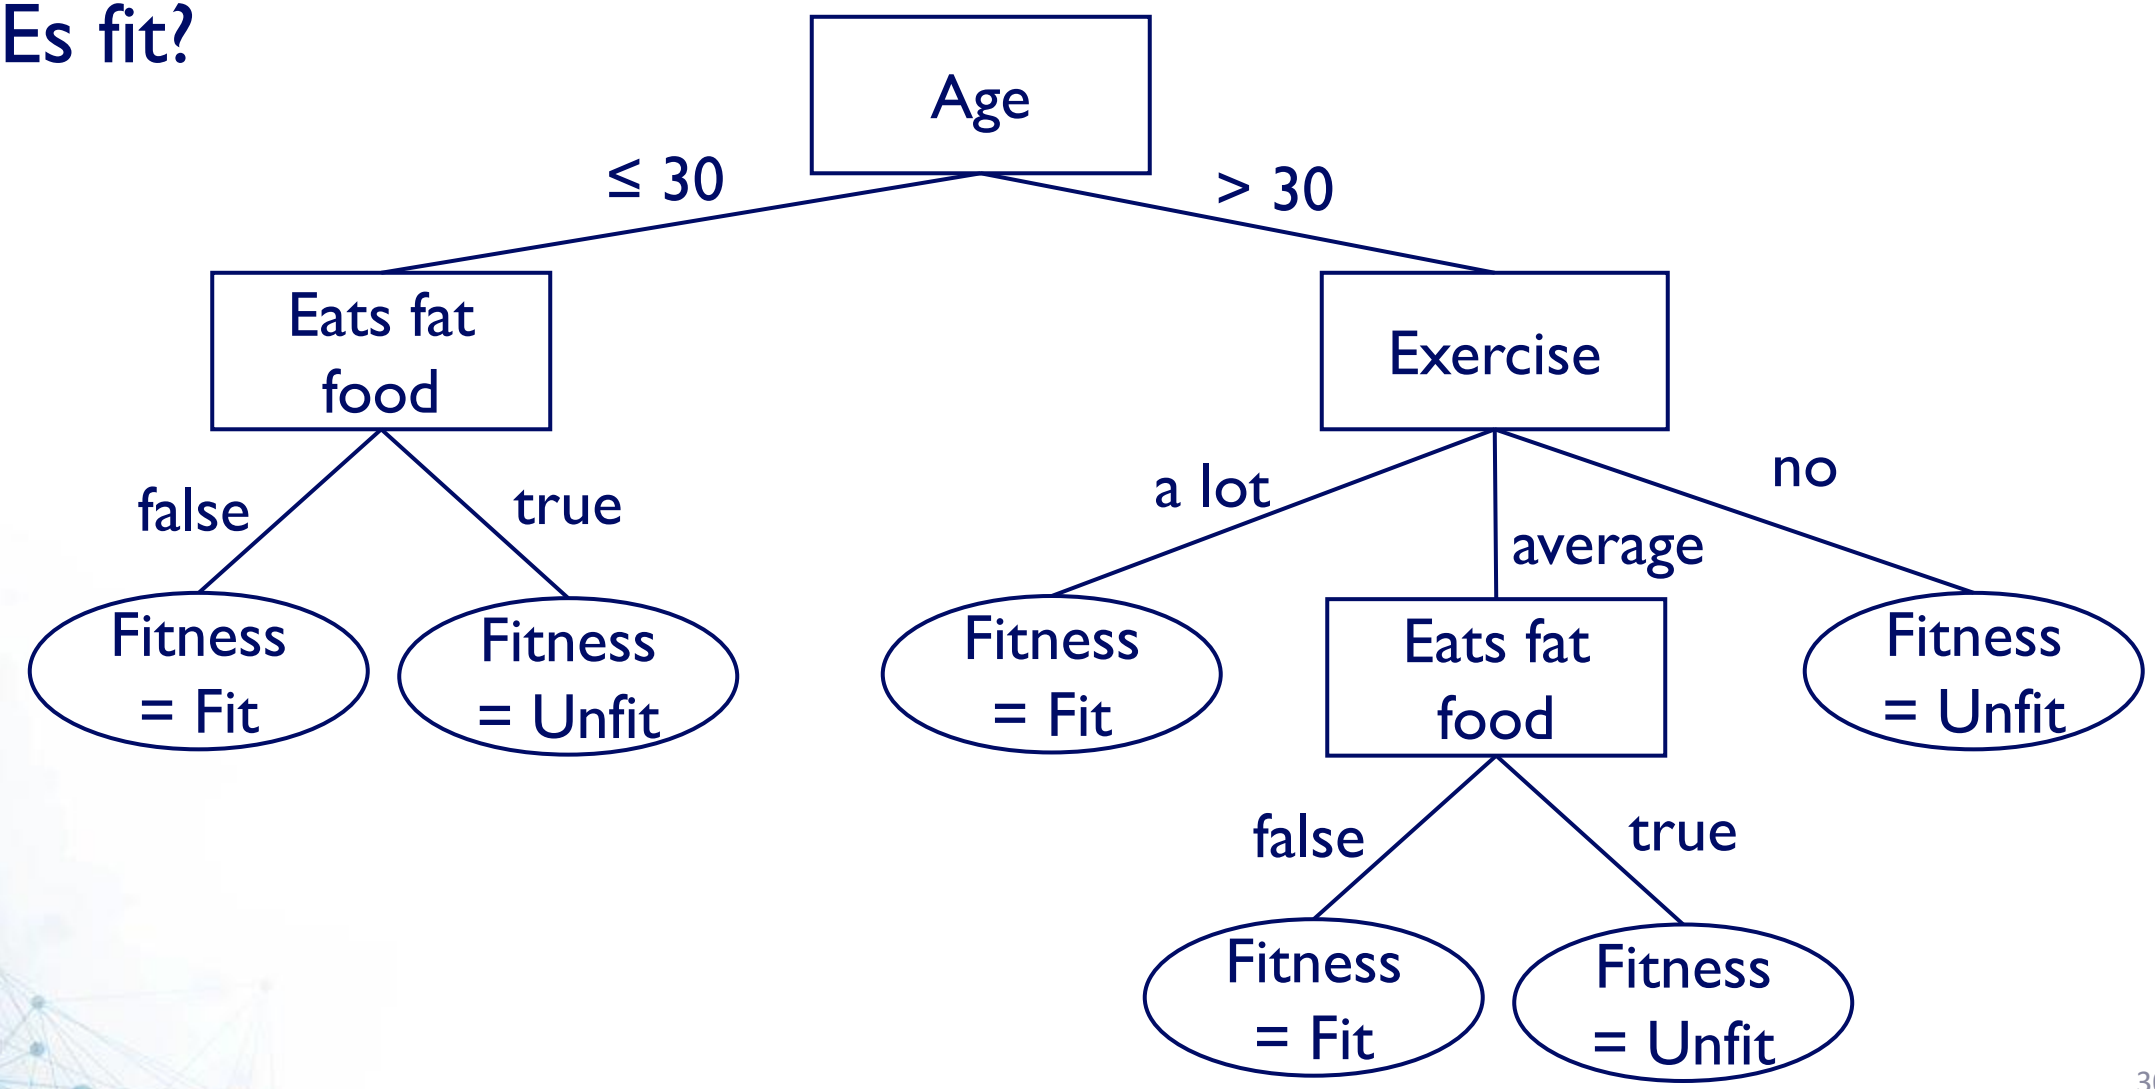

Árvores de Decisão

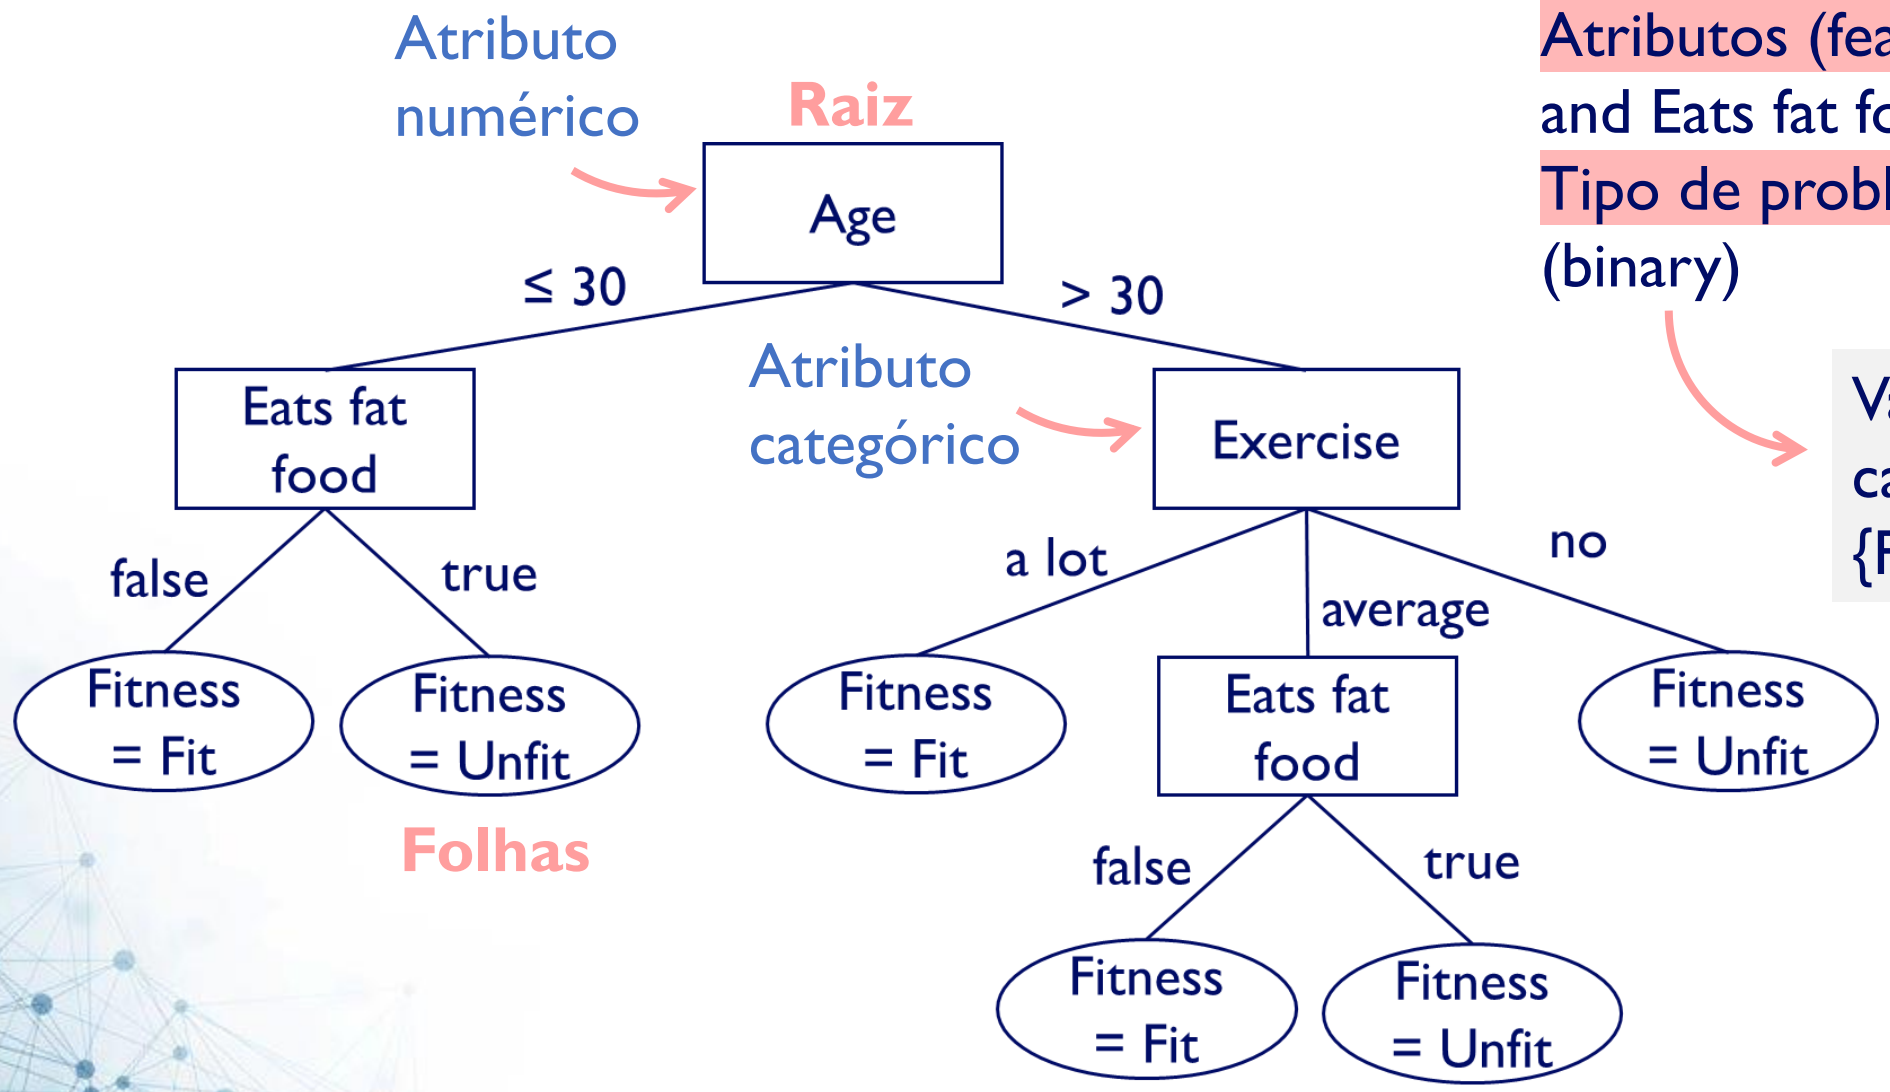

Atributos (features): Age, Exercise and Eats fat food

Tipo de problema: Classification (binary)

Variável target categórica binária: {Fit, Unfit}

Árvores de Decisão

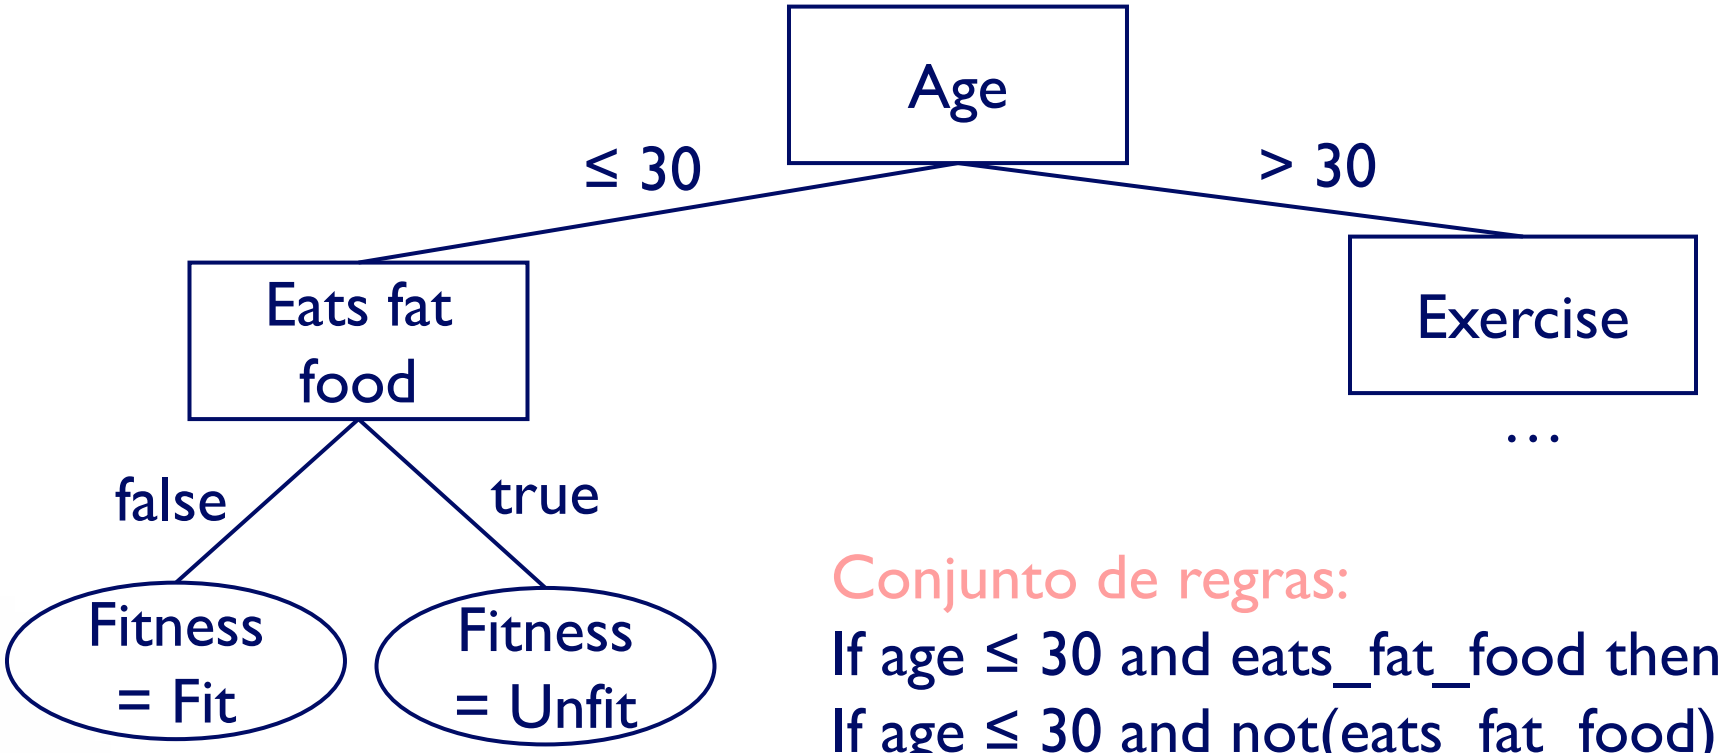

Conjunto de regras:

If age ≤ 30 and eats_fat_food then fitness = unfit

If age ≤ 30 and not(eats_fat_food) then fitness = fit

If age > 30 and exercise and… then …

Árvores de Decisão

Tipo de problema: Regressão

Prevê uma variável numérica continua: Hours Played

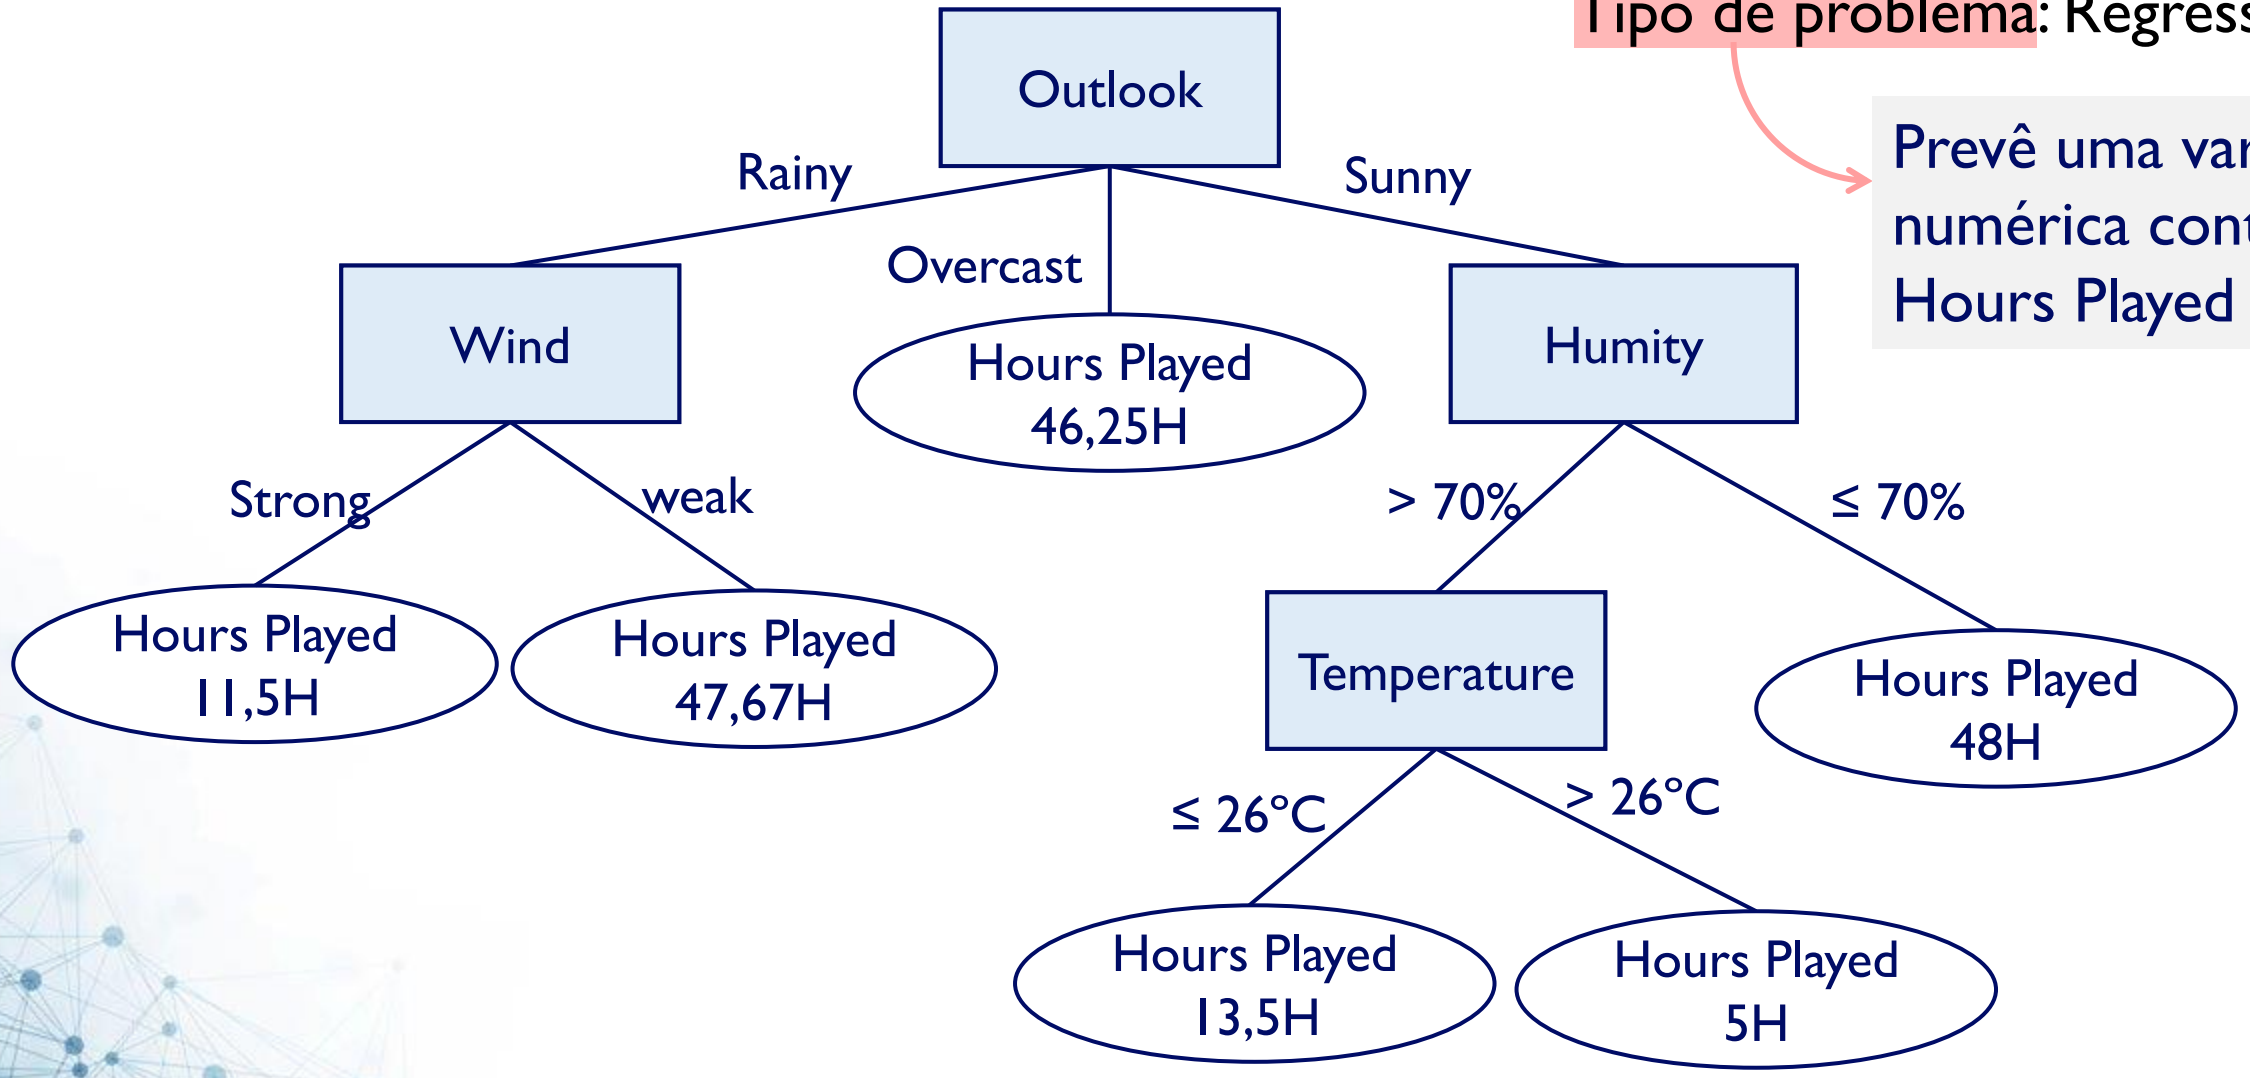

Árvores de Decisão

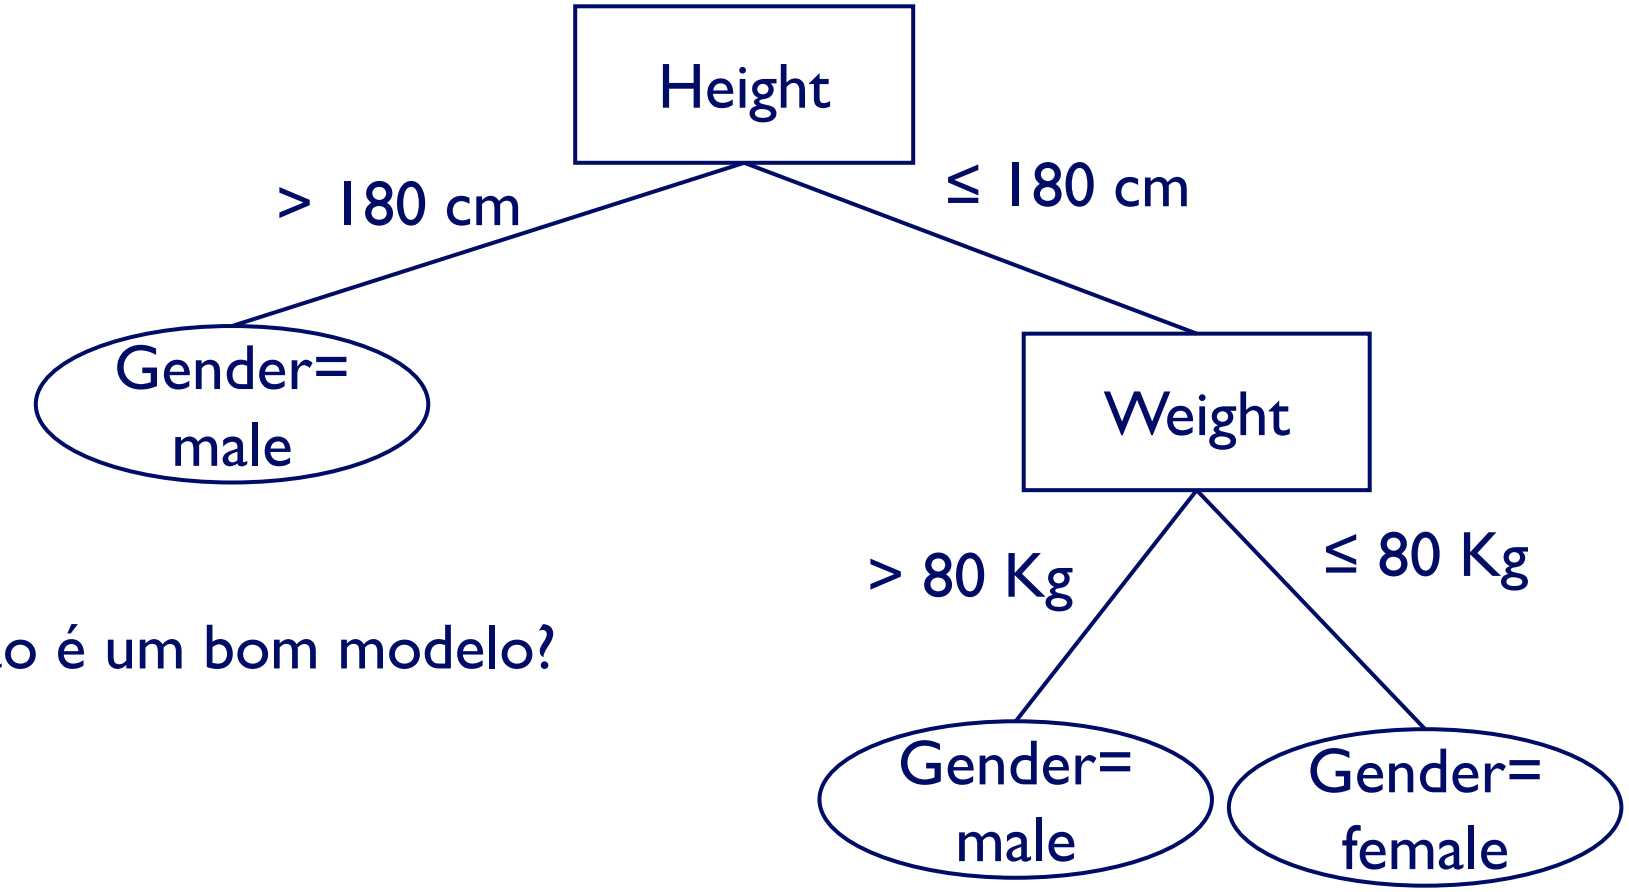

Esta árvore de decisão é um bom modelo?

Árvores de Decisão

	Height > 180 cm	Weight > 80 Kg	Gender
1	No	No	Female
2	No	No	Female
3	No	No	Female
4	No	No	Female
5	No	Yes	Male
6	Yes	Yes	Male
7	Yes	Yes	Male
8	Yes	No	Male
9	Yes	No	Male
10	Yes	No	Male

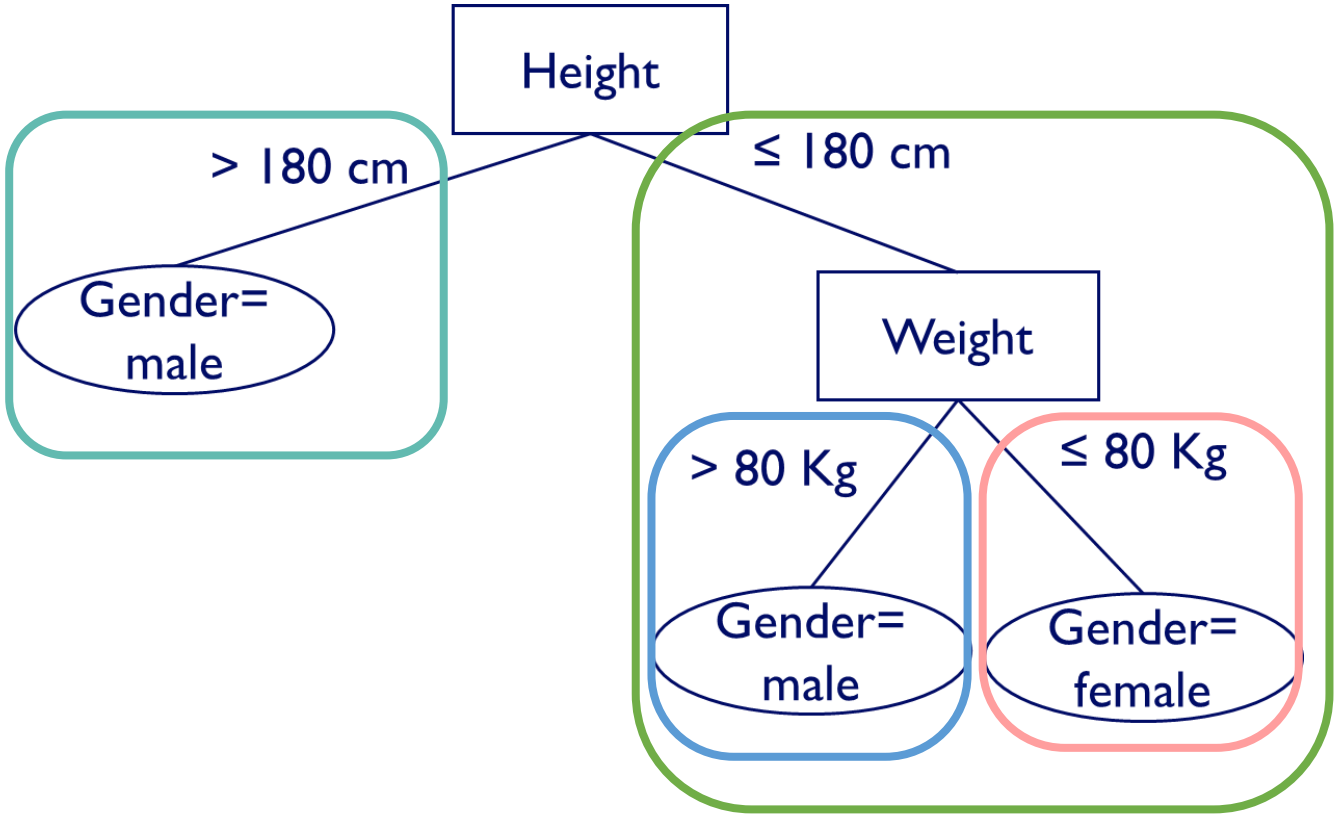

Esta árvore de decisão é um bom modelo?

Árvores de Decisão

- Um nó interior na árvore representa um atributo que foi testado com os restantes e **foi o vencedor** como o **atributo mais preditivo** a este nível (usando os rótulos supervisão)

- Cada ramo (aresta) representa um valor distinto do atributo

- Uma vez construída, a partir do início da árvore (raiz), define-se um trajeto - através dos nós e ramos - que termina num nó terminal (dito folha): o resultado (outcome) da previsão ou classe (da classificação)

Exemplos Orange

Regressão: Orange

Dataset: advertising.csv

Cria um modelo de regressão linear para prever as vendas, através do investimento em publicidade de TV, radio, jornais (newspaper) e redes sociais (social media). Usa k-cross validation (k=10). Visualiza as métricas de avaliação.

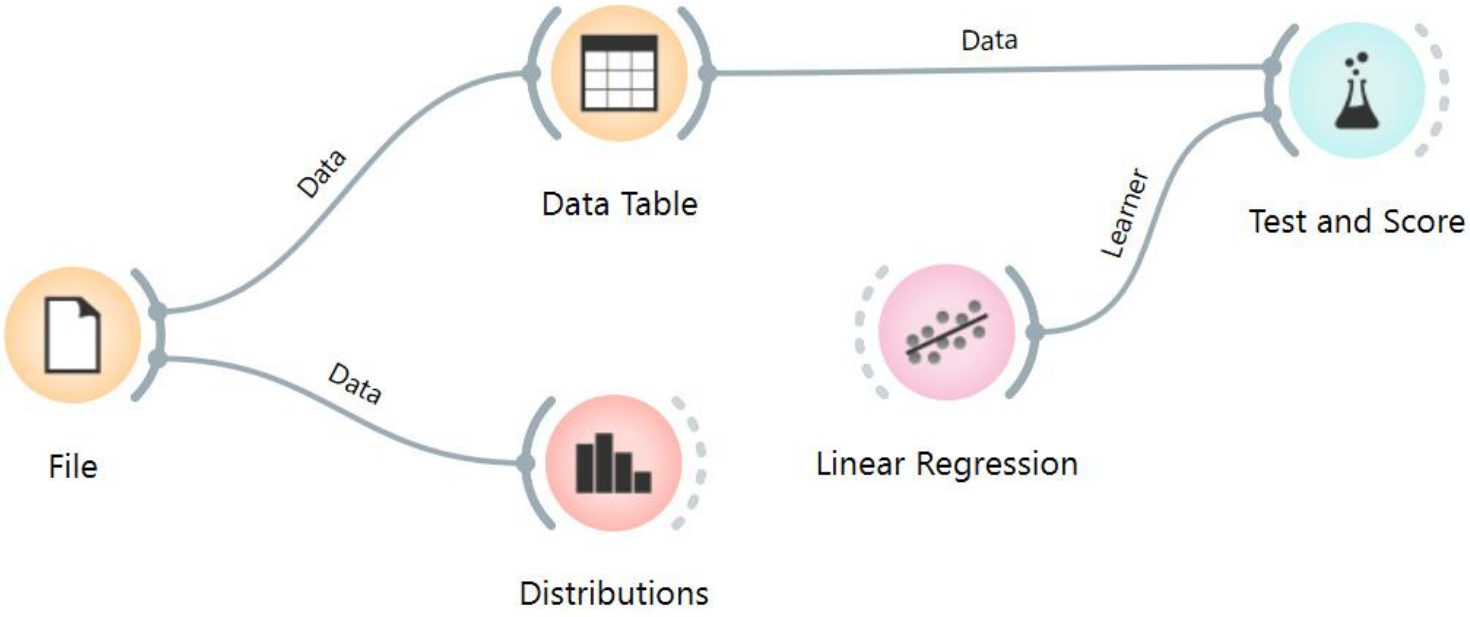

Regressão: Orange

Dataset: advertising.csv

Usando o widget “scatter plot” visualiza como é que as variáveis independentes se relacionam com a variável target. Escolhe as que mais se relacionam e repete a previsão de vendas. Os resultados foram melhores?

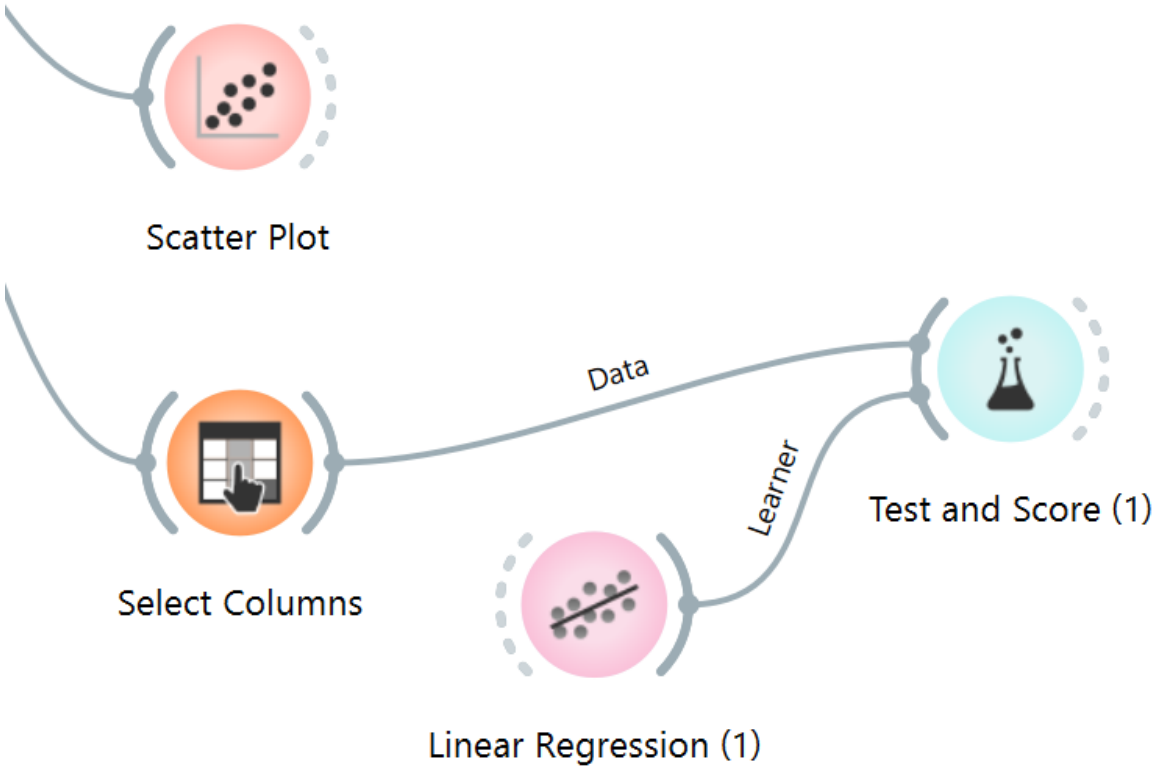

Classificação: Orange

Dataset: zoo (no Orange)

Crie um modelo de classificação usando o algoritmo das árvores de decisão para classificar os animais consoante o seu *type* (divide o dataset em 70/30 para treino e usa 10% para teste por oclusão). Quais as variáveis que mais influenciam o *type* dos animais?

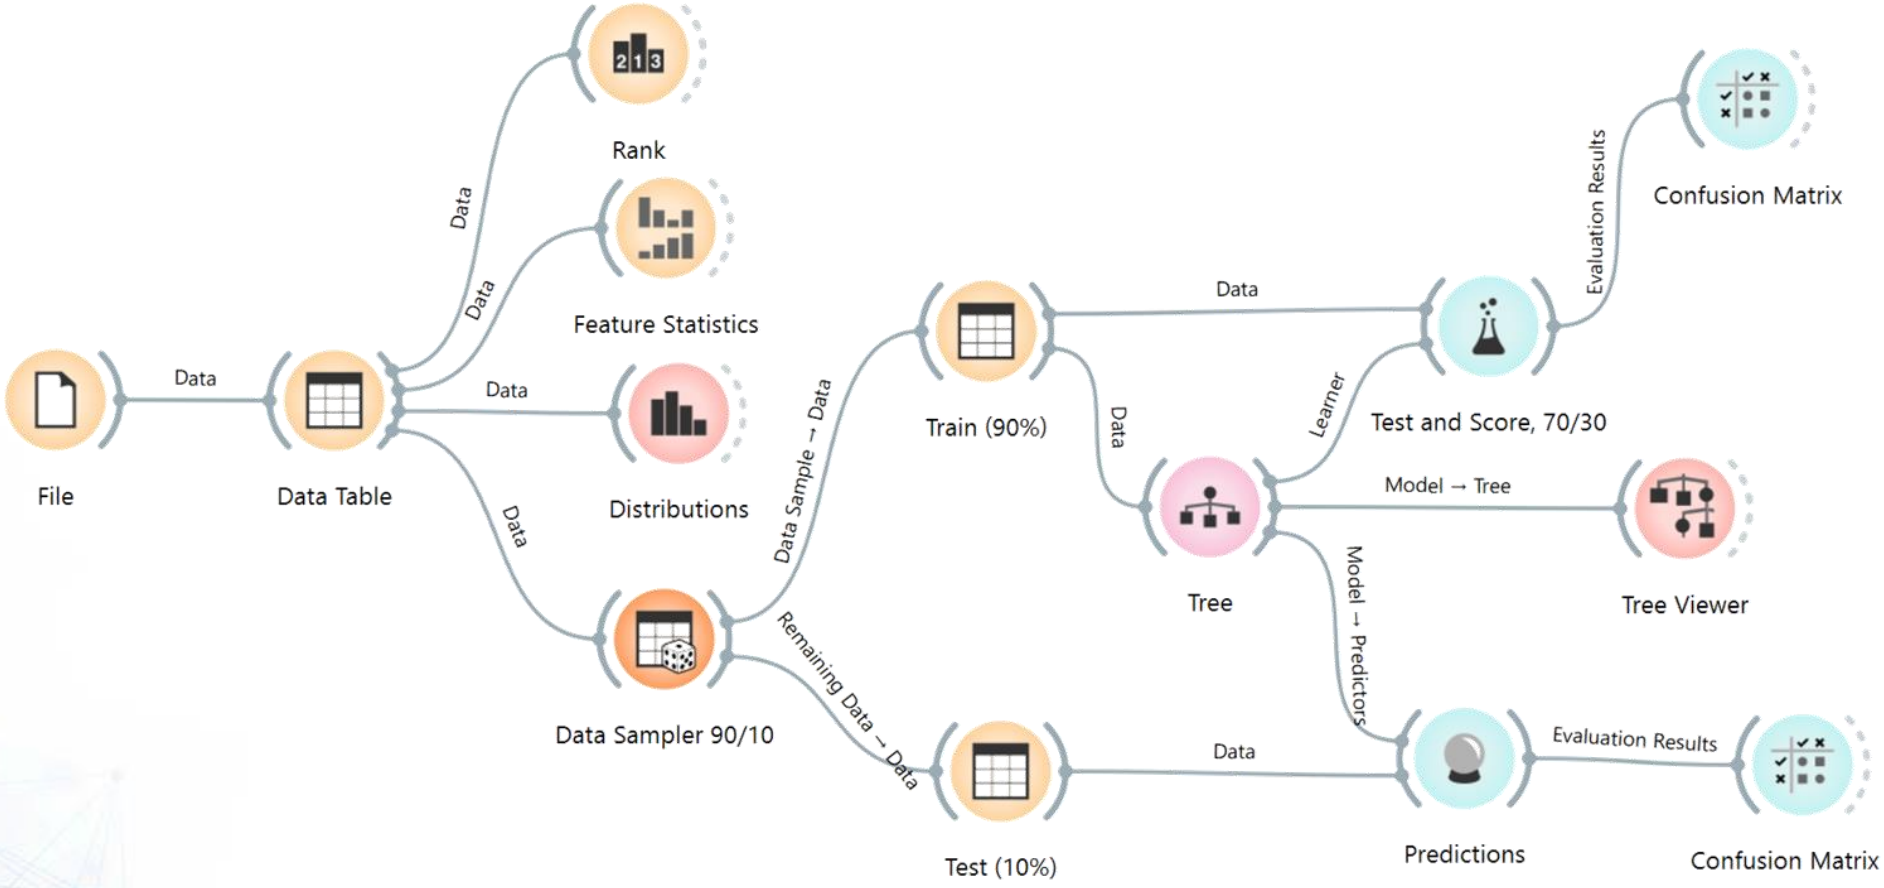

Classificação: Orange

Dataset: zoo (no Orange)
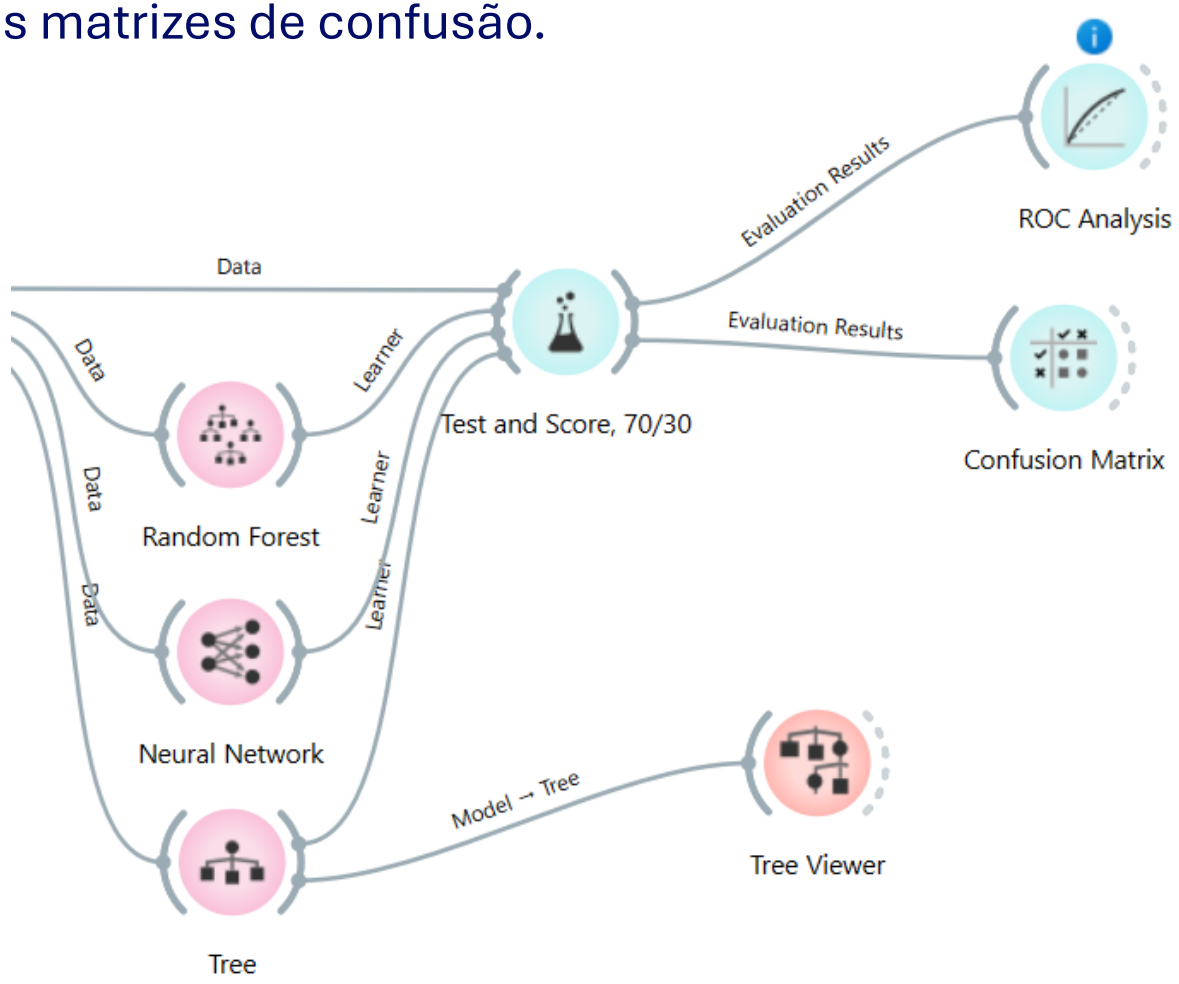
Crie mais modelos usando outros algoritmos de classificação.
Compare os vários modelos usando a curva ROC, veja também as métricas de avaliação no widget *Predictions* e as matrizes de confusão.