iscte

INSTITUTO UNIVERSITÁRIO DE LISBOA

Introdução à Ciência de Dados

Aula 08

Docentes

Ana Rita Peixoto

Miguel Teodoro

Martim Santos

2025/2026

CRISP-DM #recap

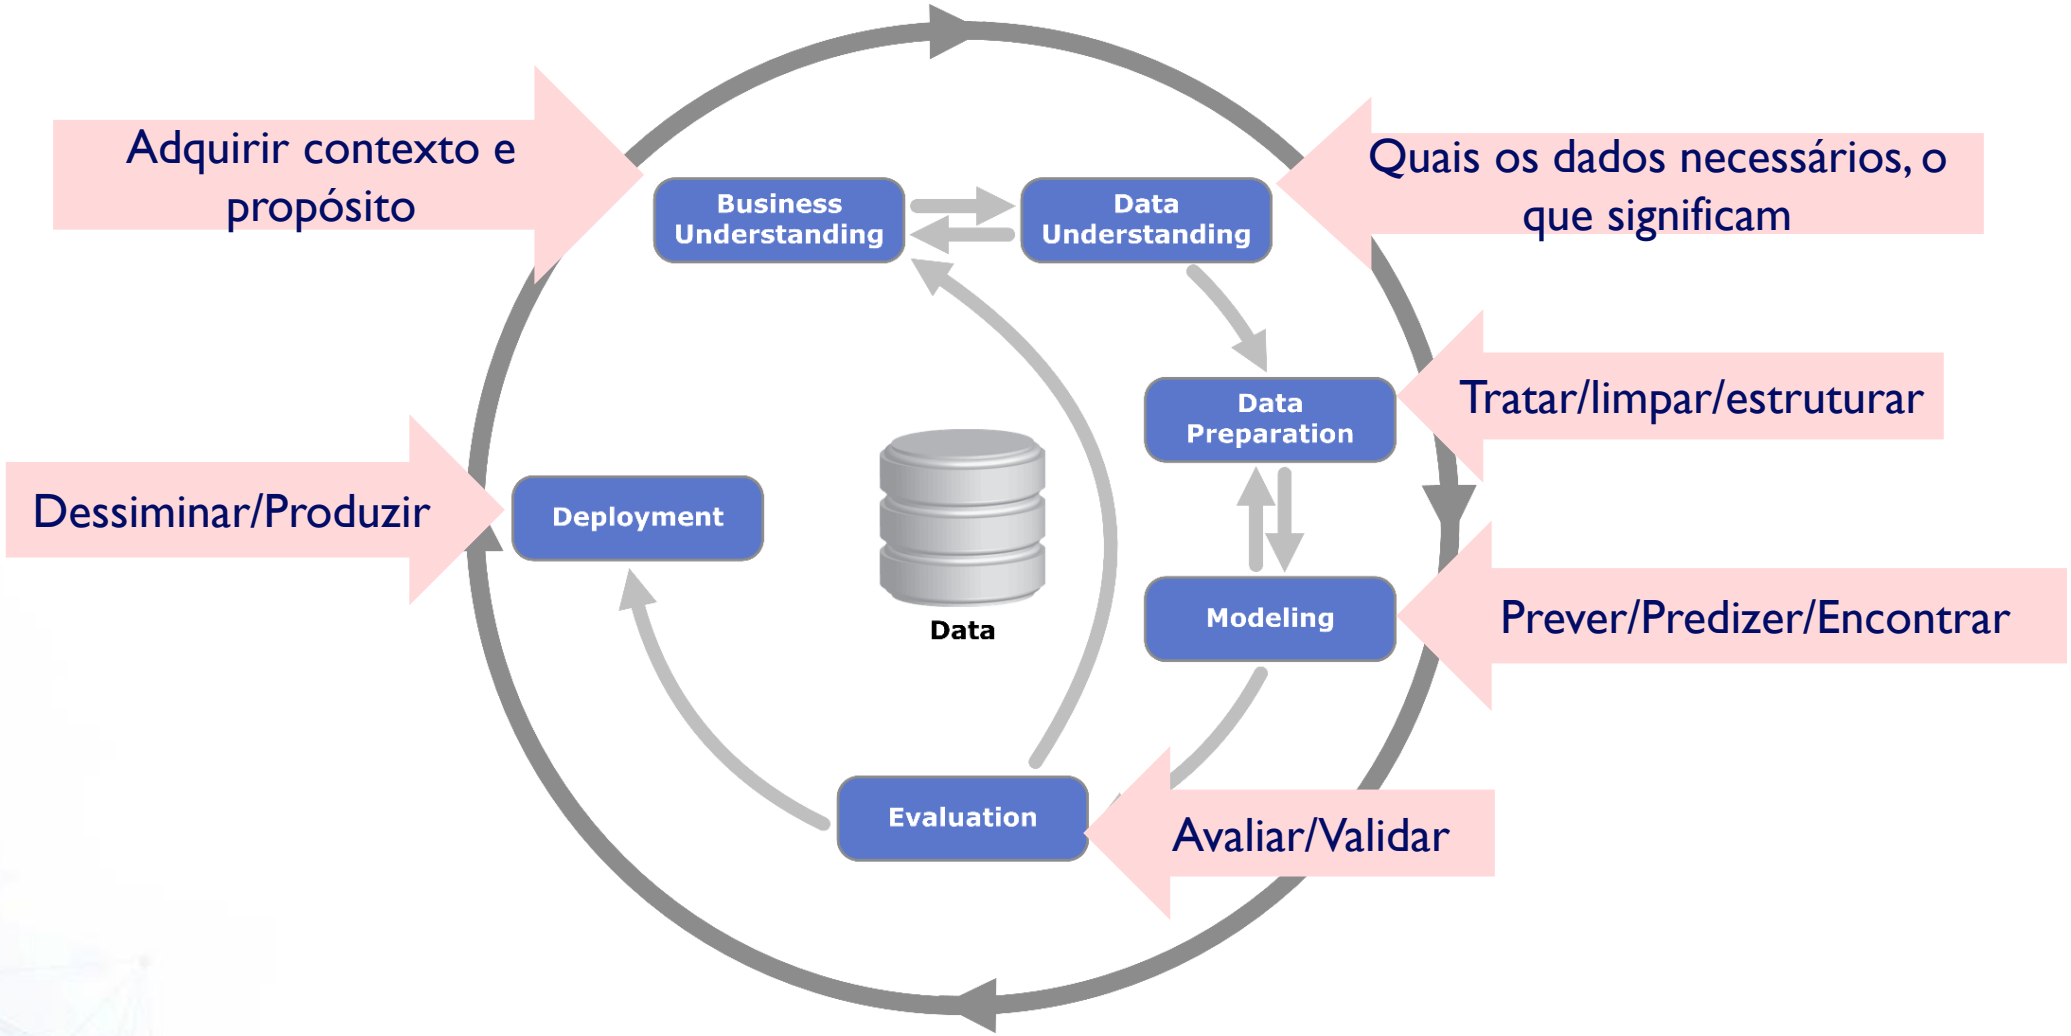

Principais tarefas em CD #recap

Aprendizagem

Cada dado possui um rótulo (label) a indicar que tipo de exemplo é

Supervisionadas
- Prever/Predizer

Classificação
Variáveis categóricas

Regressão
Variáveis quantitativas

Não Supervisionadas
- Descrever

Clustering

Associar

Sequenciar

Aprendizagem não supervisionada

- A aprendizagem não supervisionada é utilizada para encontrar padrões intrínsecos (estruturas, ligações) em dados (não rotulados/anotados).
- Estes padrões explicam o comportamento dos dados dependendo de algumas variáveis

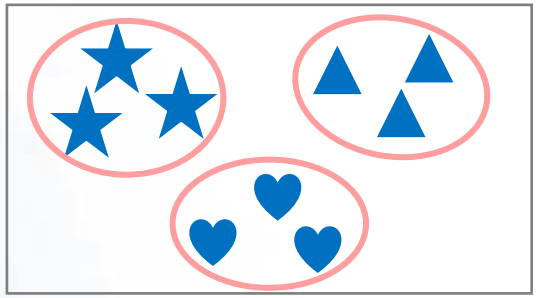

Clustering:
Identificar grupos semelhantes

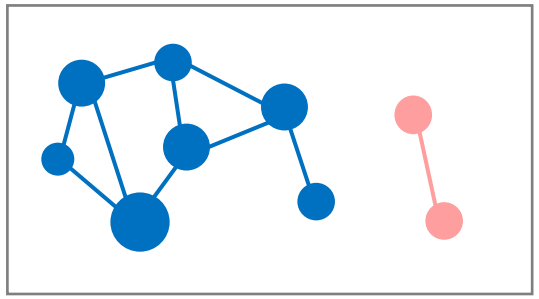

Anomaly Detection:
Identificar anomalias

Aprendizagem não supervisionada: Mall Customers

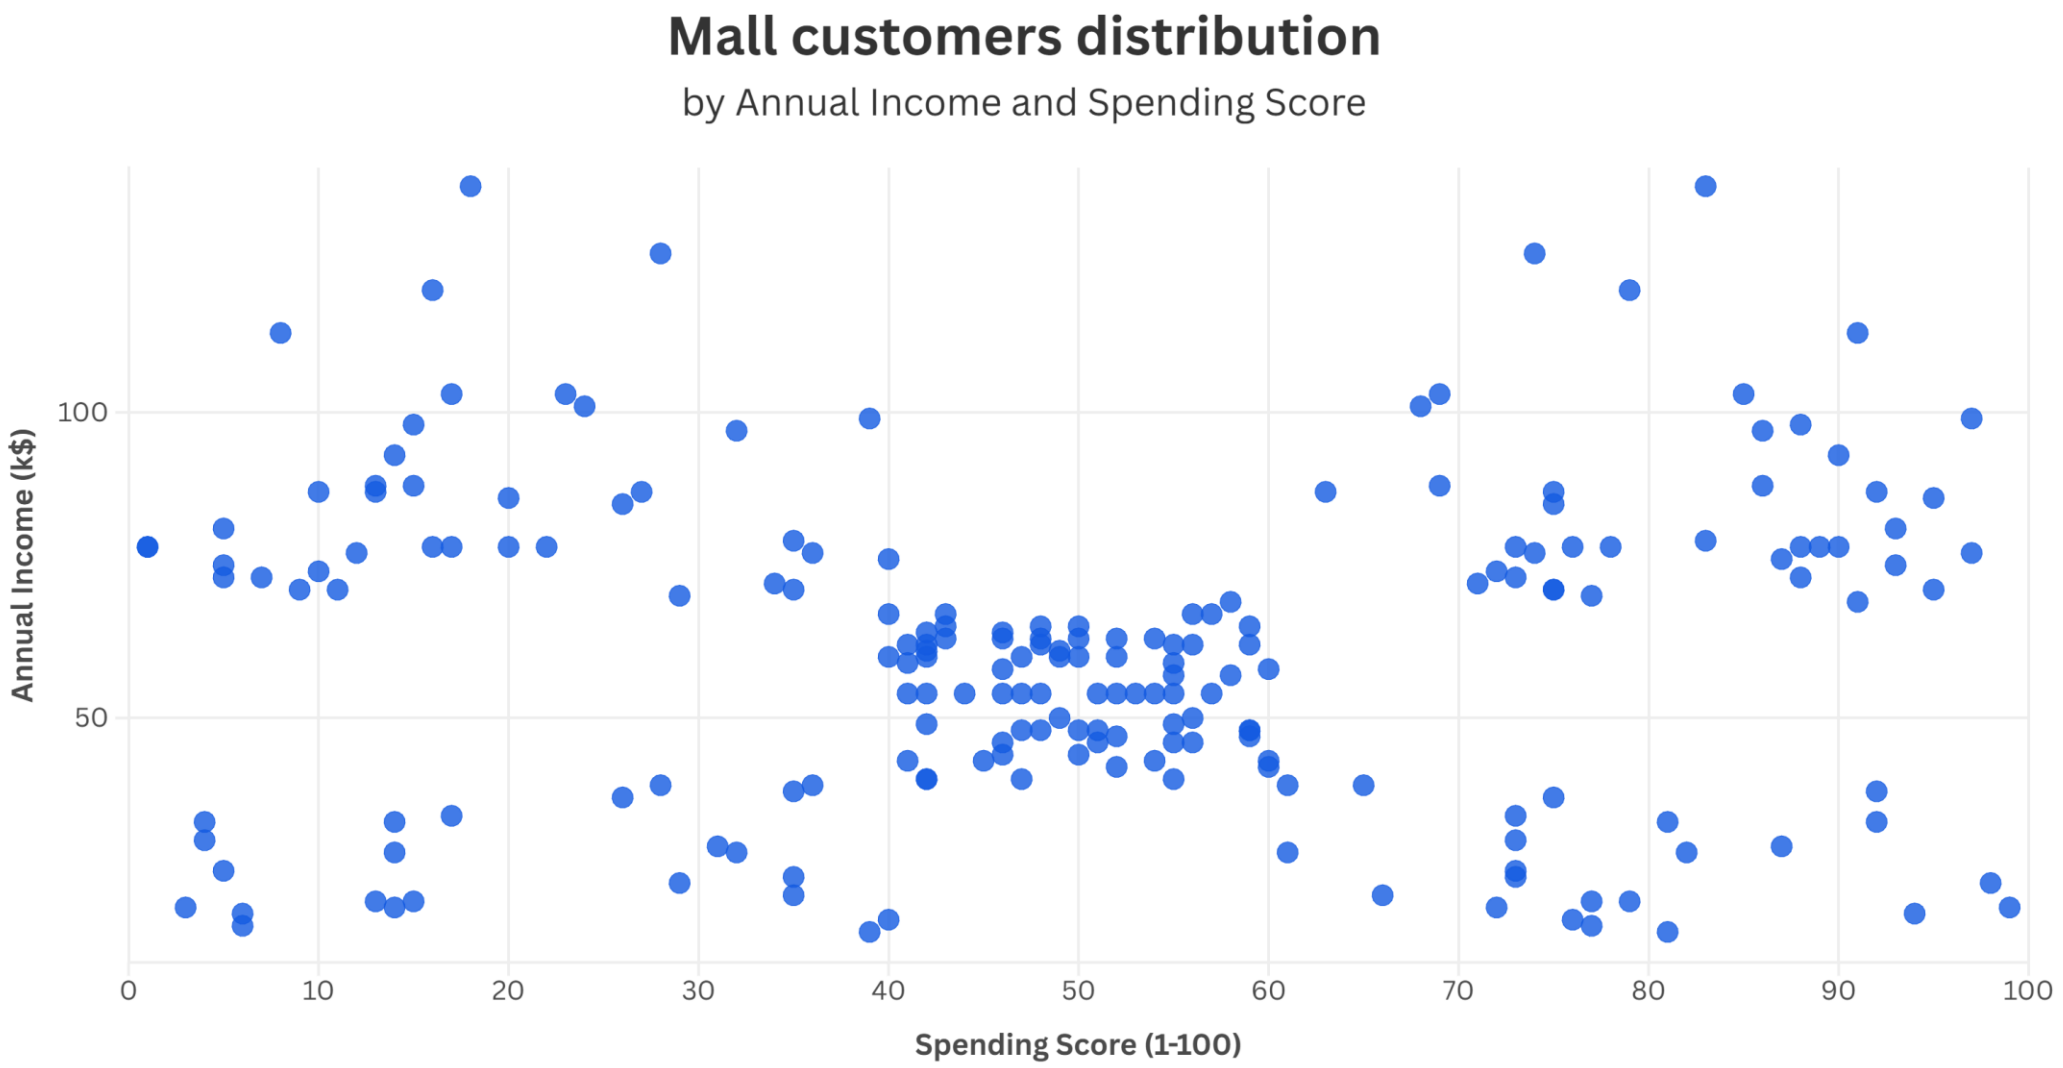

Existem alguns grupos?

Aprendizagem não supervisionada: Mall Customers

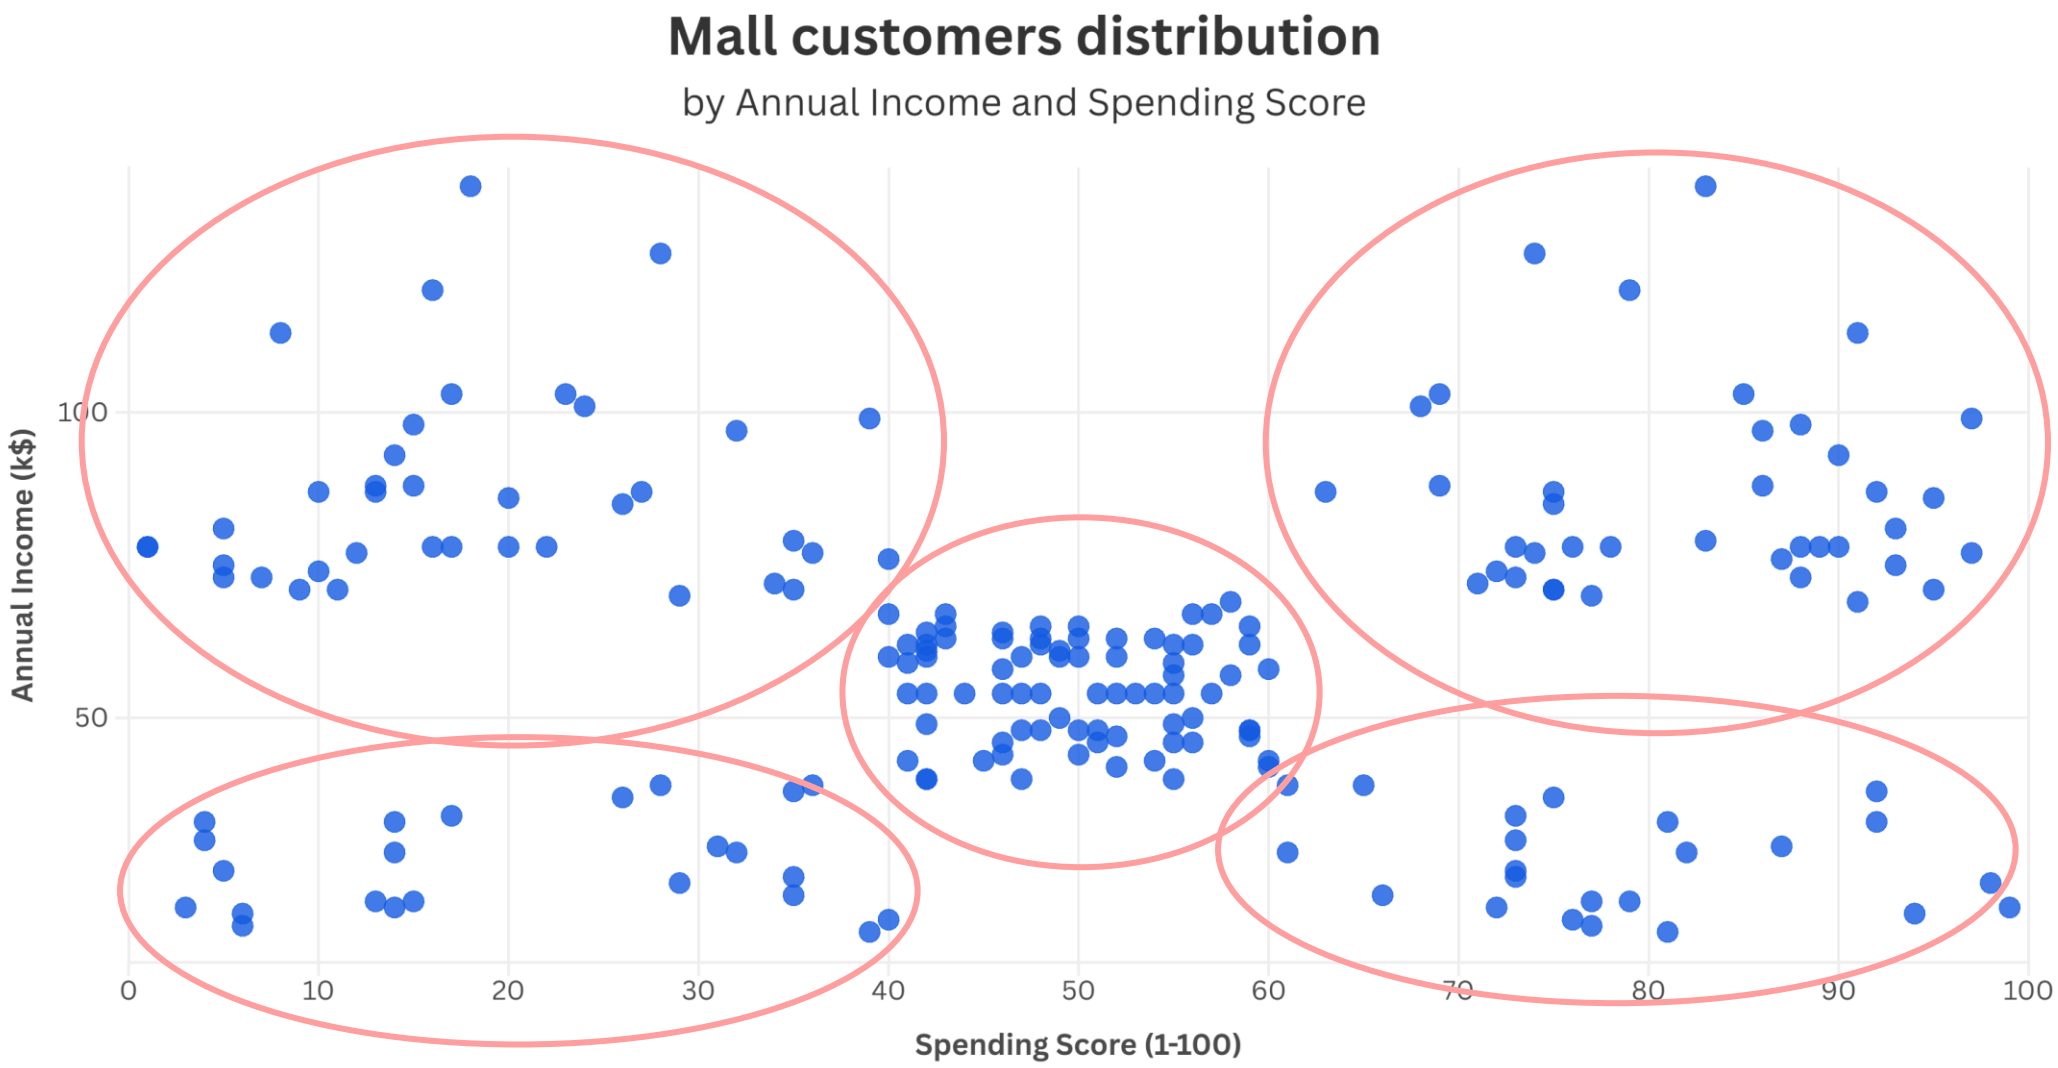

Existem alguns grupos?

Clustering Hierárquico:

Objetivo: Utilizado para agrupar pontos de dados semelhantes em clusters numa estrutura hierárquica. Pode ser representado como um diagrama em forma de árvore, chamado dendrograma.

Passos do Algoritmo:

- Calcular a Matriz de Distâncias: Calcular a distância (semelhança) entre todos os pares de pontos de dados.
- Unir Clusters: Encontre os dois clusters mais próximos e una-os.
- Atualizar a Matriz de Distâncias: Recalcule as distâncias entre o cluster recém-formado e os restantes clusters.
- Repetir: Repita os passos 2 e 3 até que todos os pontos de dados sejam unidos num único cluster ou até que o número de clusters desejado seja atingido.

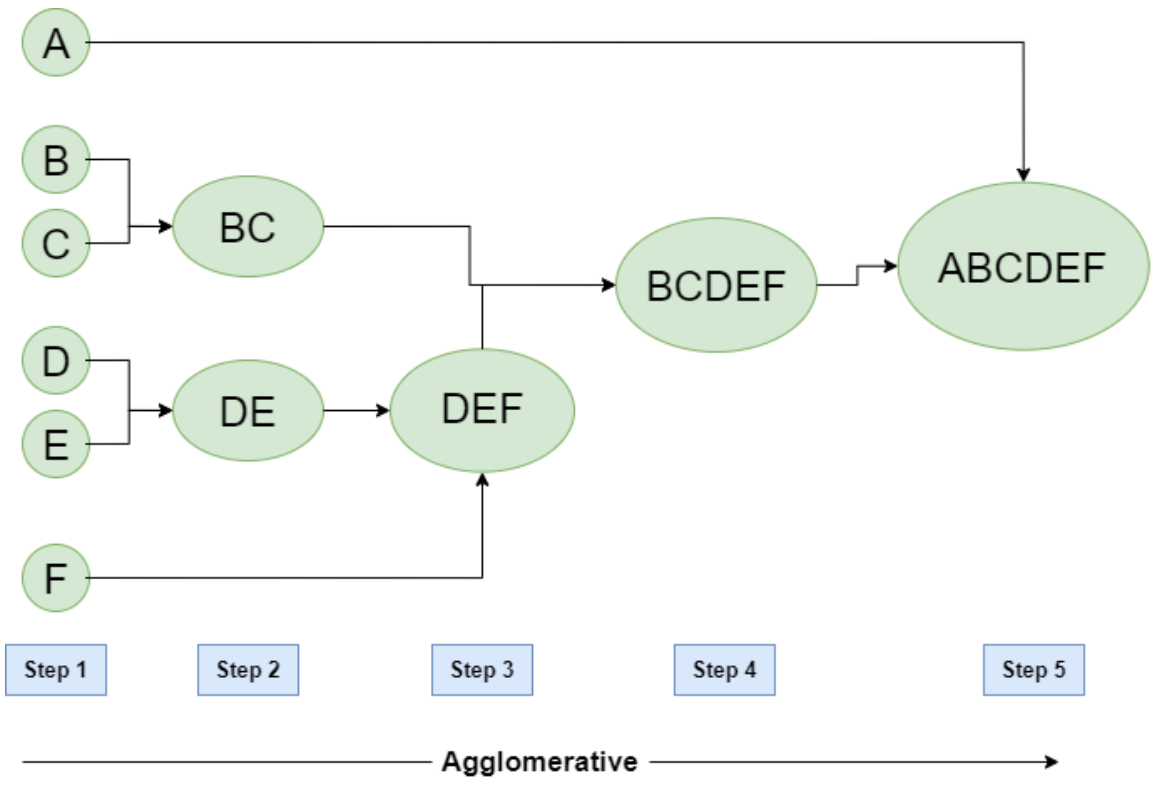

Clustering Hierárquico:

the value of the linkage criterion between {1,2} and {3,4} is C, they are merged third

the value of the linkage criterion between 3 and 4 is B, they are merged second

the value of the linkage criterion between 1 and 2 is A, they are merged first

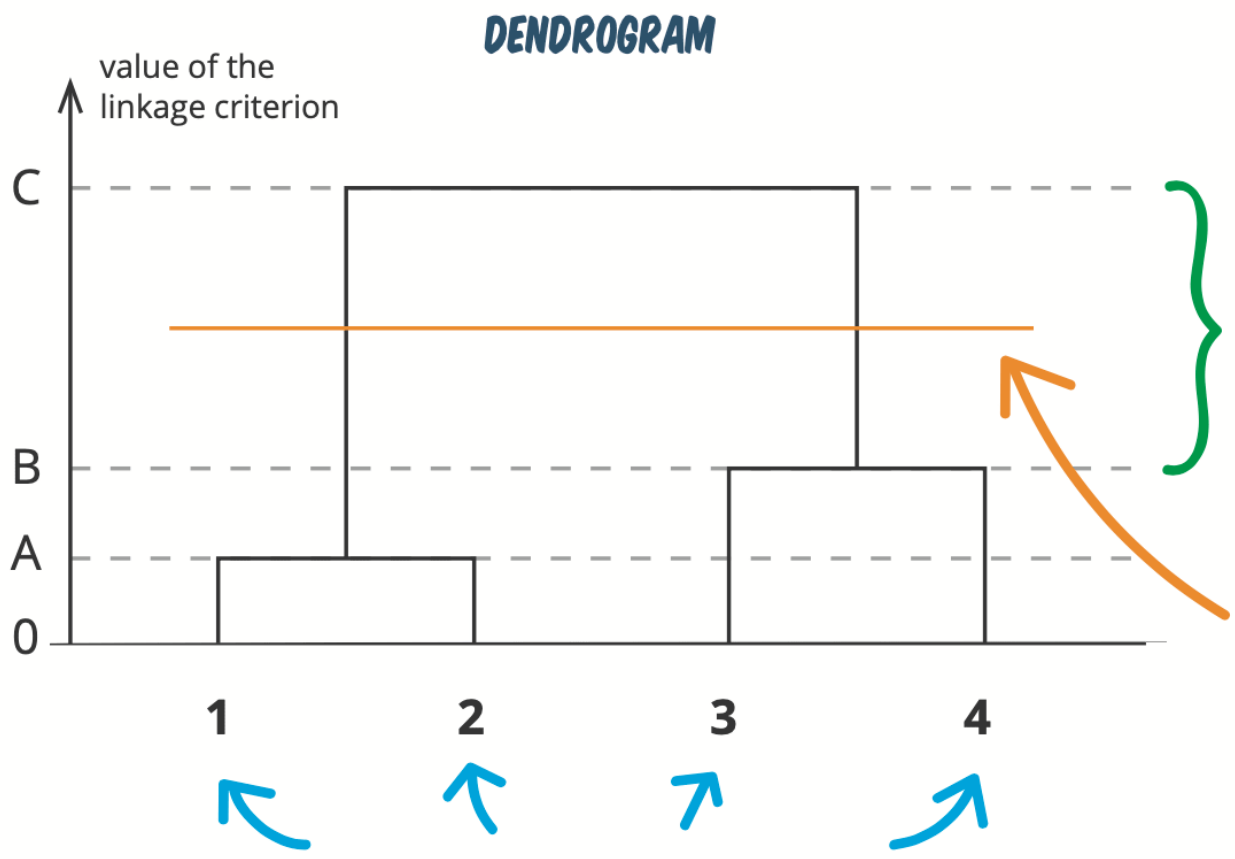

the gap between B and C is the largest (much larger than the gap between 0 and A or the gap between A and B

the "cut" associated with the largest gap generates two clusters: {1,2} and {3,4}

the 4 points to be clustered

Clustering Hierárquico:

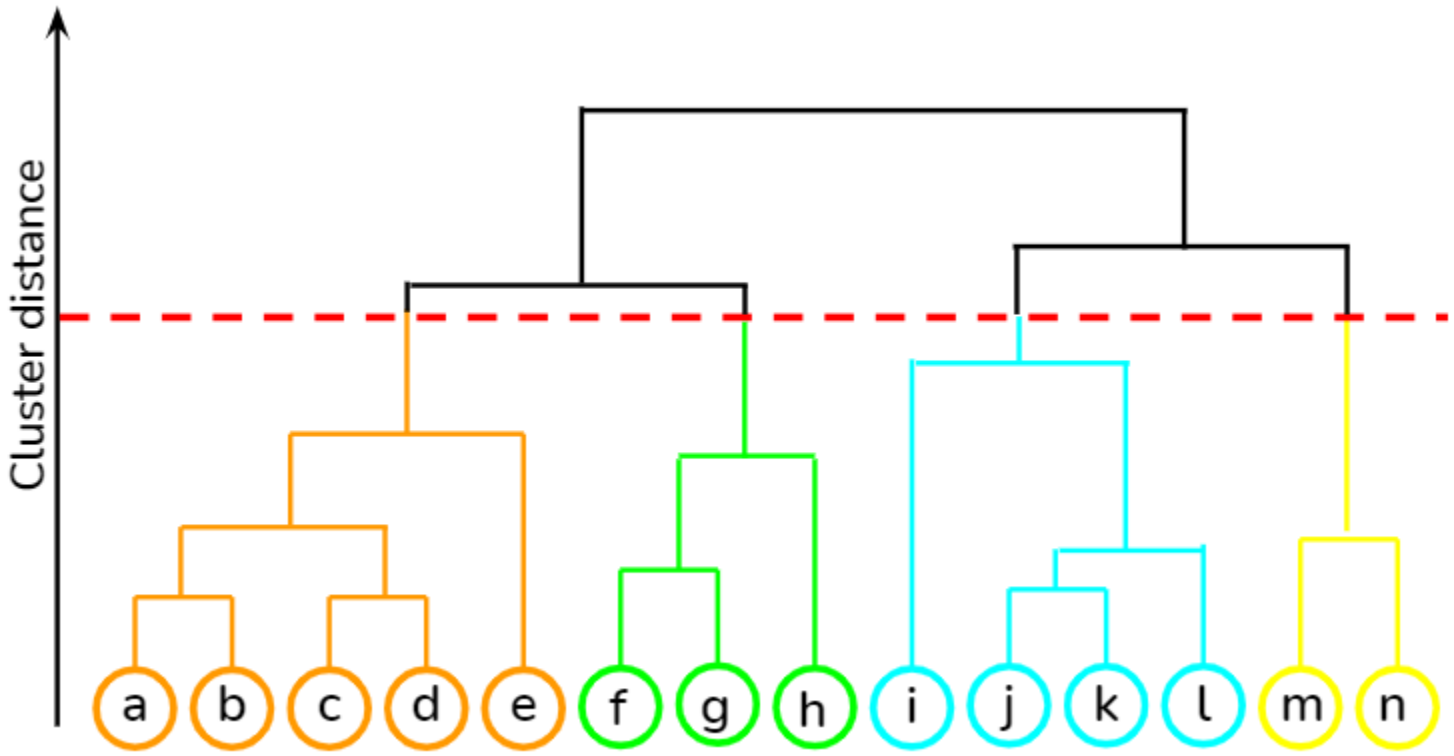

Tipo de ligação:

- **Ward:** minimiza a soma dos quadrados das diferenças dentro de todos os clusters.
- **Complete:** minimiza a distância máxima entre as observações dos pares de clusters.
- **Average:** minimiza a média das distâncias entre todas as observações de pares de clusters.
- **Single** minimiza a distância entre as observações mais próximas de pares de clusters.

https://scikit-learn.org/stable/modules/clustering.html

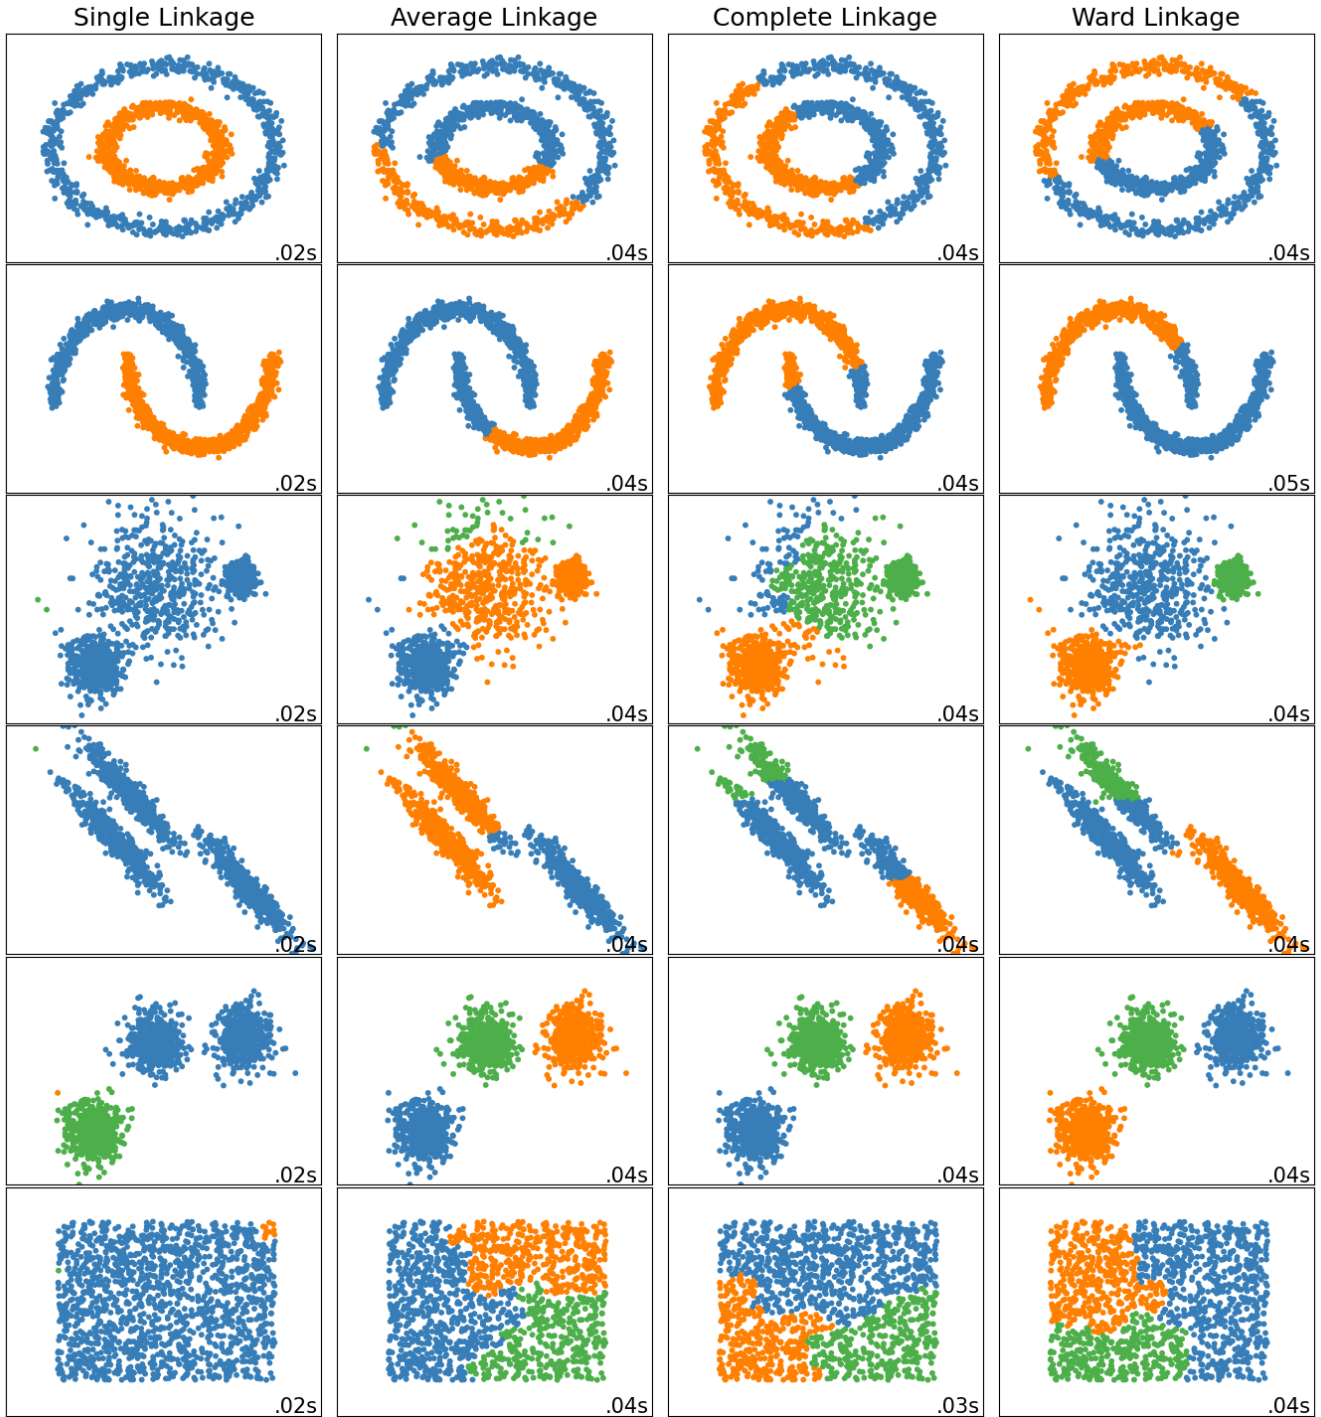

K-means Clustering

Objetivo: Utilizado para agrupar pontos de dados semelhantes em clusters. Essencialmente, trata-se de um agrupamento de elementos com base nas suas semelhanças e diferenças.

Passos do Algoritmo:

- Inicialização: Escolhe k os centróides iniciais aleatoriamente a partir dos pontos de dados.
- Passo de Atribuição: Atribui cada ponto de dados ao centroide mais próximo, formando k clusters.
- Passo de Atualização: Calcula os novos centróides como a média de todos os pontos atribuídos a cada cluster.
- Repetição: Repete os passos de atribuição e de atualização até que os centróides já não mudem significativamente ou até que um número máximo de iterações seja atingido.

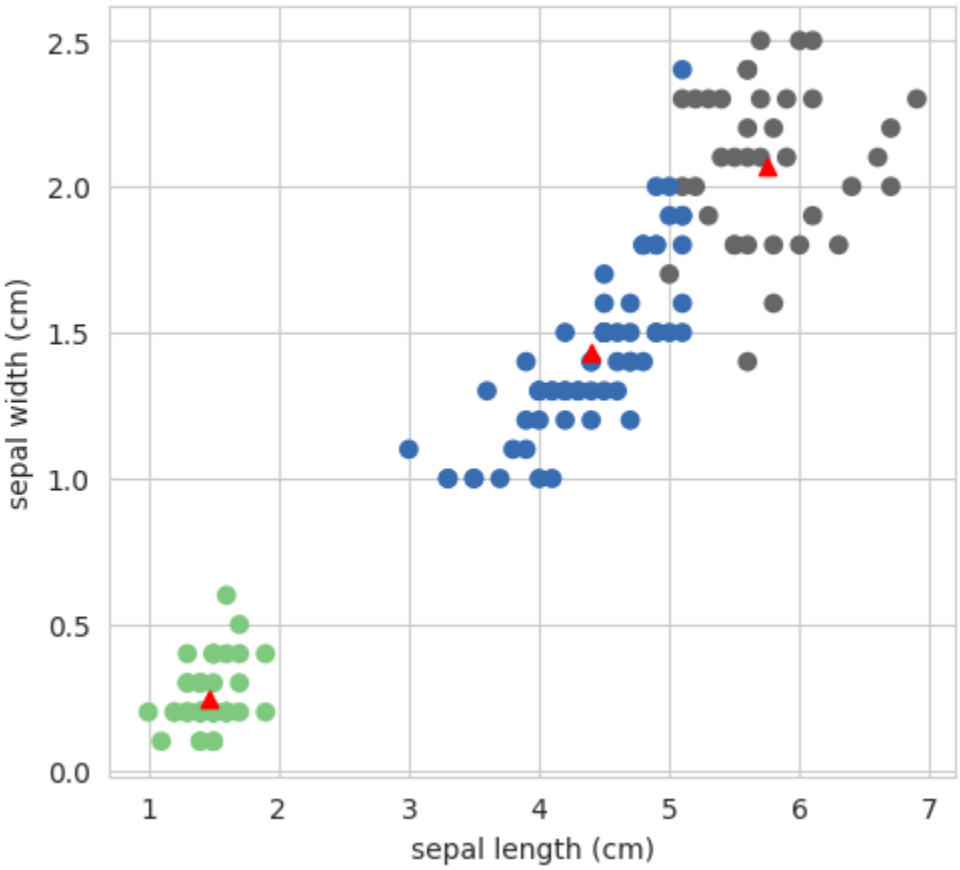

Exemplo Orange

Clustering Hierárquico

Dataset: Mall_Customers.csv

Para criar um clustering hierárquico é necessário escolher as variáveis a utilizar (*select columns*) e depois criar distâncias entre essas variáveis e visualizar utilizando um dendograma.

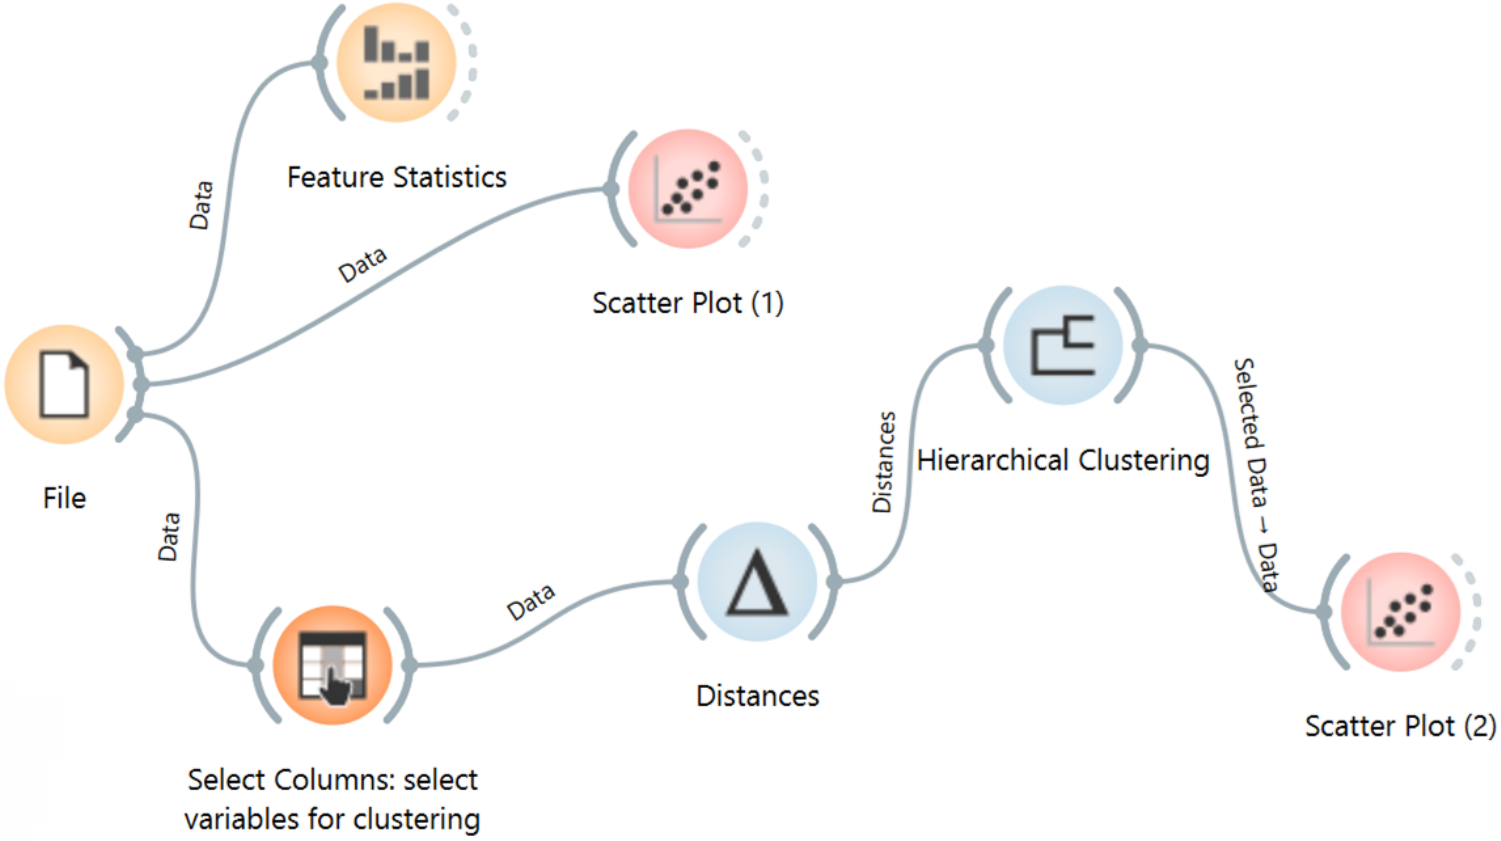

Clustering Hierárquico

Dataset: Mall_Customers.csv

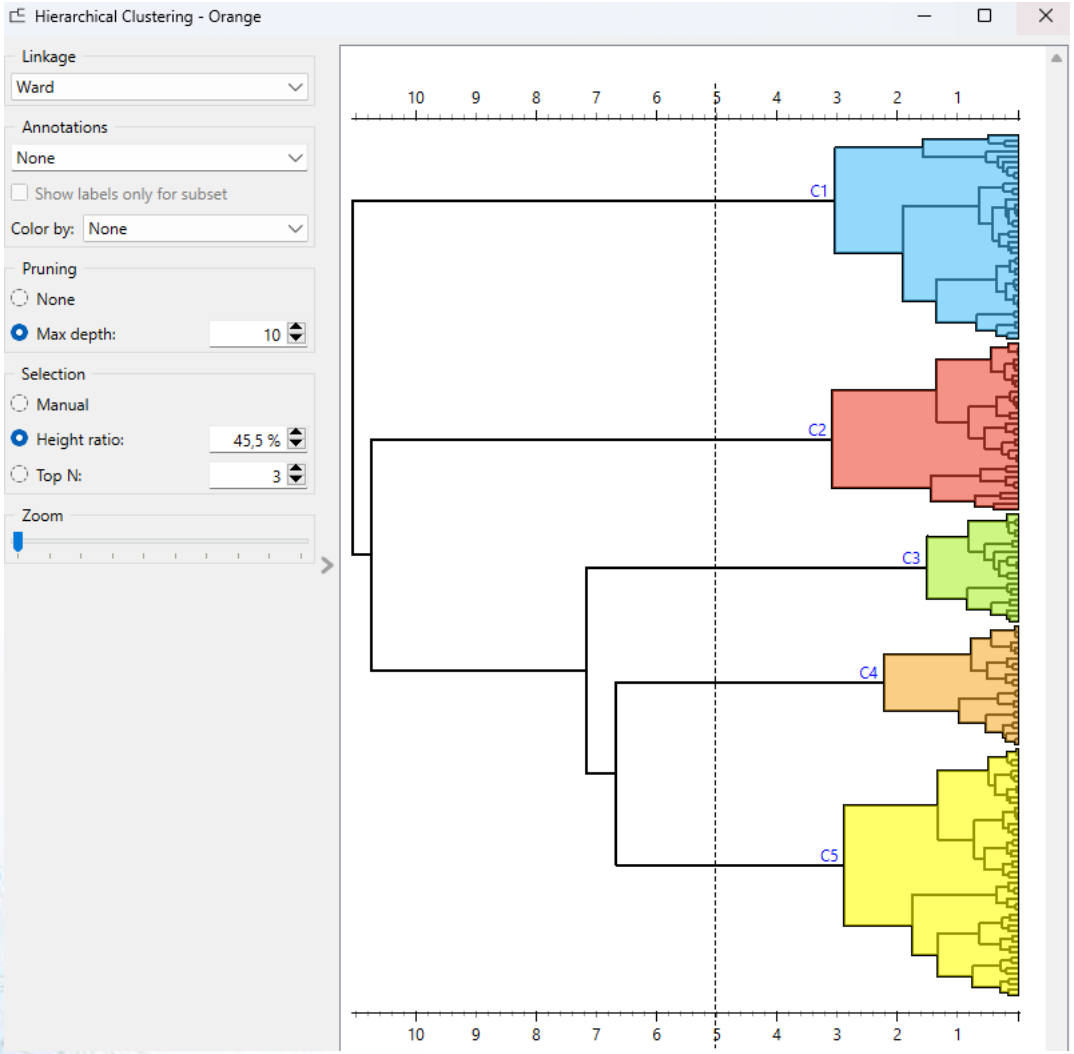

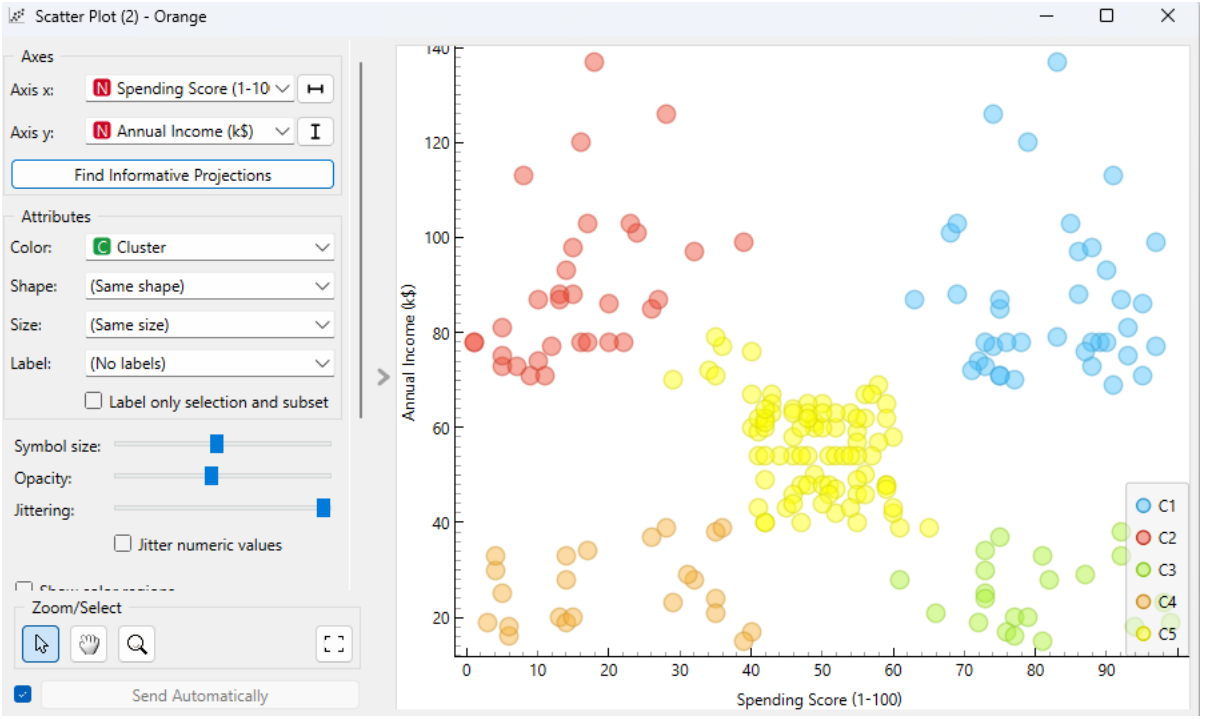

k-Means Clustering

Dataset: Mall_Customers.csv

Para criar um k-means clustering hierárquico é definir antes quantos clusters se pretende. O widget k-Means calcula a métrica *Silhoutte Score* para ajudar a encontrar o melhor valor para k.

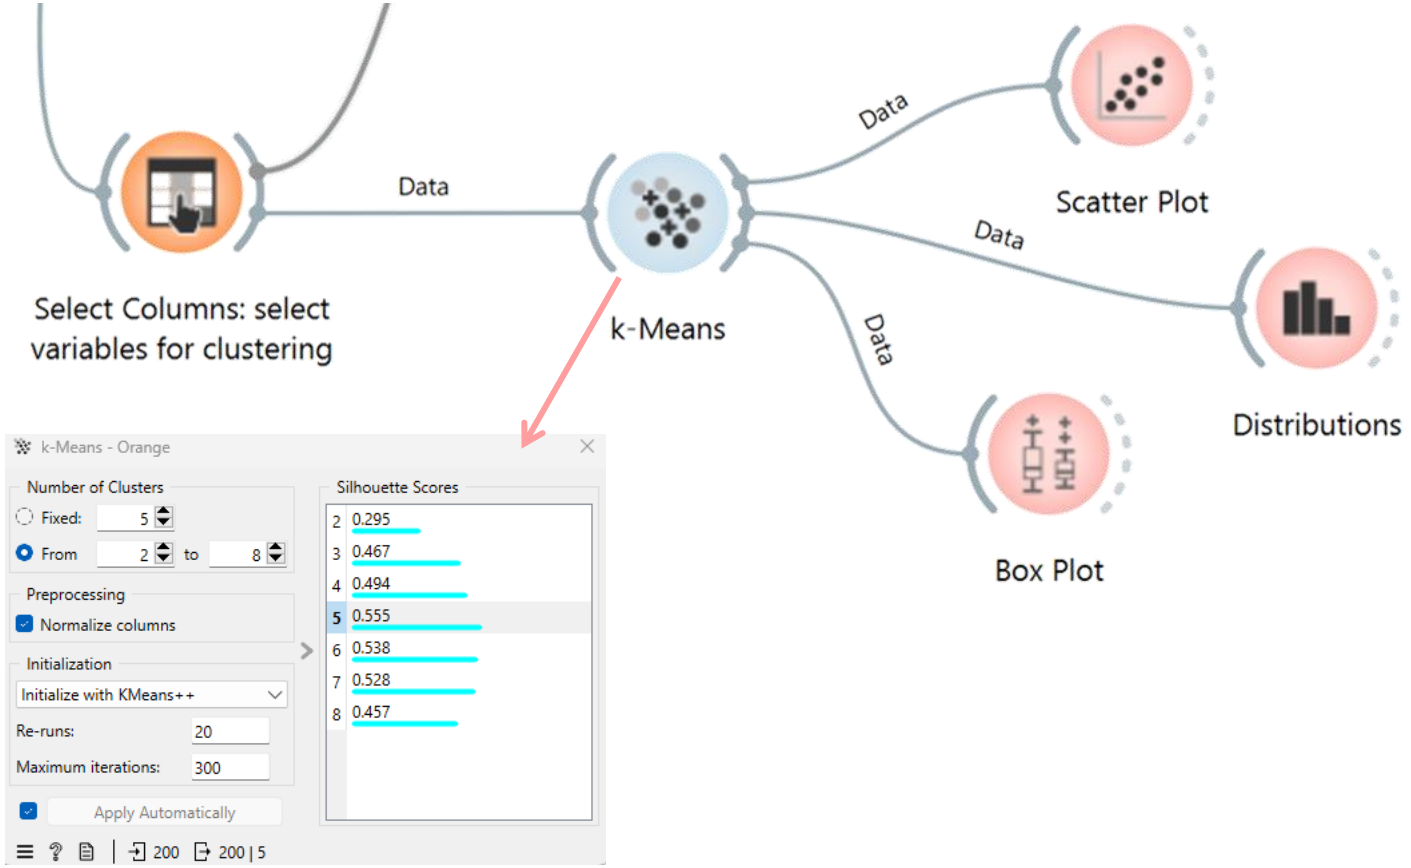

Clustering

Dataset: Mall_Customers.csv

Depois de encontrados os clusters é possível atribuir nomes aos mesmos e juntar esta nova variável aos dados!

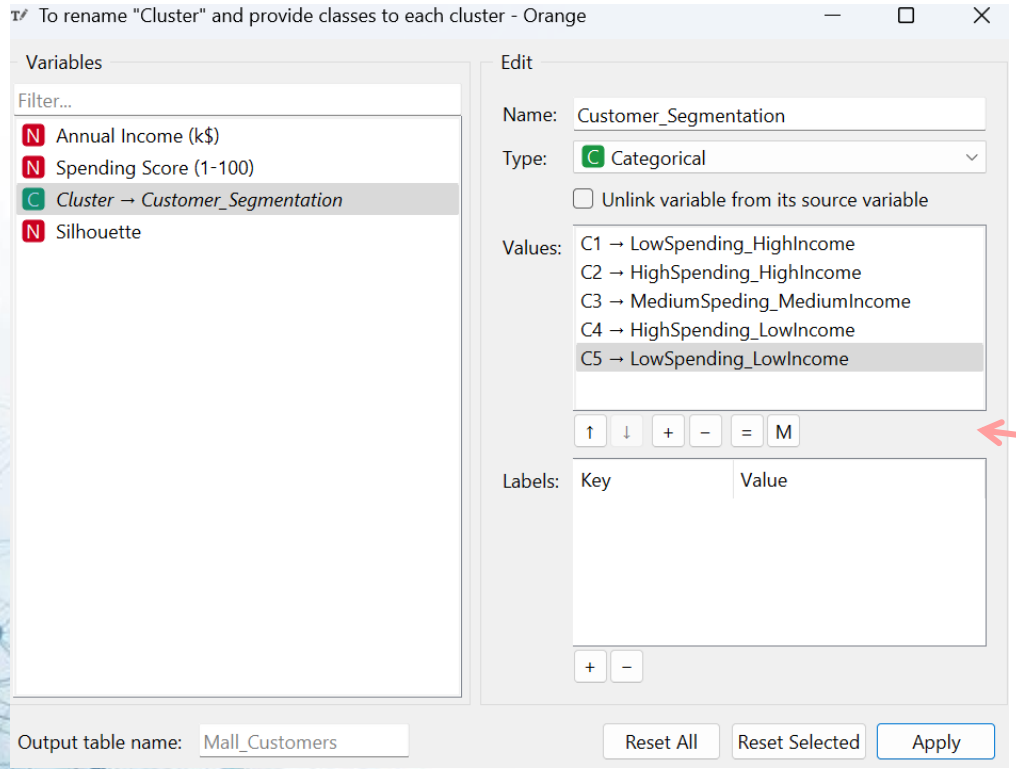

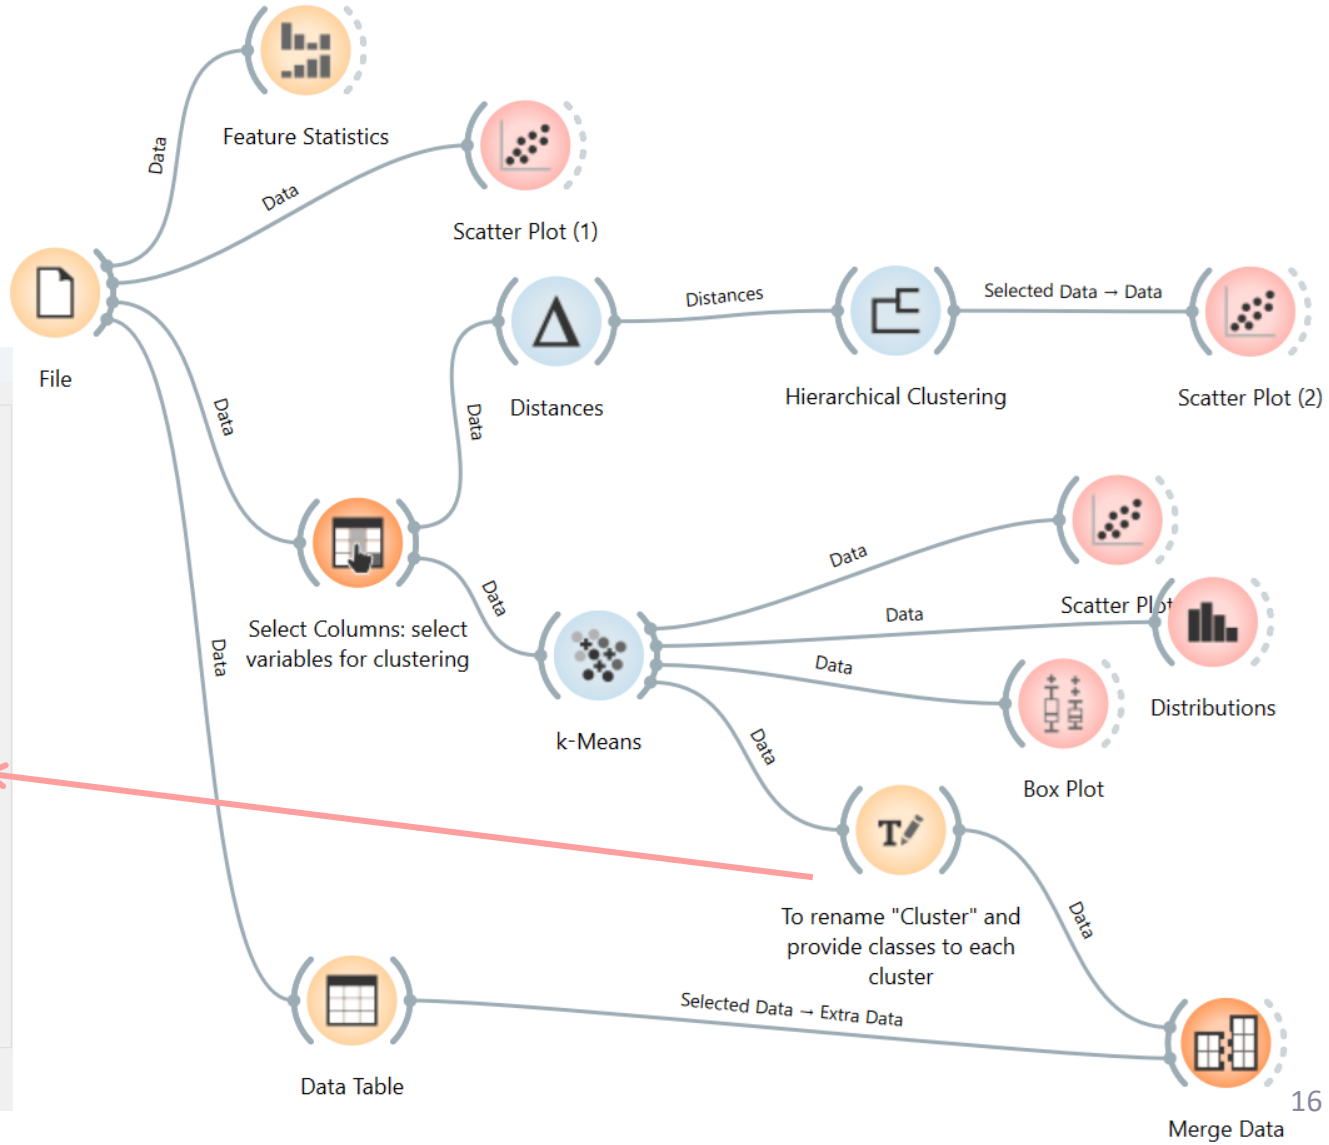

Clustering
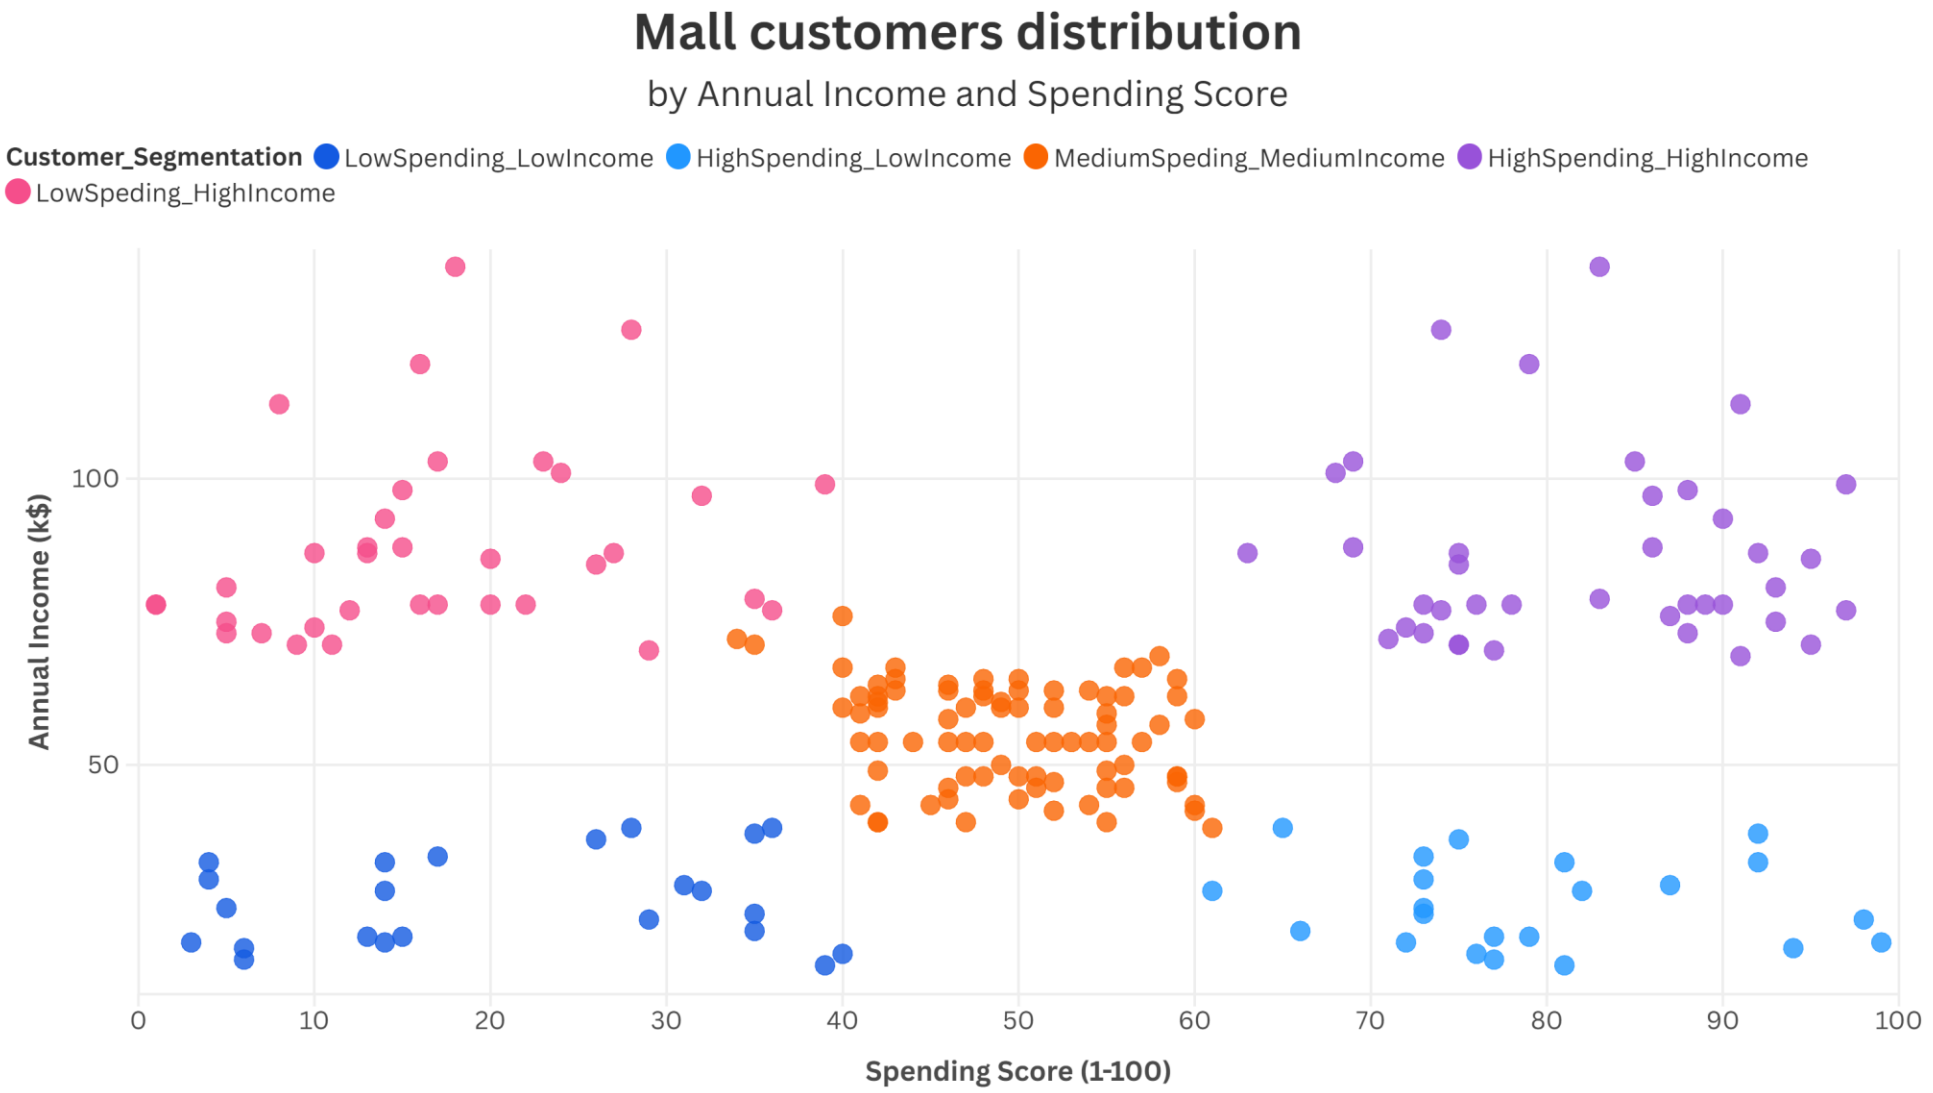
Dataset: Mall_Customers.csv